

读 书 笔 记

Book Notes

郭浩

2021 年 12 月 6 日–2026 年 5 月 9 日

目录

I 数学与信息科学	1
1 千年难题	3
2 素数之恋	5
3 素数的阴谋	7
4 Serge Lang 演讲录	11
5 数理统计学讲义	13
5.1 估计	13
5.1.1 总体参数的估计	13
5.2 假设检验	15
5.2.1 补充	15
6 计量经济学导论：现代观点	17
6.1 导论	17
6.2 横截面数据的线性回归模型	18
6.2.1 模型假定	18
6.2.2 最小二乘法	19

6.2.3	OLS 估计量的期望、方差	21
6.2.4	Gauss-Markov 定理	21
6.2.5	总体参数的区间估计和假设检验	22
6.2.6	OLS 估计量的渐近性质	23
6.2.7	预测区间估计	24
6.2.8	过原点回归	25
6.2.9	非线性关系建模	25
6.2.10	遗漏变量偏误	26
6.2.11	函数形式误设	27
6.2.12	组间异质性	27
6.2.13	异方差性	27
6.2.14	多重共线性	30
6.2.15	关于实践的评注	30
6.3	时间序列数据的线性回归模型	31
6.4	面板数据的线性回归模型	31
7	贝叶斯数据分析	33
7.1	贝叶斯推断	33
7.2	贝叶斯数据分析	33
7.3	贝叶斯计算	33
8	为什么：关于因果关系的新科学	35
9	机器学习	37
9.1	前言	37

10 图表示学习	39
10.1 导论	39
10.2 特征提取	40
10.2.1 节点特征	40
10.2.2 节点对特征	42
10.2.3 图特征	42
10.3 图嵌入	43
10.3.1 节点表示	43
10.3.2 图（子图）表示	44
10.4 消息传递	44
10.5 图神经网络	46
10.5.1 基本框架	46
10.5.2 设计空间	46
10.5.3 训练流程	47
10.5.4 常见模型	48
10.6 图生成模型	49
10.7 其它主题	49
11 科学之路：人、机器与未来	51
12 Nature Methods 方法简介	55
12.1 Association, correlation and causation	55
12.2 Quantile regression	55

II 物质科学 57

13 皇帝新脑 59

13.1 机器智能、算法与意识 59

13.2 数学、实在与证明 60

13.3 经典和量子物理 62

14 规模：复杂世界的简单法则 63

14.1 规模法则 63

14.2 生命科学 64

14.3 城市科学 65

14.4 公司科学 67

14.5 结论 68

15 随棕鸟飞行：复杂系统的奇境 69

III 生命科学 71

16 生态学经典论文 73

16.1 奠基性论文 73

16.2 理论进展 75

16.3 争论与综合 77

16.4 方法进展 78

16.5 自然系统中的案例研究 79

16.6 受控实验研究 81

目录	vii
IV 地球科学	85
17 新城市科学	87
17.1 基础与前提	87
18 计量地理学	89
18.1 概论	89
18.2 数据探索性可视化	90
18.2.1 单变量方法	90
18.2.2 多变量方法	91
18.3 点模式分析	91
18.4 空间回归分析	94
18.5 局部分析	95
18.6 空间数据统计推断	96
18.7 空间交互模型	97
18.8 前景与展望	98
19 城市与区域建模中的最大熵方法	99
19.1 背景	99
19.2 交通模型	100
19.2.1 重力模型	101
19.2.2 广义重力模型	102
19.2.3 中介机会模型	104
19.3 商品流模型	105
19.3.1 重力模型	105

19.3.2 投入产出模型	107
20 地理信息科学与系统	109
20.1 引言	109
20.2 地理数据的性质	112
20.3 地理表达	113
20.4 地理参照	115
20.5 不确定性	116
20.6 地理信息系统软件	118
20.7 地理数据建模	119
20.8 数据收集	120
20.9 空间数据库	120
20.10 GeoWeb	121
20.11 地图学	122
21 这里是中国	125
22 Michael Batty 评论集	131
22.1 A new kind of search	131
V 人文与艺术	133
23 南雍古典文学八讲	135
24 解谜：向 18 种经典谜题的巅峰发起挑战	137

目录	ix
VI 哲学与社会科学	141
25 马克思恩格斯著作	143
25.1 共产党宣言	143
26 有了博士学位还不够：学术生涯指南	145

Part I

数学与信息科学

Chapter 1

千年难题

The Millennium Problems: The Seven Greatest Unsolved Mathematical Puzzles of Our Time

Keith Devlin

千年难题奖金由企业家 Landon Clay 捐赠，由其设立的非营利性组织克雷数学促进会 (Clay Mathematics Institute) 掌管，七个问题各提供 100 万美元奖金。

Riemann 猜想：除本身不够准确而没有确定答案的问题外，黎曼猜想是 1900 年希尔伯特问题中唯一到 2000 年仍未被解决的。详见第2章。

Yang-Mills 方程存在性与质量缺口：相对论和量子力学的矛盾呼唤物质的大统一理论，其可以解释引力、电磁力、强核力、弱核力。大多数寻找大统一理论的努力在于发展量子场论。将麦克斯韦电磁理论扩展为量子场论的努力产生了规范理论，这一理论给时空中的每一点指派一个对称群。这一方向的理论突破包括量子电动力学 (QED)、电弱理论、量子色动力学 (QCD) 等。Yang-Mills 方程组是麦克斯韦方程组的量子理论版本。QED 是电磁理论的量子描述，而 Yang-Mills 方程组同时具有经典性和量子性，故是前者的扩展。该方程组尚无通解公式，题目要求证明对任何紧、单的规范群，四维欧氏空间中的量子 Yang-Mills 方程组有解，且该解预言质量缺口（即不存在无质量的粒子波）。

P 对 NP 问题：大整数质因数分解是 NP 的，故 $P=NP$ 将威胁到 RSA 密码体系的安全。作者认为可能的解决路径是构造一个自然不存在多项式时间解法的 NP 问题。

Navier-Stokes 方程存在性与光滑性：Navier-Stokes 方程描述了黏性流体在外力作用

下的运动:

$$\operatorname{div} \mathbf{u} = 0 \quad (1.1)$$

$$\frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} = \mathbf{f} - \operatorname{grad} p + v \nabla^2 \mathbf{u} \quad (1.2)$$

其中 $\mathbf{u}(x, y, z, t)$ 为流体速度, $\mathbf{f}(x, y, z, t)$ 为外力, $p(x, y, z, t)$ 为流体压强, v 为黏度 (流体内部摩擦力的度量)。欧拉给出了无摩擦流体的方程, Navier-Stokes 方程在其基础上增加了黏度项。二维情形下方程可解, 但三维情形下解的存在性未知。

Poincaré 猜想: 闭曲面的拓扑分类早已解决, 利用 Euler 示性数和可定向性也可以区分任何两个闭曲面。庞加莱猜想指出, 若一个三维闭流形是单连通的 (基本群是平凡的, 任一闭曲线可连续收缩为一点), 则它同胚于三维超球面。20 世纪数学家证明了庞加莱猜想对四维或更高维流形成立。

Birch 和 Swinnerton-Dyer 猜想: 设 E 是一条椭圆曲线, $E(\mathbb{Q})$ 是其上有理点的集合 (含无穷远点), 其可定义 Abel 群结构 (两点连线与 E 交点关于 x 轴对称点), Louis Mordell 证明了 $E(\mathbb{Q})$ 是有限生成的, 从而可表为有限阶元素构成的子群与 $\mathbb{Z}^r$ 的直积, r 被称为 E 的 Mordell-Weil 秩。Birch 和 Swinnerton-Dyer 猜想指出椭圆曲线的 Mordell-Weil 秩等于其 L 函数在 1 处的零点阶数。

Hodge 猜想: 一个非奇异射影代数簇上的每个 (一定类型的) 调和微分形式都是代数闭链上同调类的有理组合。调和微分形式是 Laplace 方程的解; 上同调类是闭微分形式依据差的恰当性进行的等价分类。

Chapter 2

素数之恋

Prime Obsession: Bernhard Riemann and the Greatest Unsolved Problem in Mathematics

John Derbyshire

黎曼假设来源于 Bernhard Riemann 在 1859 年因当选柏林科学院通讯院士提交的论文《论小于一个给定值的素数个数》。欧拉定义 ζ 函数为

$$\zeta(s) = \sum_{n=1}^{\infty} \frac{1}{n^s} = \prod_{p \text{ prime}} \frac{1}{1 - (\frac{1}{p})^s}, s > 1 \quad (2.1)$$

第二个等号称为欧拉积公式。黎曼考虑其复值函数形式 $\zeta(z)$ ，其在 $\text{Re} z > 1$ 收敛；并将其解析延拓到 $\mathbb{C}/\{z=1\}$ ，得到的函数称为黎曼 ζ 函数；该函数在所有负偶数取值为 0，称平凡零点；另有无穷多个非平凡零点位于 $0 < \text{Re} z < 1$ 的临界带内，且关于实轴、关于临界线 $\text{Re} z = 1/2$ 对称出现。Hardy 于 1914 年证明了位于临界线上的非平凡零点有无穷多个。黎曼假设断言非平凡零点均在临界线上。目前已用计算机验证了猜想对（按模长升序排列的）前 15 亿个零点成立；另一方面，E. Artin, A. Weil, P. Deligne 在有限域上发展了类似于黎曼假设的结果。

定义素数的计数函数 $\pi(x) = \#\{p \leq x | p \text{ prime}\}$ ，再令

$$J(x) = \sum_{n=1}^{\infty} \frac{1}{n} \pi(x^{\frac{1}{n}}), x > 0 \quad (2.2)$$

注意对给定的 x , $J(x)$ 为有限项的和。由 Möbius 反演得

$$\pi(x) = \sum_{n=1}^{\infty} \frac{\mu(n)}{n} J(x^{\frac{1}{n}}) \quad (2.3)$$

其中 $\mu(n)$ 是 Möbius 函数。黎曼将欧拉积公式表达为积分形式:

$$\frac{1}{s} \ln \zeta(s) = \int_0^{\infty} J(x) x^{-s-1} dx \quad (2.4)$$

这导向黎曼 1859 年论文的主要结果 (由 von Mangoldt 于 1895 年证明)

$$J(x) = Li(x) - \sum_{\rho} Li(x^{\rho}) - \ln 2 + \int_x^{\infty} \frac{1}{t(t^2 - 1) \ln t} dt \quad (2.5)$$

其中 $Li(x) = \int_0^x \frac{1}{\ln t} dt$, ρ 取遍 $\zeta(z)$ 的所有非平凡零点, 即 $\pi(x)$ 与 $\zeta(z)$ 的非平凡零点密切相关。事实上, 1896 年 Hadamard 和 de la Vallée Poussin 独立证明素数定理 $\pi(x) \sim Li(x)$, 即依赖黎曼假设的弱化结果: 非平凡零点满足 $\text{Re} z < 1$ 。1901 年 von Koch 证明, 如果黎曼假设成立, 那么有

$$\pi(x) = Li(x) + O(\sqrt{x} \ln x) \quad (2.6)$$

事实上该命题与黎曼假设等价。基于

$$\frac{1}{\zeta(s)} = \sum_{n=1}^{\infty} \frac{\mu(n)}{n^s} \quad (2.7)$$

黎曼假设的另一等价命题是

$$\sum_{k=1}^n \mu(k) = O(n^{1/2+\epsilon}), \forall \epsilon > 0 \quad (2.8)$$

Littlewood 于 1914 年证明随 x 增大, $Li(x) - \pi(x)$ 由正变负, 再由负变正, 由此反复无穷多次 (尽管第一次由正变负的位置非常大, 目前计算达不到)。

Chapter 3

素数的阴谋

The Prime Number Conspiracy: The Biggest Ideas in Math from Quanta

Thomas Lin eds.

集合论：连续统假设 (Continuum Hypothesis) 被证明独立于 ZFC 公理系统 (Gödel 于 1940 年证明了 ZFC 无法推出 CH 为假, Cohen(1963) 证明了 ZFC 无法推出 CH 为真). 两个候选公理可被加入 ZFC: (1) 力迫公理 (forcing axioms), 拓展集合的“宇宙”, 使连续统假设不成立, 可能有助于更多数学发现; (2) 内模型公理 (inner-model axiom) “V=终极 L”, 即集合宇宙等于一个可构造、同时包含大基数的“内模型”(“较小”的宇宙), 使连续统假设成立, 对数学其它领域影响较小.

代数：McKay 和 Thompson 发现了魔群不可约表示维数与 j 函数系数的联系. Conway-Norton(1979) 提出的魔群月光 (Monstrous Moonshine) 猜想刻画了这一联系, 这一猜想被 Borchers(1992) 借助弦论证明. 进一步地, 程之宁等 (2014) 提出的伴影月光 (Umbral Moonshine) 猜想断言了 23 种群与拟模形式系数的联系, 这 23 种新的“月光”分别有对应的弦论模型; 这一猜想被 Gannon(2016), Duncan-Griffin-Ono(2015) 证明.

数论：张益唐 (2014) 证明了

$$\liminf_{n \rightarrow \infty} (p_{n+1} - p_n) < 7 \times 10^7$$

这一结果改进了 Goldston-Pintz-Yildirim(2009,2010) 的结果, 即相邻素数间隔与平均间

隔的比例可以任意小:

$$\liminf_{n \rightarrow \infty} \frac{p_{n+1} - p_n}{\log p_n} = 0$$

Maynard(2015) 将张益唐的上界改进到 600, 他的工作对素数三元组以至更多元组也给出了结果。

Bhargava(2004) 给出了高斯二次型复合律的一种新表述, 并发现了三次型的若干复合律。这一工作拓展了数的几何 (geometry of numbers), 并被 Bhargava 用于解决数域与超椭圆曲线的问题。

Oliver-Soundararajan(2016) 发现给定前一个素数的尾数, 后一个素数尾数的分布不是均匀的, 这可由 Hardy-Littlewood(1923) 的 k 元素数猜想解释。

几何: Mirzakhani 的博士论文 (2007,2008) 解决了双曲曲面上简单测地线 (不与自身相交的测地线) 的计数问题, 同时得出了模空间的体积公式, 以及 Witten 猜想的一个新证明。

Scholze(2012) 引入的拟完满空间 (perfectoid spaces) 改变了 p 进域下算术代数几何的面貌。

费曼图的振幅被发现与代数几何中的原相周期 (period of motives) 重合, 原相是各种上同调理论 (奇异上同调, 平展上同调, de Rham 上同调) 从不同角度刻画的同一主题。

分析: Hairer(2014) 针对随机偏微分方程发展了正则结构 (regularity structures) 理论, 为物理学中的若干此类方程赋予了严格的数学含义。

概率论: Tracy-Widom 分布是一个左尾比右尾更陡的单峰分布, 不仅出现在一类随机矩阵最大特征值的分布中, 还表示了弱耦合相 (系统组分相对独立) 与强耦合相 (系统组分相互影响) 间的普适相变。

Liouville 量子引力 (Liouville Quantum Gravity, LQG) 和 Brownian Map 是随机二维曲面的两种描述模型, Miller-Sheffield(2020) 利用 Oded Schramm 引入的非交叉随机曲线 (Schramm-Loewner Evolution, SLE 曲线) 证明了二者的一致性。

组合学: Read 猜想断言图的色多项式系数是单峰且对数凹的 ($a_{n+1}a_{n-1} \leq a_n^2$); Rota 猜想断言拟阵的特征多项式是对数凹的。许峻珥 (2012) 利用奇点理论证明了 Read 猜想, 并与 Adiprasito 和 Katz (2018) 利用 Hodge 理论证明了 Rota 猜想。

离散几何: Viazovska(2017) 及合作者 (2017) 证明了 8 维、24 维球体的最密堆积分别为 E_8 和 Leech 格。这一结果的基础是 Cohen-Elkies(2003) 提出用辅助函数估计球堆积密

度上界；Viazovska 从模形式中找到了合适的辅助函数。

所有的三角形、凸四边形都可以密铺平面，可密铺的凸六边形有 3 种，而边数为 7 或更多的凸多边形不能密铺。Mann 等 (2018) 找到了第 15 种可密铺的凸五边形；Rao(2017) 用计算机验证了不存在其它的可密铺凸五边形。Penrose 铺陈是由两种图形实现的非周期密铺；Socolar-Taylor(2011) 给出了不连通单一图形非周期密铺的例子。Smith 等 (2024) 给出了连通单一图形的非周期密铺（由于所有凸多边形的密铺都是周期密铺，这样的图形必是凹的）。与之相关的是密铺的可判定性问题，已证明一组图形的可密铺性是不可判定的，而单一图形的可判定性问题仍未知。

王浩提出的“王氏砖” (Wang tiles) 是一种边带颜色的正方形，只允许颜色匹配的边相拼接。已证实只存在非周期密铺的王氏砖的集合。Jeandel-Rao(2021) 找到了一组只存在非周期密铺的 11 种王氏砖，并且 11 是最小的数字。

$\mathbb{F}_3^n$ 中不包含等差三元组的子集称为上集 (cap set), 如 SET 游戏中不包含 SET 的一组不同纸牌对应 $\mathbb{F}_3^4$ 中的一个上集, 其最大元素个数是 20. Ellenberg-Gijswijt(2017) 给出了上集个数的一个新上界.

Chapter 4

Serge Lang 演讲录

MATH! Encounters with High School Students

Math Talks for Undergraduates

Serge Lang

圆的周长、面积关系：证法一：考虑半径为 1 的圆，用内接正 n 边形逼近圆，设每个三角形的底为 b_n ，高为 l_n 。已知圆的周长为 2π ，则面积 $\lim_{n \rightarrow \infty} \frac{1}{2}nb_nl_n = \pi$ 。用网格逼近法说明圆半径放大为 r 倍时，面积为 r^2 倍。

证法二：已知圆的面积为 πr^2 ，考虑内径 r ，外径 $r+h$ 的环形，其面积 S 满足

$$C(r)h < 2\pi rh + \pi h^2 < C(r+h)h \quad (4.1)$$

同除 h 并令 $h \rightarrow 0$ ，得 $C(r) = 2\pi r$ 。

球的体积：考虑半径为 1 的半球，沿高均分为 n 层，每层用圆柱逼近。

$$V_n = \frac{\pi}{n} \sum_{i=1}^n \left(1 - \frac{i^2}{n^2}\right) = \pi - \frac{\pi}{n^3} \sum_{i=1}^n i^2 \rightarrow \frac{2\pi}{3}, n \rightarrow \infty \quad (4.2)$$

为直观说明 $\frac{\sum_i i^2}{n^3} \rightarrow 1/3$ ，考虑立方体切割为 $n \times n \times n$ 个小块，求和项占据以一个面为底、对面顶点为顶点的四棱锥。

球的表面积：类似圆的周长证法二，已知球的面积为 $\frac{4}{3}\pi r^3$ ，考虑内径 r ，外径 $r+h$ 的球壳，其体积 V 满足

$$S(r)h < 4\pi r^2h + 4\pi rh^2 + \frac{4}{3}\pi h^3 < S(r+h)h \quad (4.3)$$

同除 h 并令 $h \rightarrow 0$, 得 $V(r) = 4\pi r^2$.

Chapter 5

数理统计学讲义

陈家鼎 孙山泽 李东风 刘力平

数理统计学采用随机抽样法获得样本，并从样本推断总体的性质。统计推断主要包括两类问题：估计和假设检验。

当样本 $X_1, \dots, X_n$ 作为随机变量相互独立且与总体 X 同分布，称为简单随机样本。样本的函数 $g(X_1, \dots, X_n)$ 称为统计量。

发展简史：20 世纪以前描述性统计占主导地位（最小二乘法，正态分布， χ^2 分布，回归分析）；20 世纪初到二战结束，数理统计学蓬勃发展并达到成熟（t 分布，最大似然估计，方差分析，假设检验，置信区间，时间序列分析）；战后继续在理论和应用方向发展（统计决策理论，非线性滤波，贝叶斯学派兴起，计算机的应用）。

5.1 估计

5.1.1 总体参数的估计

设随机变量 X 的概率分布函数为 $F(x, \theta)$ ，给定 X 的样本 $x_1, \dots, x_n$ ，要求估计参数 θ 。

估计量的评价标准

相合与强相合：当样本量 $n \rightarrow +\infty$ ，若估计量依概率收敛到真值，称其有相合性；若估计量几乎必然（以概率 1）收敛到真值，称其有强相合性。

最大似然估计

由 Ronald A. Fisher 于 1912 年提出。设 X 的概率密度函数（离散随机变量为概率函数）为 $f(x, \theta)$ ，则样本的联合密度函数为

$$L(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f(x_i, \theta) \quad (5.1)$$

若估计量 $\hat{\theta} = \varphi(x_1, \dots, x_n)$ 满足

$$L(x_1, \dots, x_n, \hat{\theta}) = \sup_{\theta} L(x_1, \dots, x_n, \theta) \quad (5.2)$$

则称 $\hat{\theta}$ 是 θ 的最大似然估计。上述条件等价于对数似然函数 $\ln L(x_1, \dots, x_n, \theta)$ 的最大化。

常见概率分布的最大似然估计：

- Bernoulli 分布： $\hat{p} = \bar{x} = \sum_{i=1}^n x_i$.
- 指数分布 $\mathcal{E}(\lambda)$ ： $\hat{\lambda} = n / \sum_{i=1}^n x_i$.
- 正态分布 $\mathcal{N}(\mu, \sigma^2)$ ： $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$.
- 均匀分布 $\mathcal{U}(a, b)$ ： $\hat{a} = \min_i x_i$, $\hat{b} = \max_i x_i$.

上述最大似然估计量都是强相合估计，其中 Bernoulli 分布、指数分布、正态分布的情形可由强大数律导出。

矩估计

由 Karl Pearson 于 1894 年提出。设 $\theta = (\theta_1, \dots, \theta_m)$ ， X 的 1 至 m 阶原点矩存在，记为 $V_k = EX^k = g_k(\theta_1, \dots, \theta_m)$ ， $k = 1, \dots, m$ 。若能反解得到 $\theta_j = f_j(V_1, \dots, V_m)$ ， $j = 1, \dots, m$ ，则代入样本矩 $\tilde{V}_k = \frac{1}{n} \sum_{i=1}^n x_i^k$ ，即得到参数的矩估计。有时也用中心矩

$E(X - EX)^k$ 做矩估计。由强大数律，样本矩几乎必然收敛到总体矩；故当所有 f_j 为连续函数时，矩估计量是强相合的。

正态分布的矩估计与最大似然估计一致，但这并非普遍情形。

5.2 假设检验

5.2.1 补充

Mann-Whitney U 检验

Kolmogorov-Smirnov 检验

Chapter 6

计量经济学导论：现代观点

Introductory Econometrics: A Modern Approach

Jeffrey M. Wooldridge

6.1 导论

计量经济学是数理统计的一个分支，主要研究非实验经济数据收集与分析的固有问题。非实验数据 (non-experimental data) 也称观测数据 (observational data)，区别于（自然科学中）控制实验得到的数据，强调研究者只是被动的数据收集者。

计量模型中自变量的识别依据经济理论或直觉。误差项 (error term) 或干扰项 (disturbance term) 包含了不可观测及未识别的变量，以及度量自变量时的误差。

数据集分类：(1) **横截面数据** (cross-sectional data)，同一时间段（或不考虑时间差异）多个样本，通常假定是随机抽样得到（即样本独立同分布）。(2) **时间序列数据** (time series data)，一个或多个变量不同时间的观测值，一般不能假定观测独立于时间，需考虑自相关、季节效应等。(3) **混合横截面数据** (pooled cross-section data)，多个时间段横截面数据的组合（每个时间段对应不同随机样本）。(4) **面板数据** (panel data)，多个样本的时间序列，区别于混合横截面数据，每个单元都被重复观测；可以控制观测单元无法观测的特征，有助于因果推断和时间滞后的研究。

研究两个变量的关系时往往需要其它（相关）因素不变 (ceteris paribus)；退一步的要求是所关注自变量的选择独立于其它相关因素，从而可以视为实验数据。非实验数据的特

征导致难以达到识别因果效应 (casual effect) 的目标。

6.2 横截面数据的线性回归模型

6.2.1 模型假定

(1) 线性于参数：总体模型为

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u \quad (6.1)$$

其中 β_0 称截距 (intercept), $\beta_j (j = 1, \dots, k)$ 称斜率参数 (slope parameter), u 为误差项。

这一模型称为多元线性回归 (multiple linear regression) 模型；当 $k = 1$ 时，称为简单线性回归 (simple linear regression) 模型。

(2) 随机抽样：设有来自上述总体模型的含 n 个观测的随机样本 $\{(x_{i1}, \dots, x_{ik}, y_i)\}_{i=1}^N$ ，也即每个样本满足

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + u_i. \quad (6.2)$$

(3) 不存在完全共线性：样本中没有一个自变量是常数，自变量之间也没有严格线性关系。

这一假定保证了普通最小二乘法 (ordinary least squares, OLS) 估计的存在唯一性。假定的成立必要条件是样本容量 $n \geq k + 1$ 。自变量之间的非线性依赖关系是被允许的。

(4) 零条件均值：给定自变量任何值，误差期望为 0。

$$E(u|x_1, \dots, x_k) = 0. \quad (6.3)$$

这一假定保证了 OLS 参数估计的无偏性。自变量与误差独立是一个更强的条件。违背此假定的情形包括因变量与自变量关系的误设（如应为二次函数但模型未包括二次项）、遗漏变量（且该变量与任一自变量相关）等。

假定 (1)(4) 可写成

$$E(y|x_1, \dots, x_k) = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k \quad (6.4)$$

这称为总体回归函数 (population regression function)。

(4') 零均值和零相关: 对 $j = 1, 2, \dots, k$,

$$Eu = 0, \text{Cov}(x_j, u) = 0 \quad (6.5)$$

(4) 蕴含 (4'). 这一假设与 OLS 一阶条件对应。(1)-(3),(4') 即可得到 OLS 估计量的一致性, 但不能保证无偏性; 且得不到总体回归函数 (6.4)。若某个自变量 x_j 与 u 相关, 称为**内生解释变量** (endogenous explanatory variable)。

(5) 同方差性 (homoskedasticity): 给定自变量任何值, 误差方差相同,

$$\text{Var}(u|x_1, \dots, x_k) = \sigma^2 \quad (6.6)$$

也即 $\text{Var}(y|x_1, \dots, x_k) = \sigma^2$ 。误差方差随自变量变化, 称为异方差性 (heteroskedasticity)。

假设 (1)-(5) 称为横截面数据回归的 Gauss-Markov 假定。

(6) 正态性: 总体误差 u 独立于解释变量 $x_1, \dots, x_k$, 且服从均值为 0、方差为 σ^2 的正态分布。

这一假设蕴含 (4)(5), 用于得到 OLS 斜率估计值的抽样分布, 从而进行假设检验和置信区间估计。该假定的依据可以来自中心极限定理, 但要求误差是众多独立同分布随机因素的和 (事实上各因素总体分布也可以不一致, 但会影响正态近似的程度)。

(1)-(6) 合称为经典线性模型 (classical linear model, CLM) 假设。CLM 总体假定可表述为

$$y|x_1, \dots, x_k \sim N(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k, \sigma^2) \quad (6.7)$$

6.2.2 最小二乘法

给定自变量、因变量的一个样本, 被估计的方程, 即样本回归函数 (sample regression function) 形如

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \quad (6.8)$$

其中 $\hat{\beta}_0$ 称截距估计值 (intercept estimate); $\hat{\beta}_j (j = 1, \dots, k)$ 称斜率估计值 (slope estimate), 代表了其它变量不变时 x_j 对 y 的偏效应 (partial effect)。观测 i 的拟合值为

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_k x_{ik} \quad (6.9)$$

残差 (residual) 定义为

$$\hat{u}_i = y_i - \hat{y}_i. \quad (6.10)$$

区别于不可观测的误差，残差是可以计算得到的。普通最小二乘法最小化残差平方和，得到如下一阶条件 (first order conditions):

$$\sum_{i=1}^N \hat{u}_i = 0 \quad (6.11)$$

$$\sum_{i=1}^N \hat{u}_i x_{ij} = 0, j = 1, \dots, k \quad (6.12)$$

这也可以由零条件均值假设推出：上式为 $Eu = 0, E(x_j u) = 0$ 在样本中的对应。

斜率估计值的一个公式为

$$\hat{\beta}_j = \frac{\sum_{i=1}^n \hat{r}_{ij} y_i}{\sum_{i=1}^n \hat{r}_{ij}^2} \quad (6.13)$$

其中 $\hat{r}_{ij}$ 为 x_j 对 $x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k$ 的回归残差。特别地，对于简单线性回归，斜率估计值

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x}) y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)} \quad (6.14)$$

式 (6.13) 右端即 y 对 $\hat{r}_j$ 进行简单线性回归的斜率估计，表明多元回归度量了“排除其他变量影响”时的关系。

定义总平方和 (total sum of squares, SST), 解释平方和 (explained sum of squares, SSE), 残差平方和 (sum of squared residuals, SSR) 如下:

$$\text{SST} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 \quad (6.15)$$

$$\text{SSE} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^n \hat{y}_i^2 - n\bar{y}^2 \quad (6.16)$$

$$\text{SSR} = \sum_{i=1}^n \hat{u}_i^2 \quad (6.17)$$

可以证明 $\text{SST} = \text{SSR} + \text{SSE}$ 。定义决定系数 (coefficient of determination, R-squared, R^2):

$$R^2 = 1 - \text{SSR}/\text{SST} \quad (6.18)$$

R^2 同时是实际值 y_i 和拟合值 $\hat{y}_i$ 相关系数的平方。注意这只对于线性回归成立，在其它模型下，二者可能不同；按式 (6.18) 计算， R^2 可能为负；但按相关系数平方计算， R^2 总在 $[0,1]$ 中。

在方程中增加一个自变量，通常总会使 R^2 增大；调整 R^2 (adjusted R-squared) 对自变量个数进行了惩罚：

$$\bar{R}^2 = 1 - \frac{\text{SSR}/(n - k - 1)}{\text{SST}/(n - 1)} \quad (6.19)$$

事实上, 增加一个 (一组) 自变量时, 调整 R^2 增加当且仅当其 t 统计量 (F 统计量) 大于 1。此定义的依据是, 设总体 R^2 为 $1 - \sigma_u^2 / \sigma_y^2$, 即总体中 y 的变化可被自变量解释的部分; (6.19) 第二项的分子、分母分别是 σ_u^2, σ_y^2 的无偏估计。但事实上调整 R^2 并不是一个无偏估计量。调整 R^2 也可能为负。对于两个非嵌套模型 (non-nested model, 即没有一个是另一个的特殊情况), 可用调整 R^2 进行模型选择。

6.2.3 OLS 估计量的期望、方差

在假定 (1)-(4) 下, OLS 估计量是总体参数的无偏估计量, 即

$$E(\hat{\beta}_j) = \beta_j, j = 0, 1, \dots, k \quad (6.20)$$

在假定 (1)-(5) 下, OLS 斜率估计量以自变量为条件的方差为

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\text{SST}_j(1 - R_j^2)}, j = 0, 1, \dots, k \quad (6.21)$$

其中 $\text{SST}_j = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$, R_j^2 是 x_j 对所有其它自变量回归得到的 R^2 。

在假定 (1)-(5) 下,

$$\hat{\sigma}^2 = \text{SSR} / (n - k - 1) \quad (6.22)$$

是误差方差的无偏估计。其平方根 $\hat{\sigma}$ 称回归标准误 (standard error of regression, SER), 不是误差标准差的无偏估计。OLS 斜率估计量的标准差 (standard deviation) 为

$$\text{sd}(\hat{\beta}_j) = \sigma / \sqrt{\text{SST}_j(1 - R_j^2)} \quad (6.23)$$

其估计值 (称 $\hat{\beta}_j$ 的标准误) 为:

$$\text{se}(\hat{\beta}_j) = \hat{\sigma} / \sqrt{\text{SST}_j(1 - R_j^2)} \quad (6.24)$$

随着样本量的增大, 其以 $1/\sqrt{n}$ 速率收敛到 0。

6.2.4 Gauss-Markov 定理

在假定 (1)-(5) 下, 对任何 $j = 0, 1, \dots, k$, 设 $\tilde{\beta}_j$ 是 β_j 的任一无偏估计量, 且具有形式 $\tilde{\beta}_j = \sum_{i=1}^n w_{ij}y_i$, 其中 w_{ij} 是自变量值的函数, 则有

$$\text{Var}(\tilde{\beta}_j) \geq \text{Var}(\hat{\beta}_j) \quad (6.25)$$

也即 OLS 估计量是最优 (方差最小) 的线性无偏估计量 (best linear unbiased estimate)。

进一步, 在假设 (1)-(6) 下, OLS 估计量是最小方差无偏估计量 (无需限定线性)。

6.2.5 总体参数的区间估计和假设检验

t 检验

在假定 (1)-(6) 下, OLS 斜率估计量抽样分布为正态分布:

$$(\hat{\beta}_j - \beta_j)/\text{sd}(\hat{\beta}_j) \sim N(0, 1) \quad (6.26)$$

用标准误估计标准差, 得到 t 分布:

$$(\hat{\beta}_j - \beta_j)/\text{se}(\hat{\beta}_j) \sim t_{n-k-1} \quad (6.27)$$

随着自由度增加, t 分布会接近标准正态分布。当自由度大于 120, 可以使用正态分布的临界值。

总体参数 β_j 的置信区间为

$$[\hat{\beta}_j - c \times \text{se}(\hat{\beta}_j), \hat{\beta}_j + c \times \text{se}(\hat{\beta}_j)] \quad (6.28)$$

当置信水平为 α 时, c 为对应 t 分布的 $(1 + \alpha)/2$ 分位数。

设原假设 $H_0 : \beta_j = a_j$ (最常见的情形是 $a_j = 0$), t 统计量定义为 $(\hat{\beta}_j - a_j)/\text{se}(\hat{\beta}_j)$ 。双侧备择假设 (two-sided alternative) $H_1 : \beta_j \neq a_j$ 对应双边检验 (two-tailed test), 单侧备择假设 (one-sided alternative) $H_1 : \beta_j > a_j$ (或 $H_1 : \beta_j < a_j$) 对应单边检验 (one-tailed test)。若拒绝原假设 $H_0 : \beta_j = 0$, 称 x_j 在给定显著性水平下是统计显著的。检验的 p 值定义为能拒绝原假设的最小显著性水平, 即原假设成立时, 统计量 (双边检验时为统计量的绝对值) 不小于观测值的概率。

除统计显著性外, 还要关注变量的经济 (实际) 显著性 (economic/practical significance), 即 OLS 斜率估计值的大小。大样本下容易得到统计显著性, 即使斜率估计值代表的实际含义影响很小。

检验多个总体参数的线性关系, 如 $\beta_1 = \beta_2$, 可通过变量代换 $\beta_1 = \beta_2 + \theta_1$, 转化为检验 θ_1 的统计显著性。

F 检验

检验总体参数的多个线性关系, 称原模型为不受约束模型 (unrestricted model), 代入多重约束后的模型为受约束模型 (restricted model), 定义 F 统计量为

$$F = \frac{(\text{SSR}_r - \text{SSR}_{ur})/q}{\text{SSR}_{ur}/(n - k - 1)} \quad (6.29)$$

其中 SSR_{ur}, SSR_r 分别为原模型和受约束模型的残差平方和, q 为线性约束的个数, 也即两模型的自由度之差。在假定 (1)-(6) 下, $F \sim F_{q, n-k-1}$.

一种常见情形是 q 个排除性约束: $H_0: \beta_{k-q+1} = 0, \dots, \beta_k = 0$, 此时若拒绝原假设, 称 $x_{k-q+1}, \dots, x_k$ 在给定显著性水平下联合显著。此时 F 统计量改写为

$$F = \frac{(R_{ur}^2 - R_r^2)/q}{(1 - R_{ur}^2)/(n - k - 1)} \quad (6.30)$$

当 $q = k$ 时, 即 $H_0: \beta_1 = \dots = \beta_k = 0$, 有

$$F = \frac{R^2/k}{(1 - R^2)/(n - k - 1)} \quad (6.31)$$

这称为回归的整体显著性 (overall significance of the regression) 检验。

检验单个变量排除性假设的 F 统计量等于相应 t 统计量的平方, 而 t_{n-k-1}^2 与 $F_{1, n-k-1}$ 同分布, 故二者等价。但对一组变量而言, 可能出现每个变量均不显著但联合显著 (如由于多重共线性), 或单个显著变量与若干不显著变量的整体联合不显著。

Lagrange 乘数检验

Lagrange 乘数统计量 (Lagrange multiplier statistic) 也用于检验多个排除约束。设 $H_0: \beta_{k-q+1} = 0, \dots, \beta_k = 0$ 。先估计受约束模型, 得到残差 $\tilde{u}$, 再将 $\tilde{u}$ 对所有自变量做回归, 记其 R^2 为 R_u^2 。Lagrange 乘数统计量定义为:

$$LM = nR_u^2 \quad (6.32)$$

$n \rightarrow \infty$ 时依分布收敛于自由度为 q 的 χ^2 分布。若 LM 大于卡方分布临界值, 则拒绝原假设。

6.2.6 OLS 估计量的渐近性质

OLS 估计量的无偏性、有效性 (Gauss-Markov 定理) 等属于有限样本性质 (或精确性质); 渐近性质 (asymptotic properties, 或大样本性质) 关注样本容量趋于无穷大的情形。经济学界认为一致性 ($n \rightarrow \infty$ 时依概率收敛到总体参数) 是对估计量的基本要求。

在假定 (1)-(3), (4') 下, OLS 估计量 $\hat{\beta}_j$ 是 β_j 的一致估计量, $j = 0, 1, \dots, k$ 。事实上对于简单线性回归, 斜率估计量的概率极限

$$\text{plim} \hat{\beta}_1 = \beta_1 + \frac{\text{Cov}(x_1, u)}{\text{Var}(x_1)} \quad (6.33)$$

右端第二项是误差与自变量相关导致的渐近偏误 (asymptotic bias)。对于一般情形，与 OLS 斜率估计量期望的偏差类似，若 x_1 与 u 相关，其余变量与 x_1 和 u 都不相关，则只有 $\hat{\beta}_1$ 不一致。

在假定 (1)-(5) 下，OLS 估计量满足渐近正态性 (asymptotic normality)。当 $n \rightarrow \infty$,

(a) $\sqrt{n}(\hat{\beta}_j - \beta_j)$ 依分布收敛到 $N(0, \sigma^2/a_j^2)$, 其中 $a_j^2 = \text{plim}(\sum_{i=1}^n \hat{r}_{ij}^2/n)$, σ^2/a_j^2 称为 $\sqrt{n}(\hat{\beta}_j - \beta_j)$ 的渐近方差;

(b) $\hat{\sigma}^2$ 是 $\sigma^2 = \text{Var}(u)$ 的一致估计量，从而 $\hat{\sigma}$ 是 σ 的一致估计量;

(c) $(\hat{\beta}_j - \beta_j)/\text{sd}(\hat{\beta}_j)$ 依分布收敛到 $N(0, 1)$; $(\hat{\beta}_j - \beta_j)/\text{se}(\hat{\beta}_j)$ 依分布收敛到 $N(0, 1)$.

这意味着大样本条件下无需假设 (6)，OLS 的置信区间估计、t 检验、F 检验可如常进行。

在假定 (1)-(5) 下，OLS 估计量满足渐近有效性。考虑求解如下方程组得到的估计量：

$$\sum_{i=1}^n g_j(x_{i1}, \dots, x_{ik})(y_i - \tilde{\beta}_0 - \tilde{\beta}_1 x_{i1} - \dots - \tilde{\beta}_k x_{ik}) = 0, j = 0, 1, \dots, k \quad (6.34)$$

其中 g_j 是对自变量的任意函数，可以证明由此得到的估计量是一致的。在所有上述形式的估计量中，OLS 估计量的 $\sqrt{n}(\hat{\beta}_j - \beta_j)$ 具有最小的渐近方差。

6.2.7 预测区间估计

设自变量取值 $x_1 = c_1, \dots, x_k = c_k$ ，令 $\theta_0 = \beta_0 + \beta_1 c_1 + \dots + \beta_k c_k$ ，则有 $\theta_0 = E(y|x_1 = c_1, \dots, x_k = c_k)$ 。估计量 $\hat{\theta}_0 = \hat{\beta}_0 + \hat{\beta}_1 c_1 + \dots + \hat{\beta}_k c_k$ 给出 θ_0 的无偏估计，其标准误由 y 对 $x_1 = c_1, \dots, x_k = c_k$ 回归截距项的标准误得到，由此可计算条件均值 θ_0 的置信区间。

实际用于预测时，还需纳入误差的影响。设 $y_0 = \beta_0 + \beta_1 c_1 + \dots + \beta_k c_k + u_0$ ，估计量 $\hat{y}_0 = \hat{\theta}_0$ ，预测误差

$$\hat{e}_0 = \beta_0 + \beta_1 c_1 + \dots + \beta_k c_k + u_0 - \hat{y}_0 \quad (6.35)$$

以样本内自变量取值为条件，其期望为 0，方差为 $\text{Var}(\hat{y}_0) + \sigma^2$ 。定义预测误差的标准误

$$\text{se}(\hat{e}_0) = \sqrt{(\text{se}(\hat{y}_0))^2 + \hat{\sigma}^2} \quad (6.36)$$

在假定 (1)-(6) 下， $\hat{e}_0/\text{se}(\hat{e}_0)$ 服从 $n - k - 1$ 个自由度的 t 分布，由此可计算预测区间 (prediction interval)。

6.2.8 过原点回归

若利用最小二乘法估计不含截距项的模型，则残差的样本均值不一定为 0；若 $\beta_0 \neq 0$ ，OLS 的斜率估计量将有偏。若 $\beta_0 = 0$ ，带截距回归的 OLS 斜率估计量方差比过原点回归大。

6.2.9 非线性关系建模

常弹性模型： $\ln y = \beta_0 + \beta_1 \ln x$ ，解读为 x 每增加 1%， y 增加 $\beta_1\%$ ， β_1 称为 y 对 x 的弹性。

常半弹性模型： $\ln y = \beta_0 + \beta_1 x$ ，解读为 x 每增加 1， y 增加 $100\beta_1\%$ ， $100\beta_1$ 称为 y 对 x 的半弹性。

当模型为 $\ln y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u$ 时，由 $\ln y_0$ 的预测区间上下界 $[c_l, c_m]$ 可得 y_0 的预测区间 $[e^{c_l}, e^{c_m}]$ ；但点估计不能直接通过指数运算得到，在假定 (1)-(6) 下，

$$E(y|\mathbf{x}) = \exp(\sigma^2/2) \exp(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k) \quad (6.37)$$

故预测值应调整为

$$\hat{y} = \exp(\hat{\sigma}^2/2) \exp(\ln \hat{y}) \quad (6.38)$$

这一估计量一致但非无偏。若不满足正态性假设，预测值为

$$E(y|\mathbf{x}) = \alpha_0 \exp(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k) \quad (6.39)$$

$$\hat{y} = \hat{\alpha}_0 \exp(\ln \hat{y}) \quad (6.40)$$

α_0 的矩估计量是

$$\hat{\alpha}_0 = \frac{1}{n} \sum_{i=1}^n \exp(\hat{u}_i) \quad (6.41)$$

这一估计量一致但非无偏，且总大于 1（除非所有残差为 0）。

令 $m = \exp(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k)$ ，则 $E(y|m) = \alpha_0 m$ 。记 $\hat{m}_i = \exp(\ln \hat{y}_i)$ ，利用过原点回归得到 α_0 的估计量

$$\check{\alpha}_0 = \frac{\sum_{i=1}^n \hat{m}_i y_i}{\sum_{i=1}^n \hat{m}_i^2} \quad (6.42)$$

这一估计量一致但非无偏，且可能小于 1（此时可能意味着假定不满足）。

因变量为对数时的 R^2 不能和因变量为水平值的情形直接比较，解决方法有二：一是计算上述 $\hat{m}_i$ 与 y_i 相关系数的平方（不依赖 α_0 估计量的选取）；二是计算

$$1 - \frac{\sum_{i=1}^n (y_i - \hat{\alpha}_0 \exp(\ln \hat{y}_i))^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (6.43)$$

当方程包含二次项或两个变量的乘积项时，变量的偏效应取决于自变量取值。平均偏效应 (average partial effect) 即自变量取样本均值时的偏效应。包含乘积项时称这两个变量具有交互效应 (interaction effect)；通过将二次项改写为 $x_1(x_2 - c_2)$ ，则 x_1 的一次项系数可反映 $x_2 = c_2$ 时 x_1 的偏效应，同时可得到其标准误。

6.2.10 遗漏变量偏误

若包含了无关变量，即总体模型中事实上某个 $\beta_j = 0$ ，其它自变量斜率估计值的无偏性不受影响。

若遗漏了有关变量，则所有 OLS 估计量都可能存在偏误，称遗漏变量偏误 (omitted variable bias)。不失一般性，设遗漏变量 x_k 后的 OLS 估计量为 $\tilde{\beta}_j, j = 0, 1, \dots, k-1$ ， x_k 对 $x_1, \dots, x_{k-1}$ 回归的斜率估计值为 $\tilde{\delta}_j, j = 1, \dots, k-1$ ，则有

$$\tilde{\beta}_j = \hat{\beta}_j + \hat{\beta}_k \tilde{\delta}_j \quad (6.44)$$

其关于自变量的条件期望为

$$E(\tilde{\beta}_j) = \beta_j + \beta_k \tilde{\delta}_j \quad (6.45)$$

故除非 x_k 是无关变量，或回归系数 $\tilde{\delta}_j = 0$ 。有时可以利用 β_k 和 $\tilde{\delta}_j$ 的符号推测遗漏变量偏误的方向。

考虑遗漏一个变量后的简单线性回归，真实模型为 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + v$ ，满足假定 (1)-(4)，若遗漏变量 x_2 ，则有

$$E(\tilde{\beta}_1) = \beta_1 + \beta_2 \tilde{\delta}_1 \quad (6.46)$$

$$\tilde{\delta}_1 = \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2} \quad (6.47)$$

而渐近极限

$$\text{plim} \tilde{\beta}_1 = \beta_1 + \beta_2 \delta_1 \quad (6.48)$$

$$\delta_1 = \frac{\text{Cov}(x_1, x_2)}{\text{Var}(x_1)} \quad (6.49)$$

右式第二项为遗漏变量带来的不一致性。 $\tilde{\delta}_1$ 代表 x_1, x_2 的样本相关性, 而 δ_1 代表它们在总体中的相关性。

对于 OLS 估计量的方差而言, 遗漏变量会使其减小 (6.21)。但方差会随样本量的增大而减小, 而期望的偏差不会减小 (期望会越来越接近渐近极限), 故大样本情况下更倾向于使用完整模型, 而不是为避免多重共线性加剧遗漏变量。

6.2.11 函数形式误设

函数形式误设 (functional form misspecification) 指模型已包含了必要变量, 但变量的函数形式未正确设定, 如遗漏自变量的平方项、交互项, 或因变量水平值误设为对数等。

6.2.12 组间异质性

邹至庄 (Chow) 检验

用于检验组间回归方程的差异, 是 F 检验的一种特殊形式。设分组模型为:

$$y = \beta_{g,0} + \beta_{g,1}x_1 + \cdots + \beta_{g,k}x_k + u \quad (6.50)$$

其中 $g = 1, 2$ 。两方程可合写为包含 1 个虚拟变量、 k 个虚拟变量交互项的一个方程, 自由度为 $2k + 2$ 。考虑对假设 $H_0: \beta_{1,j} = \beta_{2,j}, j = 0, \dots, k$ 的 F 检验:

$$F = \frac{(\text{SSR}_P - \text{SSR}_1 - \text{SSR}_2)/(k + 1)}{(\text{SSR}_1 + \text{SSR}_2)/(n - 2k - 2)} \quad (6.51)$$

其中 SSR_P 是两组样本合并估计方程的残差平方和。

6.2.13 异方差性

异方差性不影响 OLS 估计量的无偏性, 但将导致 Gauss-Markov 定理不再成立; OLS 估计量的方差 (式 6.21) 有偏, 从而以此为基础的 t 统计量、F 统计量不再服从相应的理论分布, 且大样本也无法解决这一问题。

使用因变量的对数形式, 往往可缓解异方差性。

异方差稳健推断

在假定 (1)-(4) 下, $\text{Var}(\hat{\beta}_j)$ 的一个渐近有效的估计量为

$$\frac{\sum_{i=1}^n \hat{r}_{ij}^2 \hat{u}_i^2}{\text{SSR}_j^2} \quad (6.52)$$

其中 $\hat{u}_i$ 为原回归残差; $\hat{r}_{ij}$ 为 x_j 对所有其它自变量回归的残差, SSR_j^2 是这一回归的残差平方和. 其平方根称为异方差稳健的标准误, 可用于构造异方差稳健的 t 统计量.

异方差稳健的 F 统计量没有简单形式. 异方差稳健的 Lagrange 乘数检验如下: 设 $H_0: \beta_{k-q+1} = 0, \dots, \beta_k = 0$. 先估计受约束模型得到残差 $\tilde{u}$, 再将 $x_{k-q+1}, \dots, x_k$ 分别对 $x_1, \dots, x_{k-q}$ 回归, 得到残差 $\tilde{r}_1, \dots, \tilde{r}_q$. 之后, 将 1 对 $\tilde{r}_1 \tilde{u}, \dots, \tilde{r}_q \tilde{u}$ 过原点回归, 得到残差平方和 SSR_u . H_0 下 $n - \text{SSR}_u$ 渐近服从自由度为 q 的 χ^2 分布.

上述异方差稳健修正适用于未知形式的异方差, 但仅在大样本情况下适用.

Breusch-Pagan 异方差检验

在误差条件期望为 0 的假设下, $\text{Var}(u|\mathbf{x}) = E(u^2|\mathbf{x})$, 同方差假设意味着 $E(u^2|\mathbf{x}) = E(u^2) = \sigma^2$. 为检验异方差性, 可检验 u^2 的期望是否与一个或多个自变量相关.

先估计原模型得到残差 $\hat{u}$, 再将 $\hat{u}^2$ 对所有自变量 $x_1, \dots, x_k$ 回归 (基于对相关变量的推测, 也可将 $\hat{u}^2$ 对选定的部分自变量进行回归), 用 F 统计量或 Lagrange 乘数统计量检验此方程的整体显著性. 若 p 值足够小, 则拒绝同方差性的原假设.

White 异方差检验

先估计原模型得到残差 $\hat{u}$ 和拟合值 $\hat{y}$, 再将 $\hat{u}^2$ 对 $\hat{y}, \hat{y}^2$ 回归, 用 F 统计量或 Lagrange 乘数统计量检验此方程的整体显著性. 若 p 值足够小, 则拒绝同方差性的原假设.

事实上, $\hat{y}, \hat{y}^2$ 是所有自变量及其二次项、交叉项的线性组合. White 异方差检验的原始形式是在 Breusch-Pagan 异方差检验的基础上增加自变量的二次项、交叉项, 其出发点是 u^2 与所有自变量及其二次项、交叉项都不相关 (比同方差假定弱) 即可保证 OLS 标准误及相关检验统计量的渐近有效性. 但这一方式在变量较多时会损失大量自由度.

对于存在函数形式误设的情形, 同方差也会使上述检验给出存在异方差性的结论. 因此应当先确认函数形式, 再检验异方差性.

加权最小二乘估计

假定已知异方差的形式 $\text{Var}(u|\mathbf{x}) = \sigma^2 h(\mathbf{x})$, 记 $h_i = h(\mathbf{x}_i)$, 则方程

$$\frac{y_i}{\sqrt{h_i}} = \frac{\beta_0}{\sqrt{h_i}} + \beta_1 \frac{x_{i1}}{\sqrt{h_i}} + \cdots + \beta_k \frac{x_{ik}}{\sqrt{h_i}} + \frac{u_i}{\sqrt{h_i}} \quad (6.53)$$

满足同方差假定, 其 OLS 估计量是最优线性无偏估计量. 对上式的 OLS 估计等价于原方程的加权最小二乘 (Weighted Least Squares, WLS) 估计, 即最小化加权残差平方和 $\sum_{i=1}^n (y_i - \hat{y}_i)^2 / h_i$. 此时的 R^2 由加权残差平方和与加权总平方和 $\sum_{i=1}^n y_i^2 / h_i$ 计算. 与式6.36类似的方法可得 $\mathbf{x}_0$ 处预测误差的标准误为

$$\text{se}(\hat{e}_0) = \sqrt{(\text{se}(\hat{y}_0))^2 + \hat{\sigma}^2 h(\mathbf{x}_0)} \quad (6.54)$$

当每个观测是分组 (或地理区域) 的平均值时, 若个体观测具有相同的方差 σ^2 , 且组内各观测误差两两无关 (协方差为 0), 则分组观测的误差方差为 σ^2 / m_i (m_i 为该分组的个体数量), 此时有必要采用加权最小二乘法. 另一方面, 实际个体方程可能不满足同方差, 或组内误差存在相关, 此时可用 OLS 估计或 WLS 估计, 并报告异方差稳健的标准误.

错误设定 $h(\mathbf{x})$ 不影响 WLS 估计的无偏性和一致性 (事实上, 加权的误差与加权的自变量仍不相关), 但会导致 WLS 标准误和检验统计量不再可靠¹; 且理论上不一定比 OLS 更有效. 但实践中在异方差性较严重的情况下, WLS 标准误通常会比 OLS 更小.

若 OLS 和 WLS 估计值都显著, 但符号不同或值差异很大, 可能指示函数形式误设. 事实上, 零条件均值假设不满足可能导致 OLS、WLS 产生不同的偏误.

可行广义最小二乘估计

在异方差形式未知的情况下, 可行广义最小二乘估计 (Feasible Generalized Least Squares, FGLS) 根据数据估计函数 $h(\mathbf{x})$, 再用得到的方程计算 $\hat{h}_i$, 作为 WLS 权重. 一种形式是

$$h(\mathbf{x}) = \exp(\delta_0 + \delta_1 x_1 + \cdots + \delta_k x_k) \quad (6.55)$$

设 $u^2 = \sigma^2 \exp(\delta_0 + \delta_1 x_1 + \cdots + \delta_k x_k) v$, $E(v|\mathbf{x}) = 1$, 则有 $\ln u^2 = \alpha_0 + \delta_1 x_1 + \cdots + \delta_k x_k + e$, $E(e|\mathbf{x}) = 0$. 因此将 $\ln \hat{u}^2$ 对 $x_1, \dots, x_k$ 回归², 得到拟合值 $\hat{g}_i$, 则 $\hat{h}_i = \exp(\hat{g}_i)$. 另一种方式是 $\ln \hat{u}^2$ 对 $\hat{y}, \hat{y}^2$ 回归.

¹针对这一问题仍可以报告异方差稳健的标准误, 即模型 (6.53) OLS 估计的异方差稳健标准误

²该回归用于异方差检验时称为 Park 检验, 其缺陷是大样本下 F 统计量也不渐近服从 F 分布, 且需要 u 与 $\mathbf{x}$ 独立的强原假设. 而 FGLS 只需要 δ_j 的估计是一致的.

FGLS 估计量不是无偏的；但大样本下是一致的，且比 OLS 更渐近有效，相应检验统计量渐近服从 t 分布和 F 分布。

6.2.14 多重共线性

多重共线性 (multicollinearity) 指自变量之间高度相关（但不完全相关）。多重共线性不影响 OLS 估计量的无偏性，但会使其方差增大。

方差膨胀因子 (variance inflation factor, VIF) 定义为：

$$\text{VIF} = 1/(1 - R_j^2) \quad (6.56)$$

不应依据 R_j^2 或 VIF 值简单推断多重共线性的影响，因为 OLS 估计量的标准差还取决于误差方差和自变量的样本波动。此外若关注的变量与出现多重共线性的变量不相关，多重共线性不影响关注变量的方差。

6.2.15 关于实践的评注

为得到以标准差为单位度量的偏效应，可先将所有自变量和因变量进行 Z-score 标准化（减去均值，除以标准差），此时得到的系数 $\hat{b}_j$ 称为标准化系数，其与未标准化系数的关系是

$$\hat{b}_j = \frac{\hat{\sigma}_j}{\hat{\sigma}_y} \hat{\beta}_j \quad (6.57)$$

对取值为正的变量取对数，往往可以缓和偏态性和异方差性，且变量的取值范围变小，估计值受异常值影响更小。

较低的 R^2 并不意味着无法得到准确的偏效应估计。只要未加入模型的解释因素与自变量无关（假定 (4) 成立），就不影响 OLS 斜率估计量的无偏性；样本量的增大也可抵消误差方差对估计量方差的影响。但较低的 R^2 会给预测带来困难。

若关注 x_1 对 y 的影响，而这种影响通过中间变量 x_2 实现，就不应将 x_2 加入模型。如吸烟对家庭医疗支出的影响，不应将去医院次数作为解释变量。判定依据是“其它条件不变”是否有意义。但对于影响 y 又与 x_1 无关的自变量，总可以将其加入模型以减少估计量的方差。

当总体参数 θ 的估计量 $\hat{\theta}$ 的标准误公式难以得到，或不是估计量标准差的较好近似，可采用自助法 (bootstrap) 得到标准误。从观测中有放回地抽取等量样本，重复 m 次（通

常 500-1000 次), 重复估计流程得到 $\hat{\theta}^{(i)} (i = 1, \dots, m)$, $\hat{\theta}^{(i)}$ 的样本标准差称为 $\hat{\theta}$ 的自助法标准误。

定性信息可作为二值变量 (也称虚拟变量, binary/dummy variable) 加入模型; 对于 m 类分类变量 (分级等序数量类似处理), 一般选其中一个为基组 (base group), 加入 $m-1$ 个虚拟变量。自变量中的虚拟变量度量不同分组的截距差异; 虚拟变量与非虚拟变量的交互项度量不同分组的斜率差异。若因变量为二值变量, 称为线性概率模型 (linear probability model), 斜率系数度量了单位自变量增加导致的响应概率 $P(y = 1)$ 的变化, 其缺陷是可能得到小于 0 或大于 1 的概率拟合值, 且异方差性往往存在:

$$\text{Var}(y|\mathbf{x}) = p(\mathbf{x})(1 - p(\mathbf{x})) \quad (6.58)$$

其中 $p(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$ 为成功概率。其解决方法是使用异方差稳健标准误; 也可使用 FGLS, 此时 β_j 的 OLS 估计即给出方差函数, 但需要对权重 $\hat{h}_i = \hat{g}_i(1 - \hat{g}_i)$ 进行特殊处理 (如令小于等于 0 的 $\hat{g}_i$ 为 0.001, 大于等于 1 的 $\hat{g}_i$ 为 0.999)。

6.3 时间序列数据的线性回归模型

6.4 面板数据的线性回归模型

Chapter 7

贝叶斯数据分析

Bayesian Data Analysis

Andrew Gelman, John B. Carlin, Hal S. Stern, David B. Dunson, Aki Vehtari, Donald B. Rubin

7.1 贝叶斯推断

7.2 贝叶斯数据分析

7.3 贝叶斯计算

Chapter 8

为什么：关于因果关系的新科学

The Book of Why: The New Science of Cause and Effect

Judea Pearl, Dana Mackenzie

Chapter 9

机器学习

Machine Learning

周志华

9.1 前言

Chapter 10

图表示学习

Graph Representation Learning¹

William L. Hamilton

10.1 导论

图是描述和分析有关联 (交互) 实体的通用语言. 图机器学习的核心问题: 如何利用关系结构进行更好的预测?

任务分类:

- 节点级 (Node level): 节点分类 (当已知图中部分节点类别, 求其它节点类别时, 称半监督节点分类).
- 链接级 (Link level): 链接预测 (根据已知边预测其它节点对是否连边, 如知识图谱补全, 推荐系统中预测用户与物品的连接)
- 子图级 (Subgraph level): 社区探测
- 图级 (Graph level): 图分类 (如分子性质预测), 图生成, 图演化模拟

二部图的投影图 (folded/projected graph): 设两个顶点独立集 U, V , 对 U 的投影图节

¹本笔记亦主要参考 Jure Leskovec 图机器学习讲义 (Stanford CS224W, 2021)

点为 U , $u_1, u_2 \in U$ 连边当且仅当存在 $v \in V$, u_1, u_2 在二部图中都与 v 相连.

异质图 (heterogeneous graph): 区分不同类型节点和边. $G = (V, E, R, T)$, 边定义为 $(v_i, r_{ij}, v_j) \in E$, $r_{ij} \in R$ 是边类型, $T(v_i)$ 是节点类型. 在知识图谱中常用.

稀疏图 (sparse graph): 平均度远小于 $N - 1$. 大多数现实世界的网络都是稀疏图.

谱图论: 无向图的 Laplace 矩阵定义为 $L = D - A$, A, D 分别为邻接矩阵和度矩阵, 则 L 为对称半正定矩阵, 最小特征值为 0 ($L\mathbf{1} = D\mathbf{1} - A\mathbf{1} = 0$). 事实上, 对于任意列向量 $\mathbf{x}$,

$$\mathbf{x}^T L \mathbf{x} = \sum_{i=1}^N d_i x_i^2 - \sum_{i=1}^N \sum_{j=1}^N a_{ij} x_i x_j \quad (10.1)$$

$$= \frac{1}{2} \left(\sum_{i=1}^N d_i x_i^2 - 2 \sum_{i=1}^N \sum_{j=1}^N a_{ij} x_i x_j + \sum_{j=1}^N d_j x_j^2 \right) \quad (10.2)$$

$$= \frac{1}{2} \left(\sum_{i=1}^N \sum_{j \neq i} a_{ij} (x_i - x_j)^2 \right) \quad (10.3)$$

上述结论对矩阵 $I - D^{-1/2} A D^{-1/2}$ 仍然成立. 类似可以证明 $D + A$ 以及 $I + D^{-1/2} A D^{-1/2}$ 也是对称半正定的², 从而 $D^{-1/2} A D^{-1/2}$ (及其方幂) 的特征值均在 $[-1, 1]$, 且最大特征值为 1³.

10.2 特征提取

传统图机器学习方法需要人为定义节点、节点对、图的特征 (表示为向量) 用于训练.

10.2.1 节点特征

度、中心性、Pagerank 反映节点的重要性. 度、聚集系数、图元度向量描述节点所在局部的拓扑属性.

度 (degree).

中心性 (centrality): 衡量节点在图中的重要性.

²与 Laplacian 的情形相比, 差的平方变为和的平方, 若有自环还会多出 $2 \sum_{i=1}^N a_{ii} x_i^2$ 一项.

³GCN 中使用的版本取 $\tilde{A} = A + I$, 并基于此计算度矩阵 $\tilde{D}$ 和重归一化图拉普拉斯 (renormalized graph Laplacian) 矩阵 $\hat{L} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$. 注意到上述证明不限制图中的自环, 从而结论仍成立.

特征向量中心性 (eigenvector centrality) 满足

$$c_v = \frac{1}{\lambda} \sum_{u \in N(v)} c_u. \quad (10.4)$$

其中 A 为简单无向图的邻接矩阵. 上式化为 $\lambda \mathbf{c} = A\mathbf{c}$, 即 $\mathbf{c}$ 为 A 的特征向量. 一般取最大特征值对应特征向量⁴.

介中心性 (betweenness centrality): 对节点 v , 定义为一对节点所有最短路径中包含 v 的路径所占比例, 对所有不含 v 的节点对求和.

接近中心性 (closeness centrality): 对给定节点, 定义为该节点到其余节点最短路径长度之和的倒数.

聚集系数 (clustering coefficient): 对节点 v , 考虑其邻接节点 (设有 k_v 个) 的导出子图, 其边数与 $\binom{k_v}{2}$ 之比. 反映邻域连通程度.

图元度向量 (graphlet degree vector): 图元即较小的连通有根图. 令根节点与给定节点对应, 对每个图元统计与之同构的导出子图的数量⁵. 事实上度统计 K_2 的数量, 聚集系数统计 K_3 的数量.

Pagerank: 又称 Google 算法, 用链接分析 (link analysis) 度量有向图节点重要性的代表算法. 设节点 i 的重要性为 r_i , 出度为 d_i , 并令

$$r_j = \sum_{i \rightarrow j} \frac{r_i}{d_i}. \quad (10.5)$$

定义随机邻接矩阵 M , $M_{ji} = I[i \rightarrow j] \frac{1}{d_i}$, 则其列和为 1; 记重要性向量为 $\mathbf{r}$, 则有

$$\mathbf{r} = M\mathbf{r}. \quad (10.6)$$

考虑无偏随机游走, M 恰好为其转移概率矩阵, 归一化后的 $\mathbf{r}$ 为其平稳分布; $\mathbf{r}$ 同时为 M 特征值为 1 的特征向量.

利用乘方迭代法求解 $\mathbf{r}$: 可以从均匀分布出发通过乘转移矩阵至收敛得到. 特别地, 到达出度为 0 的节点时, 下一步以 $1/N$ 概率到达每个节点; 为处理闭集 (不指向集合外的顶点集合), 以 β 概率沿基本规则运动, 以 $1 - \beta$ 概率随机到访任一节点. β 通常取 0.8-0.9.

⁴无向连通图的邻接矩阵不可约. Perron-Frobenius 定理指出, 不可约非负矩阵最大特征值为正且代数重数为 1, 从而该特征向量在乘一个常数意义下唯一.

⁵如考虑节点数 2-5 的图元, 得到 73 维向量.

个性化 Pagerank (Personalized Pagerank) 度量各节点到特定节点集合 S 的邻近性, 随机游走时每步以 α 概率回到 S 中随机节点 (可指定不同概率). 当 S 中只含一个节点时, 称为带重启的随机游走 (random walk with restarts). 可用于在用户-商品二部图中确定某一 (些) 商品的相似商品 (此时每步游走事实上走两步, 从商品到商品).

10.2.2 节点对特征

距离: 网络最短距离.

局部邻域重叠: 公共邻居数;

Jaccard 指数:

$$\frac{|N(v_1) \cap N(v_2)|}{|N(v_1) \cup N(v_2)|} \quad (10.7)$$

Adamic-Adar 指数:

$$\sum_{u \in N(v_1) \cap N(v_2)} \frac{1}{\log k_u}. \quad (10.8)$$

局限性是如果没有公共邻居, 局部邻域重叠总是 0.

Katz 指数: 对简单无向图邻接矩阵乘方, 可得到一对节点间给定长度的路径数. 设 $\beta \in (0, 1)$ 为衰减因子, 节点 v_i, v_j 的 Katz 指数定义为

$$S_{ij} = \sum_{l=1}^{\infty} \beta^l A_{ij}^l. \quad (10.9)$$

矩阵形式为

$$S = \sum_{l=1}^{\infty} \beta^l A^l = (I - \beta A)^{-1} - I. \quad (10.10)$$

10.2.3 图特征

图核 (graph kernel) 给出两个图的相似度: $K(G, G') = \Phi(G)^T \Phi(G') \in \mathbb{R}$.

图元核 (graphlet kernel): 计数图中图元的个数, 这里的图元是无根图, 且不一定连通. $K(G, G') = h_G^T h_{G'}$, 其中 h_G 是 G 的图元计数向量 (用各分量之和归一化). 由于子图同构 (subgraph isomorphism) 是 NP 完全问题, 此方法计算复杂度过高.

Weisfeiler-Lehman 核: 采用颜色调整法 (color refinement), 初始所有节点赋相同颜色 $c_0(v)$; 每一步根据当前节点和邻接节点颜色 Hash 到一个新的颜色:

$$c_{k+1}(v) = \text{HASH}(\{c_k(v), \{c_k(u)\}_{u \in N(v)}\}), \quad (10.11)$$

从而 $c_k(v)$ 汇总了 v 的 k 跳邻域中的信息. Weisfeiler-Lehman 核的特征向量是 k 步后各颜色节点的计数向量, 该向量也作为图同构的判别依据, 计算复杂度为 $O(|E|)$.

10.3 图嵌入

10.3.1 节点表示

将图的每个节点映射到一个低维向量, 使向量的相似度反映对应节点在图中的相似度. 这一过程可取代人工设计的特征, 自动提取的表示向量可用于多种下游任务. 该向量可直接用于节点分类、聚类; 两个节点向量的连接、Hadamard 积、加和、距离等可用于链接预测.

从编码-解码的角度看, 编码器将一个节点映射为一个 d 维表示向量, 解码器从两个向量得到对应节点的相似度 (如向量内积). 简单的编码器可以仅做“查表”, 即学习一个 $d \times N$ 矩阵 Z , 每一列为对应节点的表示向量.

节点相似度的一种简单度量方式是其是否邻接, 即要求 $\mathbf{z}_v^T \mathbf{z}_u = A_{uv}$, A 为无向图的邻接矩阵; 亦即 $Z^T Z = A$. 由于 $d \ll N$, 上式难以严格成立, 考虑 $\min \|A - Z^T Z\|_2$. 可利用矩阵分解求解.

不考虑节点特征, **随机游走法**将两个节点的相似度定义为它们在一次图上的随机游走中共现的概率. 给定随机游走策略 R , 从节点 u 出发进行固定 (较短) 长度的随机游走, 访问节点的多重集记为 $N_R(u)$; 用 softmax 函数表示概率, 采用最大似然目标函数优化节点表示:

$$\begin{aligned} \mathcal{L} &= - \sum_{u \in V} \sum_{v \in N_R(u)} \log P(v | \mathbf{z}_u) \\ &= - \sum_{u \in V} \sum_{v \in N_R(u)} \log \frac{\exp(\mathbf{z}_u^T \mathbf{z}_v)}{\sum_{n \in V} \exp(\mathbf{z}_u^T \mathbf{z}_n)} \end{aligned} \quad (10.12)$$

利用负采样 (negative sampling), 上式每一项可近似为

$$\log \sigma(\mathbf{z}_u^T \mathbf{z}_v) - \sum_{i=1}^k \log \sigma(\mathbf{z}_u^T \mathbf{z}_{n_i}). \quad (10.13)$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数；负样本 $\{n_i\}_{i=1}^k$ 以节点度为概率随机抽样；理论上应取不在该游走上的节点，实际出于效率不加以限制； k 一般取 5-20（过少则估计不准确，过多则产生更大负样本偏差）。采用随机梯度下降优化，每一步随机取节点 u ，对 $-\sum_{v \in N_R(u)} \log P(v|\mathbf{z}_u)$ 求梯度，更新各表示向量。

DeepWalk 采用无偏随机游走。**node2vec** 采用有偏随机游走，以达到网络全局信息 (DFS) 与局部信息 (BFS) 的平衡：设 p, q 分别为返回 (return) 参数和进出 (in-out) 参数，若上一步从 v 走到 w ，则当前步骤以概率 $1/p$ （非归一化概率，下同）回到 v ；以概率 1 到达 v 的每个其它相邻（且与 w 相邻）的节点；以概率 $1/q$ 到达 v 的每个距离为 2（且与 w 相邻）的节点⁶。 p 低则接近于 BFS； q 低则接近于 DFS； $p = q = 1$ 的情形即为 DeepWalk。

矩阵分解法和随机游走法的局限性：(1) 加入新节点时，所有表示向量都要重新计算；(2) 不能表达结构相似性（更多关注邻近性）；(3) 不能纳入节点和边的特征。图神经网络、深度表示学习可以解决上述问题。

10.3.2 图（子图）表示

简单加和法：各节点表示向量求和（求平均）。

虚拟节点法：引入一个虚拟节点代替子图，利用节点表示方法得到子图表示。

匿名随机游走 (anonymous random walk)：随机游走序列不记录具体节点，只记录与序列中其它节点相同或相异（如 A-B-C-A-C 与 C-D-B-C-B 均为 12313）⁷。在图上进行若干次随机游走，用各匿名序列的概率分布作为图的表示；或以预测同一节点出发的相邻匿名序列为目标，同时学习每种匿名序列的表示和图的表示。

10.4 消息传递

社交网络中存在**相关性** (correlation) 或**依赖性** (dependency)：相近的节点具有相同类别标签。这一现象可从两个角度解释：同质相吸 (homophily) 即相似的个体更容易产生连接；社会影响 (influence) 使连接的个体趋向于同质。以此为理论基础，半监督节点分类

⁶对于带权图，非归一化概率可以再乘上边权。

⁷长度为 n 的匿名随机游走的数量是 Bell 数 (OEIS-A000110)，即将 n 个带标记元素划分成若干集合的方法数。

中节点类别不仅依赖于自身特征，也依赖于邻接节点的类别和特征。消息传递框架下的半监督节点分类任务有如下代表性方法：

关系分类 (Relational Classification): 利用节点连接关系迭代计算未知节点的类别概率。初始已知节点类别概率为 one-hot 向量，未知节点各类概率分别记为 $1/K$ (K 为类别数)；每轮未知节点类别概率向量更新为邻接节点类别概率向量的加权和（可按边权加权）。收敛后输出概率最大的类别。这一方法没有纳入节点特征，且无收敛性保证。

迭代分类 (Iterative Classification): 设节点 v 特征为 f_v ，邻域类别标签汇总为向量 z_v （可以包括各类别计数或占比、出现最多的类别、类别数等，有向图出边入边分别统计），在训练集上训练两个分类器 $\phi_1(f_v)$ 和 $\phi_2(f_v, z_v)$ ；在测试集上先用 ϕ_1 赋初始类别，每次迭代先更新所有 z_v 再用 ϕ_2 更新测试集的类别标签，直到收敛。只使用了邻接节点类别，且没有收敛性保证。

修正平滑法 (Correct & Smooth): 先将有标签节点作为训练集、验证集，训练基于节点特征预测各类别概率的基分类器；之后利用该分类器得到所有节点的类别概率。假设基分类器分类结果的误差具有正自相关，后处理阶段包括修正、平滑两个步骤。

设 $D = \text{diag}\{d_1, \dots, d_N\}$ 为度矩阵，定义归一化扩散矩阵 (normalized diffusion matrix) 为 $\tilde{A} = D^{-1/2}AD^{-1/2}$ ，其中 A 为邻接矩阵。

修正步骤: 设 E 为 $N \times K$ 训练误差矩阵，对于标记节点 i ， E_{ik} 为属于第 k 类的概率真值（0 或 1）与基分类器预测概率之差；对于非标记节点，对应行为 0。按下式更新误差若干次后，将误差的 s 倍加在基分类器预测概率上（ s 为超参数）；

$$E \leftarrow (1 - \alpha)E + \alpha \tilde{A}E. \quad (10.14)$$

平滑步骤: 设 Z 为 $N \times K$ 类别概率矩阵，对于标记节点 i ， Z_{ik} 为属于第 k 类的概率真值（0 或 1）；对于非标记节点， Z_{ik} 为修正步骤后的类别概率。按下式更新误差若干次后，对每个节点输出概率最大的类别⁸。

$$Z \leftarrow (1 - \alpha)Z + \alpha \tilde{A}Z. \quad (10.15)$$

⁸平滑步骤可能使每个节点类别概率和不再为 1。

10.5 图神经网络

图神经网络⁹提供了一种基于深度学习的节点（子图、图）嵌入方法，可与各种向量相似度函数结合。

朴素方法：将邻接矩阵中与特定节点对应的一行与其特征拼接，输入多层感知机。问题是与节点输入顺序有关；且不能用于不同节点数目的图。

图的表示应具有**置换不变性** (permutation invariance)；节点表示应具有**置换等变性** (permutation equivariance)。输入节点顺序重新排列的邻接矩阵和节点特征矩阵，输出图表示应相同，节点表示矩阵差一个置换（同一节点表示向量相同）。图神经网络由一系列置换不变、置换等变的层组成。

10.5.1 基本框架

聚合邻域信息以构建节点特征。节点 v 的 0 层表示是其特征本身； k 层表示由其 k 跳邻域信息聚合得到， k 跳邻域按消息传递方向构成计算图 (computation graph)。每层首先汇总邻域信息，再通过神经网络，所有节点共享每层的网络参数。以图卷积神经网络 (graph convolutional network, GCN) 为例，设节点 v 的 k 层表示为 $h_v^{(k)}$ ，

$$h_v^{(k+1)} = \sigma(W_k \sum_{u \in N(v)} \frac{h_u^{(k)}}{|N(v)|} + B_k h_v^{(k)}), k = 0, 1, \dots, K-1 \quad (10.16)$$

其中 W_k, B_k 是参数。令 $H^{(k)} = [h_1^{(k)}, \dots, h_N^{(k)}]^T$ ，有

$$H^{(k+1)} = \sigma(D^{-1} A H^{(k)} W_k^T + H^{(k)} B_k^T), k = 0, 1, \dots, K-1. \quad (10.17)$$

注意到基于邻接关系的消息传递和邻域聚合（池化）是置换等变的；由此定义的图神经网络可以迁移到新的节点和新的图。

10.5.2 设计空间

包括消息、聚合、层的堆叠、图增强、训练目标五个方面。

⁹2005 年 Gori 等人在论文 *A new model for learning in graph domains* 中就已经提出了图神经网络这一说法。

消息 (message): 对上一层节点表示的处理, 如乘权重矩阵。为保持节点自身的上一层表示, 通常采用与邻接节点不同的权重矩阵。此外为增强模型表达能力, 可以用多层感知机取代单一线性层。

$$m_u^{(l)} = \text{MSG}^{(l)}(h_u^{(l-1)}). \quad (10.18)$$

聚合 (aggregation): 对邻域消息的聚合操作, 如平均、求和、求最大。为保持节点自身的上一层表示, 通常先聚合邻接节点表示, 再与自身的表示求和或连接。

$$h_v^{(l)} = \text{CONCAT}(\text{AGG}(\{m_u^{(l)} | u \in N(v)\}), m_v^{(l)}). \quad (10.19)$$

消息和聚合构成了 GNN 的一层, 非线性激活函数可以加在消息或聚合后的表示上。层中还可加入 Batch normalization, Dropout (用在线性变换中)。

层的堆叠: GNN 层的顺序堆叠可能带来过平滑 (over-smoothing) 问题, 即不同节点的表示趋于同质。原因是随层数增大, 不同节点的多跳邻域出现大量重叠。因此 GNN 的层数不必过多, 应用中层数比所需感受野略大即可。若需要提升模型表达能力, 可在 GNN 层前后加入 MLP 层用于预处理和后处理; 或加入 skip connection (可理解为浅层网络和深度网络的集成)。

图增强: 包括图的特征增强和结构增强。

特征增强: 当节点没有特征, 需要添加 one-hot 的 index 向量或全为 1 的向量, 前者维数过高 ($O(|V|)$) 且无法迁移到新加入节点; 后者无法区分节点, 只能学习图的结构信息。传统图机器学习中的节点特征也可加入, 特别是 GNN 难以学习的特征, 如节点所在回路的长度。

结构增强: 当图过于稀疏时, 消息传递效率不高, 可加入虚拟边 (通常将二阶邻居连接), 或加入与所有节点连接的虚拟节点以加快消息传递。当图过于稠密时, 消息传递代价过高, 可在邻域中采样若干节点进行消息传递 (每层采样不同的邻接节点)。

10.5.3 训练流程

预测头 (prediction head) 将表示向量变换为所求输出。以 k 路预测为例 (k 类分类或 k 个变量回归), 节点预测可直接过线性层 (乘 $k \times d$ 矩阵); 边预测可连接后过线性层, 或训练 k 个矩阵 A_i , 以 $z_u^T A_i z_v$ 为第 i 维输出; 图预测需要对各节点表示向量进行聚合, 层次池化 (hierarchical pooling) 可增加聚合过程的区分度。

标签: 对于监督学习任务, 可直接利用标签数据进行训练; 对于非监督学习任务, 可利

用图的内部信息进行自监督学习 (self-supervised learning), 如预测节点特征, 两节点是否有链接等。

目标函数和评价指标: 与一般机器学习任务相同。

数据集划分: 包括 transductive 和 inductive 两种设置, 前者在训练、验证、测试时整个图都可见, 只对节点标签进行划分, 模型在同一个图的节点之间进行迁移; 后者去除训练、验证、测试集之间的边, 得到多个彼此不连通的子图, 模型可以在图之间迁移. 图级别的预测任务只能采用 inductive 方式.

链接预测任务需要将训练集中的边划分为消息边 (message link) 和监督边 (supervision link), 前者用于消息传递, 后者不输入到 GNN 中, 由 GNN 预测是否存在, 用于计算目标函数. 训练时已知训练消息边, 预测训练监督边; 验证时已知训练消息边、训练监督边, 预测验证边; 测试时已知训练消息边、训练监督边、验证边, 预测测试边。

10.5.4 常见模型

GraphSAGE:

$$h_v^{(l)} = \sigma(W_l \cdot \text{CONCAT}(h_v^{(l-1)}, \text{AGG}(\{h_u^{(l-1)} | u \in N(v)\}))). \quad (10.20)$$

其中邻域聚合 AGG 可以是取平均; 先过 MLP 再平均 (求最大); 邻接节点随机重排后过 LSTM. 对每层得到的表示使用 l_2 归一化。

图注意力网络 (Graph Attention Network, GAT):

$$h_v^{(l)} = \sigma\left(\sum_{u \in N(v)} \alpha_{vu} W_l h_u^{(l-1)}\right). \quad (10.21)$$

其中 α_{vu} 代表 u 对 v 的重要性。训练一个注意力函数 a , 使得

$$e_{vu} = a(W_l h_v^{(l-1)}, W_l h_u^{(l-1)}), \quad (10.22)$$

e_{vu} 归一化得到 a_{vu} , 使 $\sum_{u \in N(v)} a_{vu} = 1$. a 的形式可以自由设定 (如输入拼接消息的单隐层神经网络), 其参数随权重矩阵 W 一起训练¹⁰. 使用多头注意力 (multi-head attention) 时, 同时训练多个注意力函数 a_i , 使用每个注意力函数分别计算表示向量 $h_v^{(l)}[i]$, 最后将表示向量聚合。

¹⁰若图中 (u, v) 边有属性信息 r_{vu} , 也可以在函数 a 中加入参数 $V_l r_{vu}$, 其中 V_l 为可训练参数。参见 Liu et al., Learning Geo-Contextual Embeddings for Commuting Flow Prediction, AAAI 2020.

与其它神经网络的关系：CNN 可以视为邻域节点数量和排序固定的 GNN， $n \times n$ 卷积对应 n^2 个不同图卷积参数矩阵；Transformer 可以视为全连接的单词图 (word graph) 上的 GNN.

10.6 图生成模型

10.7 其它主题

Chapter 11

科学之路：人、机器与未来

Quand la machine apprend

杨立昆 (*Yann LeCun*)

信息的自由流动就是 (科学技术) 进步的动力。——杨立昆

学术生涯： 作者在学生时代开始研究多层神经网络的训练，提出了分层学习机 (Hierarchical Learning Machine, HLM)。HLM 仍采用输出为 ± 1 的二值神经元，但其可反向传播训练参数的思想与 Rumelhart, Hinton 的工作类似，属于梯度反向传播的“某种奇怪版本”。

作者在 Hinton 实验室、贝尔实验室工作期间发明了卷积神经网络，用于邮政编码以及手写支票的识别。后者受到福岛邦彦研究的启发，他提出的“认知机” (Cognitron) 已具备接近 CNN 的结构，但只能训练最后一层参数。神经生物学家 Hubel 和 Wiesel 对视觉系统的研究启发了福岛邦彦和作者的工作。

语言学界对“人类的语言机制是否是先天的”有争论。Noam Chomsky 认为大脑生来具有让人们学习说话的结构；而 Jean Piaget 认为这一结构也是后天习得的，智力是人与外界交流学习的结果，这启发了作者对机器学习的思考。

作者从未怀疑过神经网络的有效性：人类智能如此复杂，必须建立一个具有自我学习能力和经验学习能力的自组织才能复制它。作者坚信深度学习就是人工智能的未来。

关于学术研究： “我贪婪地阅读，我熟知前人的所有工作。在探索之路上我们并非孤身一人，时机到来之时，那些已经存在但尚未提出的理念会一个接一个地涌入许多人的头

脑中。”

深度学习的应用：社交媒体网站上不良内容的识别（尚不完善，如机器无法理解语言中的隐含意思或反讽、难以区分色情内容和严肃艺术）、用户是否点击广告的预测；人脸识别、图片搜索用到基于嵌入向量的相似度度量；根据说话者的嵌入向量，语音克隆技术将单词（音素）序列转换为说话者的语音。

人工智能的现状：深度神经网络运作复杂、难以进行数学分析，且无法进行逻辑推理。机器智能高度专业化、没有常识和意识。人脑比机器更全面、更具可塑性。相同运算能力的 GPU 与人脑相比，功率大致高 6 个数量级。

“人工智能的世界日新月异，不断地挑战新的极限。当一个关键问题被攻破后，便会进军新的领域，旧的领域便不再属于人工智能的范畴，而是会作为惯用工具存在。”

前景与挑战：监督学习依赖大量带标签数据，且会受对抗攻击影响；强化学习不需要给系统提供正确答案，只需要评估系统给出答案的质量，但即使对于简单任务也需要大量交互，用于现实任务（如自动驾驶）需要精确的模拟器。作者认为动物和人类学习的主要方式——自监督学习才是智能的本质¹。人类主要通过观察学习世界运行的规律，并建立预测模型（知晓行为的后果）；不具备此种预测能力的强化学习系统只能进行大量试错。

机器应当能像人类和动物一样有效地学习，通过自监督学习获得世界模型，并积累起足够多的世界知识以产生某些常识。作者设想的“带预测模型的自主智能体”包括感知模块、世界模型（根据状态、动作和可能的隐变量预测下一状态）、评价函数²；且可以衡量预测的不确定性，确保模型在可靠区域使用。

作者认为不必苛求人工智能系统的可解释性，人类往往将在测试中表现出足够可靠性的技术投入使用，即使未深入了解其运行机制；但应用于司法、医疗等对个人有重大影响的决策时需要给出合理的解释。

物理学理论常常归结为公式和少量自由参数，而其它一些自然科学和社会科学中的复杂现象无法如此简化。当元素相同且细节无关紧要时，可采用热力学和统计物理的方法；而当元素不同、相互作用复杂、细节重要时，只能建立唯象模型。目前的机器学习仅限于此；基于人工智能的因果推理是一个前沿方向。

作者认为人类的大脑是可以计算的生化机器，原则上可以通过计算机再现，尽管有反对

¹当“被遮盖的部分”无法确定地预测时，单词等简单输出的不确定性可用概率分布向量表示，而图像等高维输出可用带隐变量的模型（如 Conditional GAN）建模。

²这里的评价函数是机器自己计算的，不同于强化学习中外界给出的奖惩。

者认为人类还不够了解生物、物理、量子等系统如何在人体内结合以使大脑发挥作用。

《让历史告诉未来》（黄铁军序）：智能是系统通过获取和加工信息获得的能力，环境是智能的真正来源。大数据是当前智能系统成功的根本因素（小样本方法也是以大数据预训练为前提），计算资源和学习算法主要影响效率。更全面的环境模型（数字孪生）可能哺育更强的人工智能。

人工智能早期由符号主义主导，但符号描述和逻辑推理不是智能的基础，只是一种表现；人类存在不必或不能符号化的“潜智能”。我更倾向于认为符号与亚符号并列，也存在不借助符号难以精确表达的形式化知识。机器学习使人工智能的重心从人工赋予智能转移到机器自行习得智能。连接主义和行为主义发展出的深度学习和强化学习是当今人工智能的两大主要方法。

不同于杨立昆的观点，作者认为强化学习是比自监督学习更基本的学习方法；人类自监督学习的能力依赖大脑，机器也需要相应的可塑载体（如深度神经网络）；而强化学习对载体的要求更低，对温度敏感的有机大分子就能进行强化学习。“结构决定功能”，相比于学习方法，从事学习的机器载体同样重要。自然智能是大自然训练优化的结果，可探索结构逼近生物神经网络的类脑智能（神经形态计算）。

Chapter 12

Nature Methods 方法简介

12.1 Association, correlation and causation

“Correlation implies association, but not causation. Causation implies association, but not correlation.”

关联 (Association) 与依赖 (Dependence) 同义，指变量之间不独立。有因果关系一定不独立，但不一定表现出相关性 (如 $y = x^2$)。相关性是关联的一种，不能推出因果是由于可能存在混淆变量 (与自变量、因变量都相关)。

Pearson 相关系数度量线性相关关系，Spearman 相关系数度量增减趋势。后者也可以用在间隔量、比率量，即用排名做 *Pearson* 相关，这比原始数据的 *Pearson* 相关更宽松。Pearson 相关系数的统计显著性用 *t* 分布做检验；也可以利用方差分析得出自变量解释了因变量多大部分的变异。

12.2 Quantile regression

线性回归关注因变量的均值，而分位数回归 (QR) 可刻画因变量极端值与自变量的关系。QR 不依赖对因变量分布的假设，适用于因变量偏态分布或存在异方差性的情形。QR 的优化目标为

$$\min_{\beta} (Y_i - X_i\beta)(\tau - I[Y_i < X_i\beta]) \quad (12.1)$$

其中 τ 为关注的分位数。 $\tau = 0.5$ 时上式等价于 L1 loss。通常用数值优化方法求解。

识别是否需要用 QR 代替均值回归：（1）比较均值回归的预测区间和相应 QR 结果，差异指示均值回归假设不满足（如异方差性，偏态分布等）；（2）计算不同分位数下的 QR 回归系数，差异指示需要使用 QR。

对于较为极端的分位数（如 1%, 99%），通常需要较大的样本量才能准确估计。线性 QR 可能出现分位数交叉 (quantile crossing)，即拟合模型后不同分位数的回归线交叉，指示模型误设（如非线性关系）。联合 QR (Joint QR) 解决了这一问题。

Part II

物质科学

Chapter 13

皇帝新脑

The Emperor's New Mind

Roger Penrose

13.1 机器智能、算法与意识

什么是思维？什么是精神？它们是否依赖于生物结构？电子设备能否思维？

我们无法逻辑地掌握“精神”的概念，源于对基本物理定律缺乏理解。物理理论不仅在亚原子粒子、大爆炸、相对论与量子理论统一等问题上有空白，与人类思维和意识运行的水平上也存在无知。

图灵测试：行为主义观点，即如果电脑的表现和一个人在思维时的表现不能区分，则认为它在思维。具体指以与人类不能区别的方式回答我们关心的问题。对电脑而言，真正困难的问题或许是基于常识、需要理解的问题。

行为主义还宣称 AI 可以模拟快乐与痛苦。假设机器的行为尽可能增加某一正值，避免其负值，可以定义正值为快乐、负值为痛苦。作者指出缩手等条件反射或许比人对苦乐的反应更接近机器的行为。

强人工智能：认为精神活动不过是一种算法，思维、感情、智慧、意识仅仅是头脑所执行算法的特征。反之，如果找到了这样的算法，在机器上运行就可以使机器具有精神。认为只有算法的逻辑结构与其精神状态有关，执行方式与之无关。算法的抽象存在与物

理实现完全分离，这导致二元论的立场。

所有现代通用电脑都是相互等价的通用图灵机，这是强人工智能哲学认为硬件相对不重要的依据。但作者认为人的思维可能引起特别的物理现象，且其效应无法用电脑精密地模仿，即“头脑即为电脑”的假设不成立。

Searle 中文屋子：被恰当编程、根据输入文本正确回答问题的电脑仍不具备“理解”有关的精神属性。假设文本用中文而非英文，一个不懂中文的操作员同样可按电脑程序执行运算，得出正确结果。作者认为论证是有力的，不严格之处在于可能存在与一个人执行算法有关的离体的“理解”，并反射到他的意识。

Hofstadter 假想一本包含 Einstein 头脑全部描述的书，可以像 Einstein 本人一样回答问题（根据图灵测试，它就是 Einstein）。强人工智能将认为其具有思维、理解和知觉。作者质疑，书何以知觉自己被提问？是否当书中算法的激活或改变（包括其存储空间的改变）时其知觉才被唤起？

一个人的个性和自我认知与其组成成分无关（同种基本粒子是全同的），而是体现在这些成分的排列模式。强人工智能进一步认为，这一排列模式的信息被无损地翻译为另一种形式时，人的个性保持不变，其意识和知觉继续存留。这引出科幻中“超距传送”的设想，即以电磁信号束发送人的完整信息，在目的地重新装配。这是旅行还是复制？如果出发地的人不销毁，知觉会同时存在两个地方吗？

Church-Turing 论题认为，图灵机（或 λ -演算等等价概念）定义了算法，即我们认为的机械的逻辑或数学运算。利用 Cantor 对角线法可以证明停机问题（ $HALT_{TM}$ ）不是可判定的，且可以找到一个算法，对任何可识别 $HALT_{TM}$ 的算法（接受停机实例，对不停机实例可能拒绝或不停机），给出一个不停机实例使之不停机。可计算性决定了图灵机计算能力的理论边界。那么物理系统（包括人脑）的计算能力与图灵机相比如何？可计算数/问题是否足以描述实在的物理对象（可计算数只有可数多）？

13.2 数学、实在与证明

实数系统与物理概念并非在所有尺度下都一致。如实数的值可以无限小，但距离和时间间隔不一定（量子引力尺度下通常的距离概念或不再有意义）。

数学上的发明更适合称为“发现”，它们不仅是头脑的创造物，而是可以具有某种抽象的绝对性和实在性，这一观点被称为“数学柏拉图主义”。例如 Mandelbrot 集的发现，以及复数的引入（尽管引进负数的平方根似乎是一种工具式的发明，但从中获取的远比最

初设计的多得多)。进一步地, 作者认为数学真理的绝对性和数学概念的柏拉图存在性在本质上等同。

数学的**形式主义**主张抽去数学陈述中的意义, 只将其视为形式化的符号串。哥德尔不完全性定理给了形式主义毁灭性的打击, 即一个相容的形式系统必存在不能证明的真命题。连续统假设在 ZF 公理体系下不可判定, 形式主义者无法讨论其真伪。

哥德尔定理的证明思路: 形式数学系统定义了有限的符号表 (包括数字、变量、运算符、逻辑符号、量词等), 故其符号串可数。特别地, 考虑含单个自然数变量的命题函数的序列 $P_n(w)$ 和证明的序列 Π_n 。命题 $\neg \exists x [\Pi_x \text{ 证明 } P_w(w)]$ 同样可用系统编码, 设其为 $P_k(w)$ 。故我们有

$$\neg \exists x [\Pi_x \text{ 证明 } P_k(k)] = P_k(k)$$

若 $P_k(k)$ 为假, 则其存在证明, 矛盾。故 $P_k(k)$ 为真, 且不存在证明。

可以将哥德尔命题 $P_k(k)$ 作为公理加入系统, 系统又会出现新的哥德尔命题。得出哥德尔命题为真需要形式系统之外的直觉。事实上数学家对定理的证明也需要超越形式系统步骤的洞察。哥德尔定理表明仅在建立形式系统时考虑符号的实际意义是不够的; 数学真理的概念不能包容在形式主义框架之中。

此外, 停机问题不可解性与哥德尔不完全性有对应: 形式系统中验证一个符号串是否证明给定命题是可计算的。对于完备的系统, 由于所有证明可列, 可依序检查所有证明的结果, 从而存在可以判定任何命题真假的图灵机 (命题本身及其否定, 恰有一个是某个证明的结论)。可识别 $HALT_{TM}$ 的算法无法识别的实例与哥德尔命题有对应, 体现了洞察对形式运算的超越。

形式系统中可证明的命题是递归可枚举集; 但其补集不是 (考虑命题 $S(n)$: 编号为 n 的图灵机对输入 n 停机, 若不然, 所有假的 $S(n)$ 是递归可枚举的, 这与停机问题不可解矛盾)。由于可证伪的命题也是递归可枚举的, 表明有命题既不可证明有不可证伪。真命题和假命题的集合都不是递归可枚举的 (同样由于假的 $S(n)$ 不是递归可枚举的)。

直觉主义: 以拓扑学家 Luitzen E.J. Brouwer 为代表, 只接受具有确定构造的数学对象的存在性, 认为没有实在构造的存在没有意义。不接受排中律 ($\neg(\neg P) \iff P$) 和反证法 (如假设某对象不存在, 推出谬误, 以此证明存在)。这一观点导致数学论证中有力工具的丧失。事实上基于图灵可计算性研究可构造性, 可将其与存在性分开讨论。

对于非递归集而言, 不存在判定元素是否属于此集合的算法。Mandelbrot 集的补集是递归可枚举的, 作者猜想其本身不是¹。此外, 丢番图方程组解的存在性是不可判定的; 半

¹原则上递归集、递归可枚举集只能用于可数集, 这里的讨论只考虑单个点的判定, 而且可能需要排除

群的字问题不仅对于一般等价表不可判定，对特定等价表也可能是不可判定的；一组多边形是否能镶嵌平面也是不可判定的²。

13.3 经典和量子物理

作者认为现有对物理的理解不足以描述大脑的运行。牛顿力学和相对论构成的经典物理是决定性的，而量子力学是非决定性的理论。作者认为量子现象对大脑运行是重要的。

边界（考虑单位圆盘，判定点在圆盘内/外都是可计算的，但由于判定两个可计算数相等是不可计算的，判定点是否在单位圆盘的边界上也是不可计算的）。

²作者给出了两种多边形只能非周期镶嵌平面的例子，即 Penrose 铺陈。

Chapter 14

规模：复杂世界的简单法则

Scale: The Universal Law of Growth, Innovation, Sustainability, and the Pace of Life in Organisms, Cities, Economies and Companies

Geoffrey West

14.1 规模法则

规模缩放法则：特定量与规模的关系，即系统在规模变化时的响应，也称标度律（scaling law）。常见的关系包括对数线性（幂律）、常值。

设 $y = kx^\alpha$ ，则 $\ln y = \alpha \ln x + \ln k$ ，故幂律指数即取对数回归后的斜率。当 $\alpha > 1$ ，称超线性规模缩放，造成规模收益递增，意味着开放式增长； $\alpha < 1$ ，称亚线性规模缩放，造成规模经济，意味着受限生长、有限寿命。

规模法则是支撑不同系统的网络结构优化的结果，源自自然选择、适者生存内在的连续反馈机制。

规模缩放的实例：

- Galileo 指出物体不能无限按比例扩大，原因是当尺寸增大 k 倍时，横截面的压强也增大 k 倍，无法支撑；除非改变物质组成或结构设计。这意味着 Godzilla 等虚

构形象不会真实存在。实证数据表明，举重冠军成绩与体重呈指数为 $2/3$ 的幂律，与这一论证一致。

- 里氏震级每相差 2 级，能量相差 1000 倍。
- 随体重线性变化的药物剂量是值得怀疑的；如果药物的吸收是表面积（截面积）起作用，应当按 $2/3$ 次幂律变化。
- 体重与身高平方之比的 BMI 是缺乏概念基础的。这一指数的提出者是 Adolphe Quetelet，其提出了“平均人”概念，研究人类的平均生理和社会指标及其分布。
- 英国工程师 Isambard K. Brunel 认为大轮船比小轮船高效，建造“大东方号”效果不佳。Froude 发现 $\frac{v^2}{lg}$ 相同时（被称为 Froude 数， v 为行驶速度， l 为船长），船只动力学行为一致。由于大多数规模缩放是非线性的，直接按比例缩放的模型实验常常不具有可靠性。

复杂系统的特征：具备个体组分不具备的集体特性（称为涌现行为），无法简单地从个体行为预测，“整体大于局部之和”；自组织行为；对外部条件的适应性（韧性）；混沌和临界现象等。

14.2 生命科学

生物的标度律：Kleiber 定律指出，动物代谢率与体重呈现 $3/4$ 次幂规模缩放。动物的寿命随体重 $1/4$ 次幂增长；但一生的心跳总次数大致为常值（15 亿次；人突破到 25 亿次），与体重无关。主动脉压大致为常值。呼吸频率与心率成正比（约 4 次心跳对应一次呼吸）。此外，众多标度律的幂次为 $1/4$ 的倍数（ $1/4$ 次幂规模法则）。

异速生长（allometric）：身形随体型增长发生变化，但变化的比例各不相同，如动物四肢的长度增长比半径慢。

解释 $1/4$ 次幂异速生长规模法则：关注网络特性。假设网络满足空间填充、终端单元恒定性（如哺乳动物有相同直径的毛细血管）、性能优化（耗能最小化）三个特征。循环系统遵循等面积分支，从而脉动区域连续血管半径按 $\sqrt{2}$ 倍率增大。粘滞区域按 $\sqrt[3]{2}$ 倍率增大。连续血管长度按 $\sqrt{2}$ 倍增大。循环网络体积正比于身体体积。综合以上得出 $1/4$ 次幂规模法则。4 对应四个维度，多出的一个源于网络的分形特征。

哺乳动物的体型极限：血液从主动脉到毛细血管流动经历脉动、非脉动两个不同模式，

而不同体型哺乳动物非脉动血管层级数大致相同。后者更为低效，导致代谢率的线性规模缩放。循环系统至少要包含 1 级脉动分支，这给出体重下限为数克（鼯鼠）。毛细血管间的平均距离遵循 $1/12$ 次规模缩放，过大使细胞缺氧（氧气扩散的最大距离称为最大 Krogh 半径），这给出体重上限为 100 吨（最大的蓝鲸）。

生物的生长：代谢率的 $3/4$ 次规模增长与现有细胞能量需求的线性增长存在 $1/4$ 次的差值，这导致生长的最终停止。不同动物的无量纲质量与无量纲时间遵循类似的增长曲线，这可以由上述理论预测。

寿命：全球平均寿命从 1870 年的 30 岁增长到 2011 年的 70 岁，主要原因是医疗卫生的发展，以及婴幼儿死亡率的大幅下降。已知的最长寿命为 122 岁。

解释寿命随体重 $1/4$ 次幂增长：假定死亡的临界条件是受损细胞达到特定比例，而受损细胞数为时间和单位时间受损事件数之积，后者与终端单元数成正比。这推出寿命正比于细胞总数与终端单元数（幂次为 $3/4$ ）之比，幂次为 $1/4$ 。

14.3 城市科学

指数增长的特征是增长速度与现有量成正比、倍增时间恒定。当今世界人口倍增时间在缩短，事实上呈现超指数增长。人身体每天消耗的能量相当于 100W 的功率，而事实上现代生活消耗的能量相当于 3000W。

马尔萨斯主义认为，人口指数增长，而资源供应只能线性增长，这导致灾难性的崩溃。创新乐观主义认为，过去 200 年的高速增长会因人类的天才、创新能力而持续。

城市：从物理层面，城市包含道路、电网等网络系统，存在物质、能量和人的流动；从人的层面，城市中的人给城市带来了活力、灵魂和精神，城市被认为是促进社会互动、人类合作和创新的天才机制。

到 2006 年，世界城市人口已经过半。

Jane Jacobs 提倡“城市即人”，从公民集体生活的角度看待城市，指出城市规划应以人为主导，而非道路和建筑物。她以保护曼哈顿下城著名，认为城市重建或导致传统社区的摧毁。Ebenezer Howard 提出“花园城市”概念，追求城镇和乡村的融合，成为郊区的样板。规划的城市往往充满疏离感、缺少流行和文化活动、缺乏社区精神，但城市具有韧性，“城市会进化，最终发展出灵魂”。

传统的城市理论往往是定性的重点研究，依赖叙事和直觉感知，作者追求定量化、可预

测的城市理论，关注城市的共性。

城市结构：Walter Christaller 提出“中心地理论”，将城市体系描述为六边形晶体结构。事实上城市更像具有分形和褶皱的有机体，其边界线长具有类似于海岸线的分形维数，其增长模式类似于细菌菌落。Michael Batty 对城市分形维数进行了广泛研究。其研究侧重社会科学、地理学、城市规划的现象学传统，不同于本书作者的物理学传统。Zipf 定律指出城市位序反比于人口规模，即城市人口服从重尾的幂律分布。

城市标度律：基础设施指标（道路、管线长度，加油站数量）呈幂律指数 0.85 的亚线性规模增长，意味着大城市资源节约、污染减少；社会经济指标（总工资、GDP、专利数、餐厅数、犯罪数、病例数）呈幂律指数 1.15 的超线性规模增长，意味着大城市具有更多的财富、机遇、文娱设施，以及更多的疾病和犯罪。此种关系对同一国家的城市成立，意味着从指标上看，同一国家不同规模的城市是非线性缩放的版本。相对于生物，城市标度律拟合准确程度弱于生物，可能与城市的历史、文化、地理因素有关。

城市排名不应以人均指标为准（隐含线性规模缩放），而应以相比理论预测值的偏移量为准。

城市标度律的解释：基础设施网络、社会网络的结构和动力学；资源、能源、信息在其中流动的特性。这两种网络与生物网络有类似的特点：基础设施供应和社会活动定义了城市的边界；房屋和人分别是其不变终端；成本、能源利用的近似最小化（由于历史原因、私人原因可能迟滞）。

两种网络都是自相似分形网络。基础设施网络是分级网络，从一地出发的交通流量体现分形特征。社会网络是“六度分隔”的小世界网络，存在高度互联的模块化小集团；从个体出发，社会网络存在层次结构，相邻层人数具有恒定的比值（Dunbar 定律；普通人保持联系的社交网络成员最大数量为 150，这称为 Dunbar 数）。

社会经济指标与人与人之间的连接（互动）成比例。若全连接，幂指数应为 2；基础设施、能量利用限制了连接，故实际指数小于 2，且前者亚线性缩放的程度与社会经济指标超线性缩放的程度相当。联系生物的 $1/4$ 规模缩放法则对应四个维度，Luís Bettencourt 认为 15% 是 $1/6$ 的近似值。

生活节奏的加快：基础设施网络从终端单元起流量逐渐增大，导致亚线性规模缩放和规模经济。与之相反，社会网络从终端起互动、信息交流逐渐减少；社会网络的正反馈机制带来互动、创意、财富的超线性规模增长；与生物生存时间相反，社会经济活动时间根据 15% 规模法则压缩。

实证：步行速度随城市人口数增加而加快，幂律指数为 1.1。人均电话联系总次数（反映

人与人互动次数) 呈现接近 1.15 的幂律; 人均通话总时长也随人口数系统性增加。

Marchetti's constant: 源于 Y. Zahavi 对每日通勤时间恒定性的观察。每日出行的总时长约为 1 小时, 从而“步行城市”边长约 5km, 汽车都市圈边长约 40km。这决定了城市规模的上限。

城市人群移动的频率分布: 以一定频率访问某一地点的人数与距离成平方反比; 距离一定, 访问某一地点的人数与访问频率成平方反比。 $\rho \sim (rf)^{-2}$

经济多样性: 实证表明企业数量和雇员总数与人口规模呈线性关系; 企业的多样性 (类型数) 随人口规模以对数缓慢增长。不同类型企业数量在不同城市呈现一致的位序-规模曲线, 其理论解释是偏好依附 (Yule-Simon 过程) 的正反馈机制, 即企业类型越常见, 新增企业属于此类型的概率就越大。随着城市规模增大, 超线性增长的企业类型 (信息、服务业) 占比上升, 亚线性增长的企业类型 (农业、采矿业) 占比下降。

城市增长: 城市总体代谢的社会经济来源 (如财富创造和创新) 遵循超线性规模法则, 而需求量线性增长, 这意味着城市遵循与生物体相反的开放式增长。

14.4 公司科学

理解公司的传统机制: 交易成本 (优化原则, 成本最小化、利润最大化); 组织架构 (公司内的网络结构); 市场竞争 (进化压力、选择过程)。

基于主体建模 (Agent-based modelling): 假设主体之间相互作用的简单法则, 模拟时序演化。将相互依存的部分解构为半独立子系统会带来误导; 主体行为、决策的规则定义具有主观性; 主体被视为独特的实体, 难以揭示一般性法则。

公司的标度律: 尽管相较于生物、城市, 数据围绕理论曲线的波动更大, 其平均水平仍具有幂律模式: 总利润、总资产、净收入等随雇员人数亚线性增长。总收入 (销售额) 呈线性规模增长, 这意味着随时间的指数增长 (?)

公司的增长: 公司的代谢率 (销售额) 线性增长; 支出开始时亚线性变化, 随规模扩大转为近似线性变化; 故增长曲线开始较快, 之后增速放缓。

公司的消亡: 公司的寿命呈现指数分布 (恒定死亡率), 不论所处的行业或消亡的原因 (破产清算、并购)。美国上市公司具有 10.5 年的半衰期。极端长寿公司 (200 年以上) 的数量超出理论预期, 它们大多数规模不大, 持续为小众客户群生产高质量产品。

14.5 结论

城市的超线性规模增长意味着随时间的超指数增长，在有限时间内达到无穷大；到达这一奇点时，资源和能量供应的不足将导致停滞和崩溃。对策是在奇点之前重新设定增长参数，这通过创新带来的范式转移实现，但需要范式转移的速度越来越快，即连续创新的间隔不断缩短。呼吁发展“可持续性的大一统理论”。

复杂适应系统的动力学和结构难以用一小部分等式编码。即使个体成分间相互作用的动力学已知，复杂适应系统的细节仍难以预料。本书介绍的标度理论可以理解和预测系统的粗粒度行为。基本粒子及其相互作用的大统一理论不能解释并预测所有事物，因此需要发展“复杂性的大一统理论”。

大数据时代的到来不意味着数据模式挖掘可以节约一切问题，不再需要理解事物的基本原理和因果关系。作者认为，如果没有对事物背后机制的基本思考，很容易误入歧途，浪费大量算力。

Chapter 15

随棕鸟飞行：复杂系统的奇境

In un volo di storni: Le meraviglie dei sistemi complessi

Giorgio Parisi

与棕鸟齐飞：遵循简单规律的个体组成的群体可能具有复杂的集体行为。棕鸟群能快速变化阵型，既不相撞，又不散开。通过对鸟群轨迹的三维重建，作者团队发现鸟阵边缘的密度比中心更高，可能是为了避免落单的鸟被游隼袭击；鸟与前后同伴的距离远于左右同伴。更重要的是，鸟群中的相互作用取决于最邻近个体间的联系，而非距离远近；鸟群转弯时每只鸟正是依靠邻近鸟的位置进行自我调节。

“在物理学和数学领域……科学研究就像诗歌创作一样，没有任何迹象表明创作过程的艰辛，以及与之相伴的怀疑与彷徨。”

相变与自旋玻璃：相变是微观粒子的一种集体行为。一级相变在系统接近临界点时没有预兆，且需要潜热，如冰融化成水。二级相变在接近临界温度时连续发生，如磁铁受热失去磁性。重整化群用于处理二级相变，其变换尺度的思想类似于降采样。自旋玻璃是一种金属合金，高温下表现与通常磁性系统一致，低于临界温度则变化缓慢，行为类似于玻璃。自旋玻璃模型可视为 Ising 模型的扩展，后者相邻自旋趋向一致，前者一部分相邻自旋趋向相反。序参量指系统状态转换中的特征参数（如铁磁相变中的磁化强度）。作者发现需要用函数（无穷多个数）作为序参量，其物理意义是系统可能同时处于无数个相。

直觉、隐喻和无意识推理：应当区分隐喻在科学研究中的两者用途：作为启发性的工具

或是论证的基础；后者是有害的，如将观点照搬到不适用的领域。

物理学家将具体现象翻译为数学语言。有时两个不同的物理系统可以归于同一个数学结构，这种情况下它们的结论可以迁移。

无意识思维（“酝酿”）在科学问题的解决中具有重要作用。借助语言将思维形式化是重要的，但非语言的思维出现在语言的思维之前。

达尔文进化论和量子力学都涉及“选择”，但“在自然进化中，新的可能是随机出现的，选择是确定的；在量子力学中，状态的发展是确定的，但在实验得到的各种可能性之间的选择都是随机的”。

Part III

生命科学

Chapter 16

生态学经典论文

Foundations of Ecology: Classic Papers with Commentaries

Leslie A. Real, James H. Brown (Eds.)

16.1 奠基性论文

Sharon E. Kingsland. Defining Ecology as a Science

生态学源于将实验方法、数量方法应用于有机体与环境关系，群落结构和演替，种群动力学的研究。背景是马尔萨斯人口论和达尔文的自然选择论¹。达尔文的重要贡献是提出种内竞争是进化的主要动力²。此外，Herbert Spencer 认为自然界处于动态平衡中，启发生态学家探索自然具有自我调节能力、使种群间保持平衡的原因³。

1860 年代 Ernst Haeckel 提出 oecology 的说法，用于描述有关生存斗争 (struggle for existence) 的研究。Ecology 一词最初于 1890 年代被美国植物学家使用，用于摒弃描述

¹自然选择论受到了马尔萨斯的启发：达尔文推论过度生育会导致种内竞争加剧、死亡率上升，即选择过程。

²先前人们已认识到种间斗争的作用，如捕食者清除猎物中的弱势个体，但他们认为这只是通过清除异常个体保存了猎物的正常特征。而达尔文认识到种内竞争可以是创造性的而非保存性的。

³Spencer 接受自然选择观点，但认为生物会响应环境而变异，这一观点称为新拉马克主义。

性方法，关注有机体与环境关系的生理学研究⁴；动物学家紧跟这一趋势并于 1920 年代后来居上。

核心概念与方向：

群落演替：Henry Chandler Cowles 通过假设空间变化能反映时间演替，在印第安纳沙丘地区首次得到了群落演替序列。他认为演替趋向稳定平衡态，但平衡态尚未达到，过程中也可能倒退。Frederic Clements 认为演替的终点是顶级群落，而顶级群落的构成由优势植物确定。他还将植物群落类比为复杂有机体，还构建了植物群系的分类体系，二者后来都被弃用。在群落有机体隐喻的批评中，A. G. Tansley (1935) 认为群落演替代表了有多个平衡态的动力系统的轨迹；并基于此定义了生物群落与物理环境构成的生态系统 (ecosystem)；Henry Allen Gleason 提出个体主义 (individualistic) 观点，认为每个植物群落是特定时空环境因素的独特产物，不存在固定不变的 plant structure。

食物网与生态位：Stephen Forbes 分析了种群中昆虫、鱼类、鸟类的食物关系，提出捕食、竞争关系调整种群增长率以维持群落平衡；其出生率与死亡率平衡的假设被长期沿用。Charles Elton 定义了生态位的概念，用与描述物种在食物网中的位置，亦即群落中的“经济地位”。竞争排斥原理 (competitive exclusion principle) 指出不同物种不能占据相同生态位（为了共存，它们必须找到划分资源的方式）。这一原理此前已有观察（如共存物种回避竞争）。Elton 并未论及这一原理，而 Joseph Grinnell 将竞争排斥与生态位联系起来。Georgii F. Gause 的工作进一步将这一原理推向中心地位：种间竞争迫使两个物种生态位分离，这构成群落稳定性的基础。

种群动力学：Raymond Pearl 提出了单一种群规模增长的 logistic 曲线，事实上 Pierre-Francois Verhulst 一个世纪前已有这一结果，只是未引起关注。Vito Volterra 研究了种间竞争和捕食的数学模型，后者被称为 Lotka-Volterra 模型。Alfred James Lotka 独立提出这一模型，其使用的联立微分方程类似后来 Bertalanffy 的一般系统论。Alexander John Nicholson 和 Victor Albert Bailey 在种群模型中考虑了种内竞争、年龄结构等因素，不同于 Lotka-Volterra，他们的模型得到震荡不断增大的不稳定系统⁵。

能量流动：Lotka 研究了生物圈的能量转化，其著作 *Elements of Physical Biology* 涉及水、二氧化碳、氮、磷的循环。受 Tansley 的生态系统概念影响，Raymond Lindeman 关注营养动力学 (trophic-dynamic) 视角，以湖泊为例研究生态系统中的能量流动及其对演替的影响。

⁴他们将生态学视为一种“户外的生理学”，继承生理学在实验室中的严格方法。受达尔文影响，关注是否可通过改变环境控制进化，这有显见的农业应用。

⁵May 指出对于小型、短生命物种（如昆虫与寄生虫），他们的模型比 Lotka-Volterra 模型更适用。

16.2 理论进展

Leslie A. Real, Simon A. Levin. *The Role of Theory in the Rise of Modern Ecology*

1950 年代以来理论生态学主要围绕六个问题：

群落的物种数量及丰度分布：定量模型的构建始于 1940 年代, Fisher 等 (1943) 提出群落内个体数量为 k 的物种数为 $\frac{\alpha\lambda^k}{k}$, 从而总物种数

$$S = \sum_{k=1}^{\infty} \frac{\alpha\lambda^k}{k} = -\alpha \ln(1 - \lambda) = \alpha \ln\left(1 + \frac{N}{\alpha}\right) \quad (16.1)$$

其中 $N = \frac{\alpha\lambda}{1-\lambda}$ 为个体总数. 但个体数量的众数为 1, 与实际的单峰分布不符。

Preston 的工作 (1948,1962) 为这一方向基础: (1) 对物种的个体数量取 log bin 得到正态分布曲线, 亦即个体数量服从对数正态分布; (2) 物种数量-面积满足的关系⁶: $S = cA^z$, 实证给出 $z = 1/4$ 。

Preston 没有给出对数正态分布的生成机制。这方面有两个角度: (1) 生物角度: MacArthur (1957,1960) 提出“断棒 (broken-stick) 模型”, 假设生态位空间表示为一维有限区间, 同时选取 $S - 1$ 个断点, 每段的长度对应一个物种的丰度。但这一模型并不能产生对数正态分布。Sugihara (1980) 改进了这一模型, 多维的超体代替一维区间, 且断点逐一产生, 得到了对数正态分布和物种数量-面积的 $1/4$ 次幂关系。(2) 统计角度: May (1975) 认为对数正态分布是中心极限定理作用于多个因子交互的结果⁷。

生态位理论：生态位的定义并不统一, 归功于 Grinnell, Elton, Gause 和 Hutchinson. Grinnell (1917,1928) 侧重场所概念, 即物种在环境中的位置, 反映对物理环境的适应性; Elton (1927) 侧重功能概念, 即物种与食物、天敌的关系; Gause (1934) 把 Elton 的观点扩展到种间竞争。Hutchinson (1957) 基于集合论语言的形式化描述综合了场所、功能两种视角: 设某一物种受 n 个环境变量 $x_1, \dots, x_n$ 影响, 每个变量有其可接受区间; 其笛卡尔积得到的超立方体代表了物种的基本生态位 N (fundamental niche)。物种在现实中的场所 B 使 N 得到满足。不同物种基本生态位的交集反映了种间竞争。由于同一场所下不同物种的生态位不能相同, 种间竞争影响下实际占据的生态位 (realized niche) 会不同于基本生态位。

⁶这一关系基于物种相对丰度典范分布的性质。考虑每个 log bin 的个体总数得到的个体曲线, 其峰值往往对应物种曲线的尾部, 称满足这一性质的物种相对丰度分布为典范分布。

⁷May 还提出, 典范分布的性质也是大量物种对数正态曲线下的统计结论。

单一物种数量增长：进化视角源于 David Lack (1954) 对鸟繁殖力的探讨，他指出鸟并未最大化产蛋数量⁸，而是最大化能存活的后代数。Cole (1954) 进一步讨论了种群数量增长与生活史现象的联系，提出了一个悖论：单次生殖物种进化为多次生殖物种对种群数量的影响等价于每次繁殖后代数加 1，而后的进化难度远小于前者。后续研究给出了悖论的解决之法：繁殖与存活存在权衡，而幼体存活具有不确定性；只有成体、幼体存活率之比为 1 时悖论才成立。

动力学视角中里程碑研究来自 May (1974)。在此之前，logistic 增长模型表明种群数量会平滑地增加至最大承载量；密度过大对繁殖、存活的影响又会使其达到平稳值，这无法解释种群数量的实际波动。学界多尝试在连续增长模型基础上加入复杂因素，而 May 指出简单的离散增长模型即可产生复杂的动力学⁹。假设代际不重叠，离散增长模型可表达为

$$N_{t+1} = N_t \left(1 + r \left(1 - \frac{N_t}{k} \right) \right) \quad \text{或} \quad N_{t+1} = N_t \exp \left(r \left(1 - \frac{N_t}{k} \right) \right) \quad (16.2)$$

当 r 增大到某个大于 2 的临界值时，系统具有混沌性质：存在周期为任意正整数的循环，是否落入、落入何种循环完全依赖初值；不落入循环的初值有无穷多，且其序列性质类似随机过程。

个体行为：自然选择会偏好高效获取和利用资源的生物。MacArthur 和 Pianka (1966) 使用最优化方法首次显式建模了资源获取策略，优化目标对应进化和行为假设。他们考虑的目标是最大化单位时间获取的期望能量；决策变量包括不同食物数量、觅食路径中包含的地块类型。Schoener (1971) 提出需考虑另一种目标：最小化获取单位能量所需时间。Charnov (1976) 针对地块选择问题，将每个地块停留时间作为决策变量。

承接上述框架，捕食生态学后续研究主要关注生物个体行为的心理和经济学基础，包括引入营养约束；环境随机性与风险；学习、记忆、时间感知等心理约束；阐明能量获取与传统适应度（繁殖与生存）的联系；讨论行为的基因基础等。个体行为对种群增长、群落组织的影响，是一个关注较少的重要方向。

多物种交互：种间关系的数学建模始于 1910 年代 Ronald Ross 和 W. Thompson 对寄生虫病的研究；而成熟的框架归功于 Lotka (1925) 和 Volterra (1926)，他们使用联立微分方程组表达不同物种数量动态。然而这一模型主要用于理论推演，未能成功标定并描述真实动态。

⁸首先，一窝的产蛋数很低；其次，一个蛋被移走或破坏时，往往产一个蛋补上。这体现了生物生活史中的个体选择 (individual selection)。

⁹Lorenz 更早发现了非线性混沌系统，但当时影响有限；May 的研究促使更多领域寻找时序中的混沌现象。

一些学者（如 Margalef）认为群落物种越多稳定性越强，但仅停留于模糊论述，缺乏任何严格的根基。May (1975) 使用 Lotka 的数学建模方法给出了完全相反的结论，动摇了前述观点，尽管其假设存在讨论余地。

移动与尺度：生物的散布 (dispersal) 体现了对环境时空异质性的响应。Skellam (1951) 使用扩散模型建模生物的散布，尽管随机运动假设不实际，模型足以解释生物传播的宏观特性；考虑空间异质性可进一步提升预测能力。模型应用于外来物种入侵、赤潮¹⁰等问题。

16.3 争论与综合

Joel G. Kingsolver and Robert T. Paine. Conversational Biology and Ecological Debate

生态学经历着提出假设、提出不同假设、二者展开辩论的过程；有时单方面胜利，更常见的是问题重新定义后二者可以整合。作者认为已有讨论或未来将有的四个方向：(1) 空模型与零假设的选取；(2) 在通常关注的时空尺度，生态系统是否处于平衡态？一种观点是远离平衡态。许多环境存在干预，但其对生态系统稳定性的一般影响尚不清晰。(3) 种间关系研究往往只关注二元关系，如何拓展以描述食物网的复杂结构？(4) 种群和群落生态学往往只关注平均个体，个体差异仅仅是噪声吗，或者对种间交互有实际影响？

Hutchinson 的论文 *Homage to Santa Rosalia* (1959) 整合了 Lack 的进化生态学理念、生态位概念（种间竞争导致性状偏移），构建了生物多样性的理论。其基础有二：(1) 生态位多样化产生物种多样性，提出性状参数 1:3 的差异可以使两物种共存；(2) 复杂食物网使群落更稳定（后来 May 否定了这一论断）。

对于种群数量、群落结构的主要决定因素，有“种间竞争”和“非生物因素”两种观点。Hairston, Smith 和 Slobodkin (1960) 整合了两种观点，指出主要决定因素与考察的营养级有关，强调不同营养级的主导过程存在差异。

Ehrlich 和 Raven (1964) 由食草昆虫（蝶类）与植物的研究提出了协同进化 (Coevolution) 的概念：植物产生新的次级代谢物以抵御昆虫，食草昆虫进化出绕开防御的方式。特定昆虫与植物长期关联，表明协同进化能促进昆虫和植物的多样化。

¹⁰ 只有条件适宜的区域超过临界值 (critical patch size)，微生物的增殖超过海水的扩散，赤潮才可能爆发。

Harper (1967) 提倡将动物进化生态学的理念引入植物学研究。

16.4 方法进展

James H. Brown. *New Approaches and Methods in Ecology*

古生态学: Lennart von Post (1916) 指出泥炭沼泽的厌氧沉积物 (anaerobic sediments) 中可提取保存完好的花粉粒, 结合沉积物的层次序列可反映最后一次大冰期以来 (约 11500 年前至今) 的植物物种变化, 进而推断环境演变. 这一工作成为古生态学的基础——沼泽中的花粉粒、鼠类粪便堆中的植物组织、湖泊和海洋沉积物中的浮游生物骨架保存了近两万年的物种分布、群落组成信息。古生物学对古生态学影响有限, 原因是化石往往是单一物种, 重建远古群落和环境困难; 其与当今生物的差异使得难以推断其生理、行为、生态关系。相对地, 花粉粒保存了群落中大量物种, 且与现存植物有较高的一致性。

种群动力学: Patrick Leslie (1945) 基于矩阵代数构建了生命表法 (life tables) 的数学基础: 给定任意年龄 x 到 $x + 1$ 的存活率, 及年龄 x 产生的平均后代数, 可计算年龄的平稳分布; 给定任意初始年龄分布, 可计算人口增长率、到达平稳分布的时间¹¹。先前 Pearl、Lotka、Volterra 的人口动力学模型面临参数难以标定的问题, 而 Leslie 的方法依赖的数据是实验室和田野观测可获取的。Leslie 的方法还应用于寿险精算。L. Charles Birch (1948) 在实验室环境研究了象鼻虫的种群增长, 使用生命表法估算了自然增长率等参数, 发现温度等环境因素对自然增长率有显著影响。

C. S. Holling (1959) 在实验室和田野环境研究了小型哺乳动物对松叶蜂蛹的捕食行为。其最重要贡献是将捕食分解为两个层次: 一是捕食者个体对猎物的搜索和摄食行为; 二是影响捕食者和猎物种群数量的繁殖和死亡过程。这两部分对捕食量 (作为猎物密度的函数) 的影响分别称为功能响应 (functional response) 和数量响应 (numerical response)。后续最优捕食策略的研究呼应了功能响应的理念。

生理生态学: Porter 和 Gates (1969) 研究生物体与环境能量交换的物理学, 使用数学模型揭示太阳辐射、风速等环境因素对能量交换的影响; 使用动物的金属模具测量物理因素的影响, 体现生物过程 (新陈代谢、皮肤蒸发等) 的作用; 提出气候空间 (climate space) 概念以描述生物体能维持热平衡从而生存、繁殖的物理因素 (即基本生态位的物

¹¹一些动物个体对种群数量的贡献依赖其社会阶层, 为此可用分阶层的繁殖率、死亡率取代年龄的区分。

理维度)。后续研究持续关注物理环境因素对生物体生存、繁殖的影响。

植物群落生态学: Bray 和 Curtis (1957) 发展了一种基于物种组成对植物群落分类的定量方法, 采用类似 PCA 的多变量分析方法。

生态系统生态学: 1960 年代, 美国生态学界分为两派: Robert MacArthur 领导的进化生态学, 关注种群增长、群落组成、适应性等; Eugene Odum 领导的生态系统生态学, 关注能量流动、营养循环等。Odum (1969) 的论文 *The strategy of ecosystem development* 将两派关注过程统一于群落演替的概念框架中。进化生态学当时并不认可, 因其似乎需要作用于群落或生态系统层次的自然选择过程; 而后来有研究挑战了自然选择只作用于个体的正统观念, 认为群落也存在一定的进化策略。论文同时为生态系统生态学提供了可检验的预测, 推动这一分支走向实验科学。Odum 还论及人类生态学, 指出为了稳定性干预生态系统存在危险 (如阻止大沼泽地区周年的洪水)。

1975 年前尚可认为生态学是一门低技术学科, 如今则不然, 如计算机模拟; 粒子计数器用于微生物计数; 稳定同位素追踪化学物质的种间、空间流动; 遥感用于土壤和植被分布探测; 自动气相色谱 (automated gas chromatography) 识别植物的防御性化学物质; 地理信息系统等。

16.5 自然系统中的案例研究

Robert K. Peet. *Lessons from Nature*

物理学可以从极少的观测出发得出普遍结论, 尽管观测的实现条件可能很特殊 (如粒子对撞机)。一般而言, 生物系统比物理系统更复杂 (部分由于生物承载的遗传信息), 生物学家选取有代表性的模式生物做透彻研究。生态系统更加复杂, 除个体遗传信息外, 还依赖个体空间分布和物理环境的特性。因此生态系统中的普遍性 (generalization) 依赖大量系统的比较研究。经典研究分为两类: 一是单一系统的深入研究, 产生新的洞察; 二是在不同地点观测特定过程, 得到广泛适用的结论。

种群数量调控: 早期种群动力学模型基于种内竞争等密度相关 (density dependent) 因素, 难以符合观测数据。Andrewartha、Birch 和 Davidson 针对蝗虫和蓟马 (1948) 数量的系列研究¹², 揭示了种群数量调控中的密度无关因素。其中蓟马的研究基于 14 年的观测数据, 发现 30 天前的环境变量可以解释 78% 的种群数量对数波动。

¹²集成于专著 *The Distribution and Abundance of Animals* (1953)。

生态系统能量流: Lindeman (1942) 更偏向理论而非实证研究。Howard T. Odum (Eugene Odum 之弟) 针对 Silver Spring, Florida 的研究 (1957) 是自然系统能量流动的第一项相对完整的记录。Silver Spring 的营养结构相对简单, 边界清晰。结果中出人意料的是分解者的重要作用。John Teal 先后在马萨诸塞州冷泉 (1957) 和 Sapelo Island, Georgia 的盐沼 (1962) 开展了类似研究。在营养级间能量流动基础上, 盐沼研究还量化了生物功能分组间的能量流动。意外结果包括: 植物呼吸消耗了 70% 以上能量; 近一半的净初级生产被细菌消费; 相当部分净初级生产因潮汐流出系统。

植物群落结构: 为解决“群落有机体”的争论, Robert Whittaker 开展了大烟山植被分布的研究, 其结果支持 Gleason 的个体主义观点, 宣告了 Clements “群落有机体”观念的终结。Curtis 和 McIntosh 更早发表了类似的案例研究 (南威斯康星州植被), 但因缺少对其结果 implication 的发掘和传播, 影响力不及 Whittaker。

Margaret Davis (1969) 在 Rogers Lake, Connecticut 的孢粉学案例研究, 改变了前人研究仅依据花粉占比推测沉积年代植被组成的方式, 通过量化花粉汇集速率 (influx rate) 实现物种丰富度的更精确推断。基于花粉与现存物种差异的观察, Davis 后来收集全北美花粉记录并通过制图反映不同植物在后冰期的不同传播速率和模式, 为 Gleason 的个体主义观点提供了强力支撑。

过程研究: A.S. Watt 的报告 (1947) 总结了自己的多个案例研究 (覆盖沼泽、森林、苔原、草地多种类型), 指出在成熟植物群落中仍存在小尺度的循环演替, 更新了顶级群落同质、稳定的固有观念¹³。事实上, 植物群落具有时空动态性, 地块可能处于不同发展状态。从倒木到森林大火的干扰事件都可视为动态的一部分, 干扰事件的频率和规模分布反映不同生态系统动态, 这成为当代生态学方向之一。Watt 的观点还影响了后来发展的森林模拟模型, 以及有关空间模式与异质性的研究。

MacArthur (1958) 研究了云杉林中两种相似莺类得以共同存在的原因。其提倡构建理论-提出假设-检验假设的路径, 推动了生态学的研究范式转变。

Brooks 和 Dodson (1965) 观察到康涅狄格湖泊中外来鱼类使大型浮游动物消失的现象 (无外来鱼类的湖泊中, 大型浮游动物本来具有竞争优势)。这一案例研究表明捕食者可以控制其食用营养级的结构, 催生了后来的营养级联 (trophic cascade) 理论。

¹³ 此前也有类似观点, 但仅针对特定类型的群落, Watt 指出了这种再生过程的普遍性。

16.6 受控实验研究

Jane Lubchenco and Leslie A. Real. Manipulative Experiments as Tests of Ecological Theory

实验研究需要有目的地控制条件，其出发点是阐明或验证某一原理。传统上生态学有三种研究方法：（1）相关性分析，关注少数物种或单一系统，如用环境条件差异解释物种分布空间差异；（2）比较分析，对比系统中的多个物种以揭示特定过程的不同阶段，用于进化、演替研究¹⁴；（3）实验方法，可以证实产生生态模式的因果关系。前两种属于观测（Observational）方法，可以支持但无法证实因果关系。

生态学主要由概念而非实验驱动，实验的普遍程度和影响力不及其它学科，原因是：（1）生态系统的多样性导致实验结论的普遍性不足；（2）实验需要将目标对象孤立出来，而生态学关注的恰是实验难以处理的交互效应。

自然选择：由于环境因素不同，同一物种在不同位置下表型可能有显著差异，其原因是基因差异还是表型的可塑性？Clausen 等通过植物移植实验证明不同环境下的种群存在基因差异。Turesson 将这种种内基因差异称为生态型 (ecotype)。自然选择驱动进化的一个典型例子是 19 世纪英国椒蛾 (pepper moth) 的黑化：工业化导致树干颜色变深，而捕食者主要依赖视觉，原本的灰色蛾变得更易被捕食。Kettlewell (1955) 通过实验量化了不同环境下灰、黑椒蛾被捕食概率的差异。生态遗传学后续研究关注作用于隐藏变异（如同功能异构酶）和个体定量特征的选择机制。

群落结构与种间交互：种间竞争的实验室研究始于 G. Gause. Park (1948) 报告了两种小麦甲虫的实验，经过充分的复现，发现总有一种会在竞争中消亡；获胜方有可预测性但不绝对。一种孢子寄生虫的存在与否起到关键作用，尽管两种甲虫单独存在时，有无该孢子虫都不影响其生存。两种甲虫的另一竞争机制是捕食对方种的卵和蛹，这种现象称为集团内捕食 (intraguild predation)。除生物因素外，Park 还论及环境因素对竞争结果的影响。

种间竞争的田野实验始于 Tansley (1917)，其探讨植物分布源于竞争还是物种对不同土壤的适应性，但其实验设计存在缺陷。Connell (1961) 对藤壶的研究证实了竞争对物种分布的影响。他发现 C 种藤壶的幼体无法在海岸较低位置存活，通过实验排除了浸没时

¹⁴Jared Diamond 将此类研究称为 natural experiment，作者认为是 experiment 一词的误用（因为没有控制条件）。

间、捕食者因素，证实原因是较低位置存在构成竞争关系的 B 种藤壶¹⁵。实验通过考虑水深梯度考察环境因素与竞争的交互作用，启发了后续研究考虑不同环境因素（湿度、营养、海拔高度等）的梯度。此外实验还揭示了直接干预的竞争途径（B 种藤壶会挤压、窒息 C 种藤壶）。

捕食的实验室研究同样始于 G. Gause (1934)，他针对两种原生动物的实验不会出现 Lotka-Volterra 模型预测的周期性振荡，而是猎物与捕食者先后灭绝；除非定期加入猎物与捕食者的新个体（模拟迁入）。Huffaker (1958) 扩展了 Gause 的实验，使用螨虫研究了迁移和空间异质性对捕食者-猎物数量波动的影响。通过为捕食者运动设置阻碍、为猎物分散设立廊道，增加环境的斑块度 (patchiness)，即使猎物在局部被消灭也可在另一处聚集成群，从而得到稳定的周期性振荡模式。这种效应当捕食者聚集出现在猎物密度较高区域时更为明显，因为猎物密度较低的区域得到了缓冲期。

捕食的田野实验中影响较大的是 Paine (1966)，其假设是捕食者通过阻止单一物种垄断主要环境必需品促进局部物种多样性。实验在海滩样方上移除顶级捕食者海星，发现物种多样性显著下降，原因是主要竞争者（一种蜗牛）失去捕食者后对空间形成垄断。此类对群落其它成员造成超出其数量影响的物种称为关键物种 (keystone species)¹⁶。移除关键物种会对群落产生巨大影响。

生物地理学：早期生物地理学记录物种的空间分布，并试图基于物种共现和关联得到进化的结论，代表人物为“进化生物地理学之父” Alfred R. Wallace。接下来的一个世纪，生物地理学更多关注物种分布模式而非其产生过程；认为当今物种组成是地质时间尺度进化过程的结果。

针对岛屿面积越小、越偏远物种数越少的倾向，MacArthur 和 Wilson 发展了岛屿生物地理学的平衡理论，认为岛屿物种组成受当下时间尺度的两个过程影响：外来物种的迁入，本地物种的灭绝¹⁷；不同面积和偏远程度的岛屿有不同的均衡物种数，而物种组成是动态变化的。为验证这一理论，Simberloff 和 Wilson (1969) 在 Florida Keys 开展了大规模实验，在封闭的红树林岛屿上清除了所有动物而不伤害植物。除最偏远小岛外，岛屿在一年内恢复了原有物种数，随后出现物种更迭但物种数保持稳定，从而支持了 MacArthur-Wilson 理论。

大规模生态系统控制：对生态系统能量和营养流动的研究止于静态描述，难以得到生态系统对扰动的响应。Likens (1970) 在 New Hampshire 的 Hubbard Brook 实验林研究了

¹⁵后续研究表明 B 种藤壶分布的影响因素主要是捕食者，说明竞争并不是群落结构的唯一影响因素。

¹⁶除关键捕食者外，有学者提出这一概念还应包括关键共生者，其对群落的影响超出其消耗的资源。

¹⁷物种组成也受竞争、捕食、进化等过程的影响，这是后续研究探讨的议题。

植被对生物地球化学循环的调控作用。对一个样地去除所有树木的两年后，溪流中的离子含量大幅增加，证实了森林生态系统中树木对营养物质的保留作用。Schindler 和 Fee (1974) 在加拿大 Experimental Lake Area 开展了湖泊富营养化的受控实验，证明湖泊营养状况主要受磷的影响。

Part IV

地球科学

Chapter 17

新城市科学

The New Science of Cities

Michael Batty

17.1 基础与前提

传统理论将城市视为空间、场所和区位的集合；而本书将城市看作相互作用的集合，区位是相互作用的结果。流系统和网络系统是理解城市的两个略有不同而相互补充的视角。

Chapter 18

计量地理学

Quantitative Geography: Perspectives on Spatial Data Analysis

A. Stewart Fotheringham, Chris Brunsdon, Martin Charlton

18.1 概论

计量地理研究 20 世纪 80 年代早期到 90 年代中期经历低迷，主要在人文地理学领域（自然地理学受影响不大）。其原因包括支撑计量地理学的实证主义哲学¹的衰落，马克思主义、后现代主义、结构主义、人文主义等新思潮的兴起（地理学具有批判现有范式、追求新范式的特点）。有观点认为计量方法的批评者大多对其了解不够，认为其相对困难。

对计量地理学的批评包括过于注重普适规律，对个体建模不关注认知与行为过程等。作者指出计量地理学的新发展（如局部分析、融入认知和心理过程的空间交互建模）使上述批评不再适用。事实上，自然主义的观点（“地理即物理”，追求普适定律和全局关系），更多被自然地理而非人文地理学者采用。

计量方法提供了认识空间过程的有效、可靠手段。即使对于难以完全量化的人类行为，计量方法也能量化其中可度量的影响因素（如距离阻碍）。

¹实证主义 (positivism) 认为所有的真知都可通过观察、实验、逻辑推理等科学方法证实。

对空间数据特殊性质（空间效应）的认识是计量地理学发展成熟的标志，计量地理学者由其它学科技术方法的使用者转变为空间数据分析思想的输出者。

写作本书之时计量地理学的进展体现在局部分析方法、探索性数据可视化、地学计算 (Geocomputation) 等。地理计算强调空间数据定量分析中对计算机计算能力的运用，如 Moran's I 的显著性检验中，使用 t 统计量不视为地理计算，Monte Carlo 模拟则视为地理计算，后者规避了理论分布可能不满足的问题。

18.2 数据探索性可视化

18.2.1 单变量方法

茎叶图.

箱线图 (boxplot): 五数概括包括最小值 $x_{\min}$ 、1/4 分位数 Q_1 、中位数 Q_2 、3/4 分位数 Q_3 、最大值 $x_{\max}$ 。箱线图的矩形边界表示上下四分位数，矩形中的横线表示中位数；竖线可延伸到最大、最小值，或延伸到²

$$\min\{x_{\max}, Q_2 + 1.5(Q_3 - Q_1)\} \quad (18.1)$$

及

$$\max\{x_{\min}, Q_2 - 1.5(Q_3 - Q_1)\}. \quad (18.2)$$

超出此范围的异常值用点标出。

直方图和频数折线图: 可视为概率密度函数的近似，直方图假设每个分组内概率密度函数为定值，折线图假设为分段线性函数。Terrell 和 Scott 对二者分别给出极大平滑的保守分组个数 $(2n)^{1/3}$ 和 $(73.5n)^{1/5}$ (n 为观测数)，可能存在过度平滑，但更接近真实模式。

核密度估计: 核 $g(\cdot)$ 是均值为 0、方差为 1 的概率密度函数。对于标量数据，以每个 x_i 为中心生成核，再对所有核求平均得到概率密度函数:

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} g\left(\frac{x - x_i}{h}\right). \quad (18.3)$$

h 为带宽，过大则掩盖细节，过小则导致尖峰估计。Terrell 给出极大平滑规则:

$$h \approx s \left(\frac{243 \int g^2(x) dx}{35n} \right)^{1/5}. \quad (18.4)$$

²也有时延伸到 10% 分位数和 90% 分位数

s 是样本标准差。

地图：不同可视化窗口间的关联，特别是数据图与地图的关联很有帮助。

18.2.2 多变量方法

探索的多变量数据特征包括：聚类、异常、趋势。

散点图矩阵： m 个变量的矩阵为 m 行 m 列（对角线为空），同一行具有相同的 y 轴变量，同一列具有相同的 x 轴变量。局限性是只能表示两个变量间的关系。

平行坐标图：数据 $(x_1, \dots, x_m)$ 表示为折线 $(1, x_1)(2, x_2) \dots (m, x_m)$ 。实际应用需对各特征标准化处理。可同时表示 m 个变量的信息，但图形模式依赖坐标轴排列顺序（考虑左右对称， m 个变量有 $m!/2$ 种情形）。

径向坐标可视化 (Radial Coordinate Visualization, RADVIZ)：设 m 个点均匀排布在单位圆周上，位置向量分别为 $S_1, \dots, S_m$ ，数据 $(x_1, \dots, x_m)$ 表示为平面上的点，位置向量为

$$\mathbf{u} = \frac{\sum_{j=1}^m x_j S_j}{\sum_{j=1}^m x_j} \quad (18.5)$$

其物理解释为：设小球分别通过弹性系数为 x_j 的弹簧与 S_j 相连，则平衡位置为 $\mathbf{u}$ 。

当每个 x_j 非负时， $\mathbf{u}$ 在 $S_1, \dots, S_m$ 的凸包内。通常对每个变量进行 0-1 标准化。这一映射当然不是单射，只要每个 x_j 相等， $\mathbf{u}$ 都取原点。RADVIZ 对成分数据（向量各分量之和为 1）更适用。考虑旋转和镜像对称， m 个变量有 $(m-1)!/2$ 种不同的映射；实践中可根据某种目标（如 $\mathbf{u}$ 的方差）做离散搜索优化，也可通过交互控制选取。

投影寻踪 (Projection Pursuit)：指根据要探测的特征选取某个高维特征空间到二（三）维的投影，属于连续优化问题。探测的目标可以是偏离高斯分布的情况（中心孔洞或偏态分布），或最小化平均最邻近距离 (Mean Nearest-Neighbor Distance) 来探测聚类特征。与之相对的是总体巡查 (Grand Tour)，投影方向动态变化，以显示所有可能的投影。引导性总体巡查播放投影寻踪中的迭代优化过程。

18.3 点模式分析

点模式分析主要检测点集空间分布的两种现象：聚集和分散，即聚集程度大于或小于随机分布；比较同一区域多组点集分布间的关系，或点集与参考场间的关系（如病例相对

于人口密度的集中程度)。

探索性分析：绘制空间散点图（注意检查是否有重合点，如有可改用气泡图）；计算点集重心，标准距离（到重心的均方根距离）³；

$$d_s = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 + (y_i - \bar{y})^2} \quad (18.6)$$

计算最邻近距离 (Nearest-Neighbor Distance) 的分布。

点过程强度：设 X 是研究区 R 内的点集， $\mathbf{x}$ 点处的强度定义为

$$\lambda(\mathbf{x}) = \lim_{r \rightarrow 0} \frac{E(|X \cap U(\mathbf{x}, r)|)}{\pi r^2}$$

其与概率密度差一个常数：

$$f(\mathbf{x}) = \frac{\lambda(\mathbf{x})}{E(|X \cap R|)} \quad (18.7)$$

考虑不同位置的相互作用，定义二阶强度为

$$\gamma(\mathbf{x}_1, \mathbf{x}_2) = \lim_{r_1 \rightarrow 0, r_2 \rightarrow 0} \frac{E(|X \cap U(\mathbf{x}_1, r_1)| |X \cap U(\mathbf{x}_2, r_2)|)}{\pi^2 r_1^2 r_2^2}$$

满足二阶平稳假设时，有 $\gamma(\mathbf{x}_1, \mathbf{x}_2) = \gamma(\mathbf{x}_1 - \mathbf{x}_2)$ 。观测到的聚集理论上既可能由于一阶强度非恒定，也可能由于相互作用存在（事件之间不独立）；二者很难区分。因此一阶模型假定事件之间相互独立，强度非均质；二阶模型假定强度均质，但事件间非独立。两类方法对于单一点集的集聚性分析结果往往一致，但对于两个点集的比较，可能一阶属性（核密度曲面）差异显著而二阶属性（K 函数）差异不显著。

完全空间随机模式 (Complete Spatial Randomness, CSR) 假设：(1) 一阶强度恒定， $\lambda(\mathbf{x}) \equiv \lambda$ ；(2) 事件之间相互独立，即对任意两个不交的区域 A_1, A_2 ， $\text{cov}(|X \cap A_1|, |X \cap A_2|) = 0$ 。此时任一子区域 A 的点数量服从均值为 $\lambda|A|$ 的 Poisson 分布。

一阶强度分析方法包括样方法、核密度估计；二阶强度分析包括 K 函数等。

样方法：将研究区域划分为等大网格，统计每个网格内点的数量 $\{g_i\}_{i=1}^G$ ，检验其是否符合 Poisson 分布。一种方法是利用 Poisson 分布均值等于方差的性质：

$$I = \frac{\sum_{i=1}^G (g_i - \bar{g})^2}{(G-1)\bar{g}} \quad (18.8)$$

CSR 假设下近似有 $(G-1)I \sim \chi_{G-1}^2$ ⁴。 I 的显著高值代表聚集分布，显著低值代表规则分布。检验结果可能与网格大小有关。

³当点集不止一个聚簇时，重心和标准距离可能意义不大。

⁴当 $G > 6$ 且 $\lambda|A_g| > 1$ 时（ A_g 为任一网格），可认为近似成立。

核密度估计：可视为强度朴素估计（圆盘内计数与面积之比）的连续性扩展。核强度的估计式为

$$\hat{\lambda}(\mathbf{x}) = \sum_{i=1}^n \frac{1}{h^2} k\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right) \quad (18.9)$$

除以点计数即得核概率密度估计。其中带宽 h 可取局部值（随空间位置变化）。

K 函数：若点过程满足二阶平稳、各向同性，二阶强度是距离的函数。定义 K 函数为

$$K(d) = \frac{E_{\mathbf{x} \in X}(|X \cap U(\mathbf{x}, d)|)}{\bar{\lambda}} \quad (18.10)$$

其中 $\bar{\lambda}$ 为平均强度. K 函数的估计式为

$$\hat{K}(d) = \frac{|R|}{n^2} \sum_{i=1}^n |X \cap U(\mathbf{x}_i, d)| \quad (18.11)$$

若研究区域未包含完整的空间点过程，需要考虑边缘效应。当 d 相对研究区域较小时，可在式 (18.11) 的求和号中忽略到边界距离小于 d 的点（分母相应变为 $n(n-s)$ ， s 为忽略的点个数）；否则需要在和式的对应项除以调整因子以弥补边界带来的点数低估。CSR 假设下有 $K(d) = \pi d^2$ ；高于此值代表集聚，反之代表分散。可定义辅助函数与随机模式进行比较：

$$L(d) = \sqrt{\frac{K(d)}{\pi}} - d \quad (18.12)$$

$$l(d) = \frac{1}{2} \ln \left(\frac{K(d)}{\pi} \right) - \ln(d) \quad (18.13)$$

显著性检验可采用自助法（估计样本分布）或 Monte Carlo 模拟（估计零假设下理论分布）。为检验两组空间点的分布模式是否有显著差异，可类似定义 $l_{12}(d) = \ln K_1(d) - \ln K_2(d)$ ，利用自助法或 Monte Carlo 模拟（固定事件点位置，随机分配两类点的标签）检验显著性。

交叉 K 函数：度量一组空间点在另一组空间点周围聚集或排斥的趋势，定义为

$$K_{12}(d) = \frac{E_{\mathbf{x} \in X_1}(|X_2 \cap U(\mathbf{x}, d)|)}{\bar{\lambda}_2} \quad (18.14)$$

$$\hat{K}_{12}(d) = \frac{|R|}{n_1 n_2} \sum_{\mathbf{u} \in X_1} \sum_{\mathbf{v} \in X_2} I[\|\mathbf{u} - \mathbf{v}\| \leq d] \quad (18.15)$$

若两组空间点来自同一个点过程，则交叉 K 函数为 πd^2 。

18.4 空间回归分析

经典线性回归本质上是非空间的，用于空间数据时残差往往具有正空间自相关。误差项之间不独立使得 OLS 估计不再是有效的，统计推断也不能如常进行。建模非独立误差项的两种思路：(1) 考虑误差项的空间自相关（空间滞后模型，Kriging 回归）；(2) 建模误差项的空间趋势（半参数平滑法）。对 (1) 而言，这些方法给出的回归系数置信区间没有考虑空间权重矩阵（空间相关函数）的不确定性。

一般框架：模型记为

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\epsilon}, \boldsymbol{\epsilon} \sim \mathcal{N}(0, C) \quad (18.16)$$

C 为任意协方差矩阵；误差不独立意味着 C 不是对角矩阵。若 C 已知，则有最大似然估计

$$\hat{\boldsymbol{\beta}} = (X^T C X)^{-1} X^T C \mathbf{y} \quad (18.17)$$

但 C 一般需要从样本数据中求出。

空间自回归模型 (Spatial Autoregressive Model):

$$\mathbf{y} = \rho W \mathbf{y} + X\boldsymbol{\beta} + \boldsymbol{\epsilon} \quad (18.18)$$

其中 W 是行标准化的空间权重矩阵。上式可变形为

$$\mathbf{y} = (I - \rho W)^{-1} X\boldsymbol{\beta} + (I - \rho W)^{-1} \boldsymbol{\epsilon} \quad (18.19)$$

令 $X' = (I - \rho W)^{-1} X$, $\boldsymbol{\epsilon}' = (I - \rho W)^{-1} \boldsymbol{\epsilon}$, 则变换后误差协方差矩阵为

$$C = \sigma^2 (I - \rho W)^{-1} [(I - \rho W)^{-1}]^T \quad (18.20)$$

采用最大似然法估计模型参数。

空间误差模型 (Spatial Error Model)⁵:

$$\mathbf{y} = X\boldsymbol{\beta} + \mathbf{u}, \mathbf{u} = \rho W \mathbf{u} + \boldsymbol{\epsilon} \quad (18.21)$$

上式可变换为

$$(I - \rho W)\mathbf{y} = (I - \rho W)X\boldsymbol{\beta} + \boldsymbol{\epsilon} \quad (18.22)$$

参数估计步骤为：(1) 先视为经典线性回归，利用 OLS 估计得到初始系数 $\boldsymbol{\beta}$ ；(2) 计算残差，对残差估计自回归模型得到 ρ ；(3) 利用式 (18.22) 和 ρ 值重新估计 $\boldsymbol{\beta}$ ；(4) 重复 (2)-(3) 直至收敛。

⁵原文称为“空间滑动平均模型”

Kriging 回归: 先视为经典线性回归, 利用 OLS 估计得到初始系数 β , 然后对残差拟合半变异函数 $g(d)$, 由此可得到误差的协方差矩阵 C , 并用式 (18.17) 重新估计 β 。事实上,

$$g(d_{ij}) = \frac{1}{2}E(e_i - e_j)^2 = \sigma^2 - \text{Cov}(e_i, e_j) = \sigma^2 - c_{ij} \quad (18.23)$$

其中 σ^2 是基台值 (sill), 即半变异函数的渐近上界。

半参数平滑法:

$$y_i = f(u_i, v_i) + \sum_j \beta_j x_{ij} + \epsilon_j \quad (18.24)$$

其中 f 模拟误差的空间变化, 由各样本点的残差根据距离衰减的核函数加权得到。矩阵形式为

$$\mathbf{y} = \mathbf{f} + X\beta + \epsilon, \mathbf{f} = W(\mathbf{y} - X\beta) \quad (18.25)$$

对前一式用 OLS 估计, 再代入后一式, 得⁶

$$\hat{\beta} = (X^T(I - W)X)^{-1}X^T(I - W)\mathbf{y} \quad (18.26)$$

其中带宽参数可采用广义交叉验证 (Generalized Cross-Validation) 选取。

18.5 局部分析

全局分析是对研究区域的整体概括, 可能隐藏空间变化。局部分析强调空间的差异性, 其发展动力部分来源于对 GIS 与空间分析集成的兴趣 (局部分析是空间显式的, 其结果可用 GIS 可视化)。

变量间关系表现出空间非平稳性的原因: (1) 随机采样的变化 (也应包括测量误差等随机波动); 并非关注重点, 一般关注的是参数估计中的系统变化。(2) 关系在空间上的本质差异; 自然地理学中少见, 但人的态度、偏好和行为是空间变化的, 这一观点与后现代主义人类行为研究以位置和局部性为研究框架相符。(3) 模型误设, 如遗漏变量和函数形式误设; 这一观点与实证学派相近, 认为行为存在普遍规律, 只是我们的模型不够完善。

局部点模式分析: 点模式的全局统计量给出集聚性、分散性、随机性的总体描述, 但无法探测局部异常, 而后者在疾病研究中有重要应用。局部点模式分析的进展包括 Openshaw 提出的地理分析机 (Geographical Analysis Machine) 及其改进, 该方法通过比较实际和期望情形下随机圆形窗口内点的个数识别局部异常。

⁶若直接联立上述两式, 则得到类似于空间误差模型的形式: $(I - W)\mathbf{y} = (I - W)X\beta + \epsilon$

局部自相关分析：可视化方法包括半方差函数云 (semivariogram, 变量平方差对距离) 和 Moran 散点图 (邻域均值对当前值)。局部自相关指数包括 Getis-Ord G_i^* 指数和 Moran I_i 指数⁷。

局部回归分析：包括 (1) 空间自适应滤波 (Spatial Adaptive Filtering), 参数估计难以进行统计检验。(2) 贝叶斯随机系数模型、多层次模型, 没有关系空间依赖性的假设。(3) 空间扩展法。(4) 地理加权回归。

多层次模型同时包含个体因素和地点因素 (语境效应), 避免仅考虑个体层面的微体谬误 (Atomistic Fallacy) 和仅考虑总体层面的生态谬误 (Ecological Fallacy); 需要定义离散的空间单元, 且地理过程在边界处发生突变。

空间扩展法的局限性在于需要预先设定方程的形式, 且只能建模关系空间变化的整体趋势, 可能掩盖局部变化。

地理加权回归原理与局部加权回归 (Locally Weighted Regression)、回归参数漂移分析 (Drift Analysis of Regression Parameters, DARP) 相似; 后两种数据权重由属性相似度而非地理距离决定。

局部空间交互模型：交互起点为单元 i 的条件下, 终点为单元 k 的概率

$$p_{ik} = \frac{S_k^\alpha d_{ik}^{-\beta}}{\sum_j S_j^\alpha d_{ij}^{-\beta}} \quad (18.27)$$

全局模型对参数 α, β 作全局估计, 也可对每个起点分别估计模型, 得到参数的空间变化。

18.6 空间数据统计推断

推断指基于可观测的相关信息对未观测的信息所作的陈述。推断方法大致可分为非形式推断 (包括探索性数据分析、可视化、聚类分析等) 和形式推断 (包括经典统计推断、贝叶斯推断)。

经典统计推断中的假设检验有时受到批评, 如在 θ 真实值很接近 0 时, 若样本量足够大, $\theta = 0$ 的零假设也会被拒绝。贝叶斯推断的争议主要在于先验分布的主观性, 即可以根据预设结论调整先验; 尽管在一定条件下当数据量足够大时, 结果对先验选择不敏感。

⁷Anselin 指出, 若要求全局与局部统计量有加和关系, G_i 不属于局部空间自相关统计量。

假设检验之间不相互独立给多重假设检验校正带来进一步的困难。可能的解决方案是考虑高维空间中的置信域（或贝叶斯统计中的多元后验分布）。

18.7 空间交互模型

空间交互模型的发展可分为四个阶段：

社会物理学阶段（1860-1970）：Carey 和 Ravenstein 指出城市间人口流动类似物体间的引力，因而出现了类比万有引力的重力模型：

$$T_{ij} = k \frac{P_i^\alpha P_j^\gamma}{d_{ij}^\beta} \quad (18.28)$$

其中 α, γ 反映了空间流动与规模的待估关系； β 建模了距离衰减作用对不同类型交互、不同地区的可能变化。上式的规模可扩展为一系列属性（方幂）的乘积，并用取对数最小二乘拟合参数。

统计力学阶段（20 世纪 70 年代）：Wilson 利用最大熵推导了空间交互模型族。设总交互量为 T ，熵定义为

$$H = - \sum_{i,j} \frac{T_{ij}}{T} \ln \frac{T_{ij}}{T} \quad (18.29)$$

无约束时交互量均匀分布于各边熵最大。Wilson 引入一系列约束，不同约束组合分别推导出前述无约束、下述产出约束、吸引约束重力模型：

$$T_{ij} = O_i P_j^\gamma d_{ij}^{-\beta} / \sum_k P_k^\gamma d_{ik}^{-\beta} \quad (18.30)$$

$$T_{ij} = D_j P_i^\alpha d_{ij}^{-\beta} / \sum_k P_k^\alpha d_{kj}^{-\beta} \quad (18.31)$$

以及双约束重力模型

$$T_{ij} = A_i O_i B_j D_j d_{ij}^{-\beta} \quad (18.32)$$

$$A_i = \left(\sum_j B_j D_j d_{ij}^{-\beta} \right)^{-1} \quad (18.33)$$

$$B_j = \left(\sum_i A_i O_i d_{ij}^{-\beta} \right)^{-1} \quad (18.34)$$

批评认为最大熵模型只是用统计力学的物理类比代替万有引力的物理类比，仍没有反映个体的空间决策过程；其部分约束条件也缺乏合理性。

非空间信息处理阶段（20 世纪 80 年代）：MacFadden 提出离散选择模型，根据目的地属性分配出发点 i 的流量。设目的地 j 的效用为 $U_{ij} = V_{ij} + \mu_{ij}$ ，其中 V_{ij} 是可观测的部分，则选择目的地 j 的概率

$$p_{ij} = P(U_{ij} > U_{ik}, \forall k \neq j) \quad (18.35)$$

在一定条件下，有 $p_{ij} = \exp V_{ij} / \sum_k \exp V_{ik}$ 。再令 $V_{ij} \propto (\alpha \ln P_j)(-\beta \ln d_{ij})$ ，即得产出约束重力模型。这一模型限制了两个备选项概率之比不受其它选项影响；且新增目的地总会使其它选项概率降低（实际集聚效应可能导致其它选项概率升高）。

空间信息处理阶段（20 世纪 90 年代以来）：Fotheringham 提出了竞争目的地模型，基于人处理信息容量的有限性，假设人首先确定目的地的备选集，再从中选取目的地。具体而言，在模型中加入每个目的地进入备选集 M 的可能性度量，分配模型变为

$$p_{ij} = \frac{\exp V_{ij} \cdot l_i(j \in M)}{\sum_k \exp V_{ik} \cdot l_i(k \in M)} \quad (18.36)$$

可能性度量的一种形式是利用可达性度量其它目的地的竞争效应：

$$l_i(j \in M) = \left(\sum_{k \neq j} P_k^\alpha / d_{kj}^\beta \right)^\delta \quad (18.37)$$

δ 一般为负，若为正，代表集聚效应。

18.8 前景与展望

空间数据分析面临的挑战包括可变面状单元问题，分析结果依赖邻近关系（权重矩阵）的定义等。未来研究方向包括地理加权思想的扩展，贝叶斯推断的应用，时空相互作用（事件发生的时间、地点是否相互独立）等。

感知或认知距离不太可能遵循欧氏几何规则。

Chapter 19

城市与区域建模中的最大熵方法

Entropy in Urban and Regional Modelling

Alan Geoffrey Wilson

19.1 背景

在本书之前，熵的概念主要用于非社会科学。本书表明了其在城市和区域建模中的应用价值。

统计力学可以在不解释粒子微观行为的情况下解释气体系统的宏观性质；与之类比，空间交互模型在不解释个体出行行为的情况下解释宏观现象；二者都借助熵的概念与微观状态联系。

空间交互系统可用 OD 表 (origin-destination table) 描述；各 O-D 对的个体集合构成系统的完整描述，称为系统的一种状态 (state)；各 O-D 对的流量称为系统的一种（流量）分布 (distribution)。状态是系统的微观描述，分布是宏观描述；一阶流量的空间分布是更高层（信息量更少）的宏观描述。假定状态是等概率的，可求出对应状态数最多（概率最大）的流量分布；这一状态数的对数即对应系统的熵，反映了系统微观状态的不确定性。

从概率论视角，离散概率分布 $P(X = x_i) = p_i, i = 1, \dots, n$ 的熵定义为

$$S(p_1, \dots, p_n) = -k \sum_i p_i \ln p_i \quad (19.1)$$

给定已知约束估计概率分布时, 最大化熵的假设不引入额外的偏置 (其它结果意味着缺乏根据地减少不确定度). 另一方面, 令 $h(X) = \ln P(X)$, 对数似然的期望 $Eh(X) = \sum_i p_i \ln p_i$ 恰为熵的负值. 在最大似然估计中, 随着样本量增大, 对数似然函数的均值依大数律收敛于期望, 估计的结果是不确定度最小的分布, 这与前述信息不足的情形恰好相反.

设已知条件为 $Ef(X) = \sum_i p_i f(x_i)$, 用 Lagrange 乘子法最大化熵得到

$$p_i = \frac{e^{-\mu f(x_i)}}{\sum_i e^{-\mu f(x_i)}} \quad (19.2)$$

其中乘子 μ 根据 $Ef(X)$ 的值确定. 若 $Ef(X)$ 的值未知, 可采用统计学参数估计方法拟合¹; 在这种情况下, 最大熵方法的作用是给出 p_i 的函数形式; 引入更多已知条件 (约束) 对应增加模型参数.

熵与微观状态数的关系. 设有 n 种离散状态, T 个个体的分布 $\{T_i\}_{i=1}^n$ ($\sum_i T_i = T$) 对应的微观状态数为 $\mathcal{W}(\{T_i\}) = T! / \prod_i T_i!$. 记 $p_i = T_i/T$, 由 Stirling 公式, 有

$$\begin{aligned} \ln \mathcal{W}(\{T_i\}) &\approx \ln T! - \sum_i (T_i \ln T_i - T_i) \\ &= (\ln T! + T - T \ln T) - T \sum p_i \ln p_i \end{aligned} \quad (19.3)$$

因此熵与微观状态数的对数近似线性相关.

本书主要关注最大熵方法在模型 (假设) 构建²、现有理论解释、系统动力学研究三个方面的应用.

19.2 交通模型

交通模型包含四个子模型: 行程生成 (trip generation)、行程分布 (trip distribution)、交通方式选择 (mode choice)、路线分配 (route assignment). 行程生成得出一阶流入量或流出量的分布; 行程分布得出二阶流量. 最大熵方法应用于行程分布和交通方式选择.

¹此时 $f(x)$ 的选取是需要考虑的因素, 一种方式是选取在系统中有重要含义的量.

²Hypothesis 和 Model 作为同义词使用; Theory 是经过检验的 Hypothesis.

19.2.1 重力模型

给定一阶流量的空间分布 $\{O_i\}, \{D_j\}$ 和总出行费用 C , 并记 c_{ij} 为 i 到 j 的出行费用. 记 $T = \sum_{i,j} T_{ij}$, $\{T_{ij}\}$ 对应的状态数为

$$\mathcal{W}(\{T_{ij}\}) = \frac{T!}{\prod_{i,j} T_{ij}!} \quad (19.4)$$

流量分布 $\{T_{ij}\}$ 的约束为

$$\sum_j T_{ij} = O_i \quad (19.5)$$

$$\sum_i T_{ij} = D_j \quad (19.6)$$

$$\sum_{i,j} T_{ij} c_{ij} = C \quad (19.7)$$

在上述约束下, 使用 Lagrange 乘子法最大化 $\ln \mathcal{W}(\{T_{ij}\})$,

$$\mathcal{L} = \ln T! - \sum_{i,j} \ln T_{ij}! + \sum_i \lambda_i (O_i - \sum_j T_{ij}) + \sum_j \mu_j (D_j - \sum_i T_{ij}) + \beta (C - \sum_{i,j} T_{ij} c_{ij}) \quad (19.8)$$

使用 Stirling 近似公式³有 $\ln N! \approx \ln N \ln N$,

$$\frac{\partial \mathcal{L}}{\partial T_{ij}} = -\ln T_{ij} - \lambda_i - \mu_j - \beta c_{ij} \quad (19.9)$$

因此极值条件为

$$T_{ij} = e^{-\lambda_i - \mu_j - \beta c_{ij}} \quad (19.10)$$

令 $A_i = e^{-\lambda_i}/O_i$, $B_j = e^{-\mu_j}/D_j$, 结合流入、流出量约束即得到双边约束的重力模型

$$T_{ij} = A_i B_j O_i D_j e^{-\beta c_{ij}} \quad (19.11)$$

$$A_i = \left(\sum_j B_j D_j e^{-\beta c_{ij}} \right)^{-1} \quad (19.12)$$

$$B_j = \left(\sum_i A_i O_i e^{-\beta c_{ij}} \right)^{-1} \quad (19.13)$$

³Stirling 近似对较小值不成立的问题不是本质的, 使用熵的概率定义而不借助该近似也能导出同样结果. 事实上, 令 $S = -\sum_{i,j} T_{ij} \ln(T_{ij}/T) = T \ln T - \sum_{i,j} T_{ij} \ln T_{ij}$, S 对 T_{ij} 的偏导为 $-\ln T_{ij} - 1$, -1 在结果中只影响常数项.

通常 C 未知, β 依据流量数据估计⁴. 引入的约束是否合理可能影响导出模型的有效性. 作者的讨论限定于相对同质人群的通勤流, 基于 *Marchetti* 常数认为总时间成本守恒是合理的; 相应如果将 c_{ij} 解读为地理距离则不尽合理; 非通勤流的情况也可能更复杂.

上述方法与统计物理中的微正则系综 (microcanonical ensemble) 相关. Dieter 认为双约束重力模型中的 A_i, B_j 代表了起终点处的成本. 最大熵方法不支持这一结论, 因为将 c_{ij} 改写为 $a_i + b_j + c_{ij}$, 模型仍包含 A_i, B_j 项.

考虑 $\ln W$ 在最大熵分布处的二阶 Taylor 展开,

$$\begin{aligned}\Delta \ln W &= \frac{1}{2} \sum_{i,j} \frac{\partial^2 \ln W}{\partial T_{ij}^2} (\Delta T_{ij})^2 \\ &= -\frac{1}{2} \sum_{i,j} T_{ij} \left(\frac{\Delta T_{ij}}{T_{ij}} \right)^2\end{aligned}\quad (19.14)$$

设每个 $\frac{\Delta T_{ij}}{T_{ij}}$ 均为 p , $\ln W$ 变化量为 $-\frac{1}{2}p^2T$. 作者以此说明最大熵分布是尖锐的极值 (如 $T = 3 \times 10^7, p = 10^{-3}, \Delta \ln W = -15$), 但忽略了当 T 非常大时, W 本身的量级也是巨大的.

上述结果并不意味着负指数是唯一正确的距离衰减形式, 因为实际成本与测量成本间可能存在转换函数. 例如以 $\ln c_{ij}$ 代替 c_{ij} 即得到幂律衰减. 这意味着, 在人类移动受成本约束的幂律衰减的实证结果暗示对数距离比距离更接近人群移动中的成本的含义.

19.2.2 广义重力模型

模型有必要区分不同交通方式, 以及可选交通方式不同的人群 (如是否拥有小汽车). 在原有记号基础上, 设 $T_{ij}^{(kn)}$ 为人群 n 中以交通方式 k 从 i 到 j 的人数, $c_{ij}^{(k)}$ 为交通方式 k 下的出行成本, $M(n)$ 为人群 n 可选交通方式的集合. 考虑如下约束:

$$\sum_j \sum_{k \in M(n)} T_{ij}^{(kn)} = O_i^{(n)} \quad (19.15)$$

$$\sum_i \sum_n \sum_{k \in M(n)} T_{ij}^{(kn)} = D_j \quad (19.16)$$

$$\sum_{i,j} \sum_{k \in M(n)} T_{ij}^{(kn)} c_{ij}^{(k)} = C^{(n)} \quad (19.17)$$

⁴上述推导对保留或去除到自身的流 (T_{ii}) 都适用.

最大化 $\ln \frac{T!}{\prod_{i,j} \prod_n \prod_{k \in M(n)} T_{ij}^{(kn)}!}$ 给出

$$T_{ij}^{(kn)} = A_i^{(n)} B_j O_i^{(n)} D_j e^{-\beta^{(n)} c_{ij}^{(k)}} \quad (19.18)$$

$$A_i^{(n)} = \left(\sum_j \sum_{k \in M(n)} B_j D_j e^{-\beta^{(n)} c_{ij}^{(k)}} \right)^{-1} \quad (19.19)$$

$$B_j = \left(\sum_i \sum_n \sum_{k \in M(n)} A_i^{(n)} O_i^{(n)} e^{-\beta^{(n)} c_{ij}^{(k)}} \right)^{-1} \quad (19.20)$$

这给出选择交通方式 k 的比例为

$$\frac{1}{1 + \sum_{k' \in M(n), k' \neq k} e^{-\beta^{(n)} (c_{ij}^{(k')} - c_{ij}^{(k)})}} \quad (19.21)$$

该模型中 $\beta^{(n)}$ 反映了人群 n 在选择交通方式、目的地时对花费的敏感程度⁵.

对不同人群聚合（或不区分人群时），模型简化为

$$T_{ij}^{(k)} = A_i B_j O_i D_j e^{-\beta c_{ij}^{(k)}} \quad (19.22)$$

$$A_i = \left(\sum_j \sum_k B_j D_j e^{-\beta c_{ij}^{(k)}} \right)^{-1} \quad (19.23)$$

$$B_j = \left(\sum_i \sum_k A_i O_i e^{-\beta c_{ij}^{(k)}} \right)^{-1} \quad (19.24)$$

对不同交通方式聚合，模型简化为

$$T_{ij}^{(n)} = A_i^{(n)} B_j O_i^{(n)} D_j \sum_{k \in M(n)} e^{-\beta^{(n)} c_{ij}^{(k)}} \quad (19.25)$$

$$A_i^{(n)} = \left(\sum_j B_j D_j \sum_{k \in M(n)} e^{-\beta^{(n)} c_{ij}^{(k)}} \right)^{-1} \quad (19.26)$$

$$B_j = \left(\sum_i \sum_n A_i^{(n)} O_i^{(n)} \sum_{k \in M(n)} e^{-\beta^{(n)} c_{ij}^{(k)}} \right)^{-1} \quad (19.27)$$

⁵若希望两种选择对应不同的衰减系数，可先按照 (19.31) 分配目的地，再以出行成本为约束将每个 $T_{ij}^{(n)}$ 分配到不同交通方式，得到类似 (19.21) 的表达式. 两步所用成本可以取 $c_{ij}^{(n)} = \min_{k \in M(n)} c_{ij}^{(k)}$ ，或 $c_{ij}^{(n)} = (\sum_{k \in M(n)} w_{ij}^{(k)} c_{ij}^{(k)}) / (\sum_{k \in M(n)} w_{ij}^{(k)})$ ，其中 $w_{ij}^{(k)}$ 为 i 到 j 流量中交通方式 k 的占比，通过迭代法计算. 类似的方法可用于将 $T_{ij}^{(n)}$ 或 $T_{ij}^{(kn)}$ 分配到不同路径；两种模型的实证结果可验证模式在出行行为中的心理学意义.

另一种约束方式是

$$\sum_j T_{ij}^{(n)} = O_i^{(n)} \quad (19.28)$$

$$\sum_i \sum_n T_{ij}^{(n)} = D_j \quad (19.29)$$

$$\sum_{i,j} T_{ij}^{(n)} c_{ij}^{(n)} = C^{(n)} \quad (19.30)$$

其中 $c_{ij}^{(n)}$ 是人群 n 感知的出行成本. 由此得到模型

$$T_{ij}^{(n)} = A_i^{(n)} B_j O_i^{(n)} D_j e^{-\beta^{(n)} c_{ij}^{(n)}} \quad (19.31)$$

$$A_i^{(n)} = \left(\sum_j B_j D_j e^{-\beta^{(n)} c_{ij}^{(n)}} \right)^{-1} \quad (19.32)$$

$$B_j = \left(\sum_i \sum_n A_i^{(n)} O_i^{(n)} e^{-\beta^{(n)} c_{ij}^{(n)}} \right)^{-1} \quad (19.33)$$

以上两个模型的对比给出多种交通方式复合成本的一种表达式⁶

$$c_{ij}^{(n)} = \frac{\ln |M(n)| - \ln \sum_{k \in M(n)} e^{-\beta^{(n)} c_{ij}^{(k)}}}{\beta^{(n)}} \quad (19.34)$$

19.2.3 中介机会模型

记 S_j 为 j 地的机会数. 对起点 i , 将目的地按阻力从小到大排序, 记为 $j_1, \dots, j_{N-1}$. 假设个体按该顺序选择目的地, 到 j_μ 依然无法满足需求的概率为 U_{ij_μ} , 并设

$$U_{ij_\mu} = \prod_{k=1}^{\mu} (1 - LS_{j_k}) \quad (19.35)$$

又设 $A_{j_\mu} = \sum_{k=1}^{\mu} S_{j_k}$, 有

$$\frac{U_{ij_\mu} - U_{ij_{\mu-1}}}{U_{ij_{\mu-1}}} = -L(A_{j_\mu} - A_{j_{\mu-1}}) \quad (19.36)$$

不严格地, 有

$$\frac{dU}{U} = -LdA \quad (19.37)$$

⁶两式中 $\beta^{(n)}$ 可能不同, 这里取相等值使之单位一致; 乘积因子 $|M(n)|$ 的引入保证了 $c_{ij}^{(n)}$ 非负.

因此导出中介机会模型

$$U_{ij\mu} = k_i e^{-LA_{j\mu}} \quad (19.38)$$

$$\begin{aligned} T_{ij\mu} &= O_i(U_{ij\mu-1} - U_{ij\mu}) \\ &= k_i O_i(e^{-LA_{j\mu-1}} - e^{-LA_{j\mu}}) \end{aligned} \quad (19.39)$$

取 $k_i = 1/(1 - e^{LA_{jN-1}})$ 可保持流出量, 事实上通常 $1/(1 - e^{LA_{jN-1}}) \approx 1$.

本书试图用最大熵方法导出中介机会模型, 但目标函数定义不正确, 使用的成本约束也不合理。

19.3 商品流模型

考虑一类商品 m (相应变量用上标 (m) 表示, 讨论单一商品时略去), 记 x_{ij} 为区域 i 生产、区域 j 消费 (包括用于生产或终端消费) 该商品的量; c_{ij} 为运输一单位该商品的平均费用; X_i, Y_i 分别为区域 i 生产、消费该商品的总量, $X = \sum_i X_i = \sum_j Y_j$.

19.3.1 重力模型

商品流的重力模型可表达为

$$x_{ij} = K X_i Y_i f(c_{ij}) \quad (19.40)$$

其中 $K = X/(\sum_{i,j} X_i Y_j f(c_{ij}))$, 不同商品的 f 可能不同. 当 X_i, Y_i 均为已知, 估计值可直接计算; 否则需要用 $\sum_j x_{ij}(\sum_i x_{ij})$ 代替 $X_i(Y_j)$, 此时模型求解需要迭代法.

对于 $\{X_i\}$ 或 $\{Y_i\}$ 为已知值的情形, 估计的一阶流量不一定与已知值一致. 添加下列约束及其组合

$$\sum_j x_{ij} = X_i \quad (19.41)$$

$$\sum_i x_{ij} = Y_j \quad (19.42)$$

依次得到生产约束、吸引约束、双边约束的重力模型. 注意 $\{X_i\}$ 或 $\{Y_i\}$ 已知才能添加对应的约束; 否则根据前述变量替代操作, 约束自然满足. 此外, 模型中的 X_i, Y_j 可以增加幂次参数, 但仅限相应变量未出现在约束中的情形.

生产约束模型 (production-constrained):

$$x_{ij} = A_i X_i Y_j f(c_{ij}) \quad (19.43)$$

$$A_i = \left(\sum_j Y_j f(c_{ij}) \right)^{-1} \quad (19.44)$$

吸引约束模型 (attraction-constrained):

$$x_{ij} = B_j X_i Y_j f(c_{ij}) \quad (19.45)$$

$$B_j = \left(\sum_i X_i f(c_{ij}) \right)^{-1} \quad (19.46)$$

双边约束模型 (production-attraction-constrained):

$$x_{ij} = A_i B_j X_i Y_j f(c_{ij}) \quad (19.47)$$

$$A_i = \left(\sum_j B_j Y_j f(c_{ij}) \right)^{-1} \quad (19.48)$$

$$B_j = \left(\sum_i A_i X_i f(c_{ij}) \right)^{-1} \quad (19.49)$$

双边约束模型可通过最大熵方法导出, 步骤与交通流中的重力模型相同. 对单边约束模型, 以生产约束为例, 最大熵方法给出

$$x_{ij} = A_i X_i e^{-\mu c_{ij}} \quad (19.50)$$

$$A_i = \left(\sum_j e^{-\mu c_{ij}} \right)^{-1} \quad (19.51)$$

将 c_{ij} 改写为 $c_{ij} - v_j$, v_j 为区域 j 消费一单位商品 (相对于其它区域) 的效益; 再用消费规模作为效益的代理量, 令 $\mu v_j = \alpha \ln Y_j$, 即得所求模型 (α 为 Y_j 的幂次参数). 无约束模型可通过同时引入生产、消费端的效益导出.

经济学文献中出现过与重力模型类似的形式 (如 Theil)

$$x_{ij} = \frac{X_i Y_j}{X} Q_{ij}, Q_{ij} = \frac{x'_{ij} X'}{X'_i Y'_j} \quad (19.52)$$

其中 x'_{ij}, X'_i, Y'_j, X' 为历史数据.

19.3.2 投入产出模型

考虑单一区域中的商品部门 $1, 2, \dots, n, \dots$, 设生产的商品 m 对商品 n 的输出为 $Z^{(mn)}$, 终端消费量 (含出口) 为 $y^{(m)}$, 则有

$$\sum_n Z^{(mn)} + y^{(m)} = X^{(m)} \quad (19.53)$$

设生产一单位商品 n 需要的商品 m 为已知的常数 a_{mn} , 即 $Z^{(mn)} = a_{mn}X^{(n)}$, 我们得到

$$\sum_n a_{mn}X^{(n)} + y^{(m)} = X^{(m)} \quad (19.54)$$

其矩阵形式为 $X = (I - a)^{-1}y$.

Leontief 和 Strout 将上述框架扩展到多区域:

$$Y_i^{(m)} = \sum_n a_{mn}^i X_i^{(n)} + y_i^{(m)} \quad (19.55)$$

其中 $X_i^{(m)}, Y_i^{(m)}$ 分别为区域 i 生产、消费商品 m 的总量, $y_i^{(m)}$ 为终端消费量⁷.

本书通过最大熵方法实现重力模型与投入产出模型的结合. 在 Leontief-Strout 约束基础上加入成本约束

$$\sum_{i,j} x_{ij}^{(m)} c_{ij}^{(m)} = C^{(m)} \quad (19.56)$$

以及已知生产、消费总量时可选的约束

$$\sum_j x_{ij}^{(m)} = X_i^{(m)} \quad (19.57)$$

$$\sum_i x_{ij}^{(m)} = Y_j^{(m)} \quad (19.58)$$

可导出无约束、单边约束、双边约束的重力-投入产出模型. 无约束模型:

$$x_{ij}^{(m)} = \delta_i^{(m)} \epsilon_j^{(m)} e^{-\mu^{(m)} c_{ij}^{(m)}} \quad (19.59)$$

$$\delta_i^{(m)} = \prod_n \left(\epsilon_i^{(n)} \right)^{-a_{mn}^i} \quad (19.60)$$

$$\epsilon_i^{(m)} = \frac{y_i^{(m)} + \sum_n a_{mn}^i \delta_i^{(n)} \sum_j \epsilon_j^{(n)} e^{-\mu^{(n)} c_{ij}^{(n)}}}{\sum_j \delta_j^{(m)} e^{-\mu^{(m)} c_{ji}^{(m)}}} \quad (19.61)$$

⁷他们假定 $X_i^{(m)}, Y_i^{(m)}, X^{(m)}$ 均未知, 通过对 $x_{ij}^{(m)}$ 求和得到. 设商品数为 M , 区域数为 L , 式 (19.52) 除 $i = j$ 的情形给出 $ML(L-1)$ 个约束, 加上 ML 个投入产出关系, 恰与未知数数量相同.

其中 δ, ϵ 需要迭代求解.

生产约束模型:

$$x_{ij}^{(m)} = A_i^{(m)} X_i^{(m)} \epsilon_j^{(m)} e^{-\mu^{(m)} c_{ij}^{(m)}} \quad (19.62)$$

$$A_i^{(m)} = \left(\sum_j \epsilon_j^{(m)} e^{-\mu^{(m)} c_{ij}^{(m)}} \right)^{-1} \quad (19.63)$$

$$\epsilon_i^{(m)} = \frac{y_i^{(m)} + \sum_n a_{mn}^i X_i^{(n)}}{\sum_j A_j^{(m)} X_j^{(m)} e^{-\mu^{(m)} c_{ji}^{(m)}}} \quad (19.64)$$

吸引约束模型:

$$x_{ij}^{(m)} = \delta_i^{(m)} B_j^{(m)} Y_j^{(m)} e^{-\mu^{(m)} c_{ij}^{(m)}} \quad (19.65)$$

$$B_j^{(m)} = \left(\sum_i \delta_i^{(m)} e^{-\mu^{(m)} c_{ij}^{(m)}} \right)^{-1} \quad (19.66)$$

$$\sum_n a_{mn}^i \delta_i^{(n)} \sum_j B_j^{(n)} Y_j^{(n)} e^{-\mu^{(n)} c_{ij}^{(n)}} = Y_i^{(m)} - y_i^{(m)} \quad (19.67)$$

对于双约束的情形, Leontief-Strout 约束已不含 $x_{ij}^{(m)}$ 项, 而成为已知量应满足的条件. 这意味着重力模型和投入产出模型已经解耦, 可用单一商品的重力模型估计流量.

考虑到不同商品的特性, 可以进一步将商品分为四类, 依次采用无约束、生产约束、吸引约束、双约束, 用最大熵方法导出复合重力-投入产出模型.

Chapter 20

地理信息科学与系统

Geographic Information Science and Systems

*Paul A. Longley, Michael F. Goodchild, David J. Maguire,
David W. Rhind*

20.1 引言

格言: "Everything that happens, happens somewhere."

涉及地理信息的问题场景分类标准: (1) 空间尺度, 或涉及到的地理细节的层次。(2) 时间尺度。(3) 目的, 好奇心驱动的科学或现实世界中的问题求解。二者使用的方法没有明显区别。

Geographic, Geo-spatial, Spatial 往往可以混用。后者强调不限于地球表层空间, 事实上空间分析也适用于其它星球、宇宙空间、人体空间等。

Spatial is Special (GI 的特殊性):

- 几乎所有的人类活动和决策涉及位置因素, 而且后者是十分重要的
- 空间数据是高维数据 (二/三维位置加属性); 数据量可能很大; 可能需要多源融合
- 在计算机中有不同表达方式; 可以在不同尺度进行表达; 需要投影到平面

- 需要独特的分析和可视化方法

知识 (Knowledge) 分为可编码 (codified) 和隐性 (tacit) 知识, 前者容易书写和传递, 后者难以传递。

地理知识可区分为关于形式的 (form, how it looks), 和关于过程的 (process, how it works)。后者可以用于预测, 因而更有价值; 一般也具有更强的可泛化性。个案式的地理学 (idiographic) 更关注形式, 强调区域特性; 普适式的地理学 (nomothetic) 寻求普适的过程。两者都是必要的, 实际问题的解决需要普适过程知识和具体区域知识的结合。GIS 恰恰实现了这种结合, 具体信息存储在数据库中, 而普适知识由 GIS 中的分析方法和工具实现; GIS 既提供了不同地点间泛化的途径, 又顾及了不同地点间独特的语境。

地理信息系统是基于计算机的, 用于收集、存储、处理、分析、可视化地理信息的工具。从某种意义上说, 整个数字世界已经成为一个巨大的、互联的地理信息系统 (Twitter, Flickr, RFID 刷卡, 信令和行车轨迹); GIS 的边界变得模糊, 几乎人人都是 GIS 用户。

地理信息系统的组成部分: 硬件, 软件, 数据, (组织管理上的) 流程, 人, 网络。硬件包括台式机, 笔记本、车载设备等; 软件可以是开源或商业软件, 在本地或云端; 大数据指数数据量大、结构复杂, 超出传统数据管理和处理工具能力。

地理信息科学是使地理信息系统得以实现的一般知识和重要发现, 与技术细节相比具有相对的稳定性。其核心动机是世界中时空现象的表达, 包括形式和过程两个层面。作为一门科学, 其应当具备假设和方法的透明性、客观性、可重复性、结果可验证性、可泛化性。Varenus 计划指出 GIScience 位于个体、计算机、社会三者的交汇点。UCGIS 与 AAG 共同编制了地理信息科学与技术知识体系 (GISBoK)。

对于社会和环境科学而言, 控制条件实验有时难以实施, 带来不确定性; 且个体具有自主性, 故难以得到严格的规律 (law), 往往有反例。

场所 (Place) 是人类对空间的社会建构。空间独立于人而存在, 人的交互和经验通过共同的感知和认识将空间塑造为场所。

发展历史: 开创时期 (20 世纪六七十年代), 商业化时期 (20 世纪八九十年代), 开放和泛用时期 (21 世纪以来)。1963 年加拿大地理信息系统诞生, 最初的目的是土地管理中的面积测量; 1967 年双重独立地图编码 (Dual Independent Map Encoding) 程序诞生, 服务于美国人口普查的街道数字化。70 年代末, 哈佛大学开发了通用的 Odyssey GIS。几乎独立地, 60 年代末英国制图部门开始尝试计算机制图, 到 70 年代末主要国家制图机构都实现了一定程度上的计算机化。80 年代初, 计算设备成本下降, GIS 产业开始快速发展。1981 年 ESRI ArcInfo 发布。

学科地位:

- 商业视角：软件产业、数据产业（政府测绘部门、遥感影像公司、OpenStreetMap 等）、地理信息服务（提供解决方案）。
- 政府视角：商业 GIS 的最大用户群体；分发地理信息数据，特别是公众事务数据 (Public-sector information)。
- 信息科学视角：GIScience 可以视为信息科学或计算机科学的分支。从技术角度，时空数据库、计算几何的很多议题属于计算机科学范畴，但地理信息的独特性决定了其很多原理与信息科学关系微弱。
- 地理学视角：GIS 的很多基础来源于地理学中的空间分析传统。GIS 的发展与地理学、测绘学、规划、景观等学科紧密相关。Neogeography 用于描述互联网制图和网上地理信息传播的发展，其基础是用户和网站的双向交互，如 WikiMapia 和 OpenStreetMap. 仍有地理学家对地理研究中 GIS 的使用持怀疑态度。
- 社会视角：软件商会利用用户暴露的位置信息，或通过 cookie 记录偏好，用于用户画像和广告精准投放。志愿者地理信息 (Volunteered Geographic Information) 指个体自愿提供的地理数据，其内容、范围、收集过程往往定义不完善；志愿者的能力和知识存在差异，数据覆盖也受可达性、个人兴趣等因素影响。有观点批评 GIS 在社会科学中的应用，认为其代表了逻辑实证论 (logical positivism, 即只有可以用逻辑解决的问题才有意义)。

社会问题:

- 知识与权力的关系。GIS 对地表的表达可能对特定人群有利，少数人群或个体的意见可能被忽视。
- 用于军事（对别国的测绘）、侵犯个人隐私（监视）或被恶意目的利用（如开放珍稀动物分布数据引发盗猎，弱势群体数据引发犯罪等）。很多人不知道其个人信息如何被采集、使用。

实例：地理家谱学 (Geo-Genealogy)，分析姓氏的空间分布及其演变过程，也用于研究族群分布。种群基因学 (Population Genetics)，Walter Bodmer 研究英国人等位基因的空间分布，反映族群入侵、定居的历史进程。

20.2 地理数据的性质

有关空间变异 (spatial variation) 性质的基本原理: 邻近效应, 尺度效应, 不同地理现象的共变性 (covariation, 同一位置不同属性存在联系)。

属性数据的分类: 名义 (nominal), 有序 (ordinal), 间隔 (interval), 比率 (ratio) 四种类型。循环量 (如方位角) 需要特殊处理, 不能直接平均 (359° 与 1° 平均非 180°)。若要作为输入特征, 一种处理方式是采用方位角的正弦和余弦。

制图中还区分 spatially extensive 与 intensive 变量。前者仅对整个区域有意义 (如计数), 可视为某一密度场在区域内的积分; 后者在区域同质情况下对每一点都有意义 (如密度, 比率), 可视为某一场在区域内的平均。一般认为等值区域图 (choropleth map) 不能用于 spatially extensive 变量。

空间对象可以是自然的或假想的 (如质心), 按维度分为点 (point)、线 (line)、面 (area)、体 (volume)。实体的表达方式决定了空间变异的分析方法, 且与尺度密切相关。

Scale 一词的多重含义: (a) 数据的细节层次 (level of details, granularity), 即空间分辨率; (b) 研究项目的范围 (extent); (c) 地图的比例尺 (representative fraction). *Lam* 认为有四种含义, 还包括空间过程的范围 (*spatial extent of a spatial process*)。

空间自相关: 由位置和属性的相似性决定。若空间上相似的事物属性也相似, 称为正空间自相关, 与 Tobler 第一定律一致; 反之为负空间自相关。空间自相关有助于对世界的建模, 但不利于地理变量的统计推断和预测 (违反了样本独立性假设)。

“The past is the key to the present” 概括了事件发生的时间语境。时间上的因果只有一个方向, 解释当下只需要考虑过去; 而空间现象的解释需要考虑所有方向。我们认为时间相近的事件关联更强; Tobler 地理学第一定律是其在空间上的类比, 即相近的位置更相关或相似。Tobler 定律意味着空间分布的连续渐变性, 现实中也存在不规则突变的反例。

认识空间自相关的两种途径: 演绎法 (deductive) 依据理论推导; 归纳法 (inductive) 从数据出发度量自相关。自相关统计量通常考虑位置相似度 (即空间权重 w_{ij}) 与属性相似度 c_{ij} 的交叉乘积 $\sum_{i,j} w_{ij}c_{ij}$, 可用于空间点或多边形图层的属性, 或网络的边权。假定地理过程不存在异质性, 低空间自相关可能表明存在局部性的影响因子; 而高空间自相关往往伴随区域尺度的变异, 可能受大尺度因子影响。

空间异质性: “the tendency of geographic places and regions to be different from each

other”。空间变异可能是可控 (controlled variance) 的或不可控的 (uncontrolled variance), 前者在某一均值附近振荡; 后者观测时间越长变化越剧烈。一般而言, 距离越大, 空间数据的变幅越大, 异质性越强。

空间采样: 数据采集涉及尺度、采样方式、样本权重。事实上任何地理表达都可以视为采样的结果。采样过程要求采样范围 (sample frame) 内每个样本被选中的概率已知, 由此可借助统计推断将样本性质推广到总体。一般的空间采样方式包括随机采样、系统抽样 (等间隔格点) 等。系统抽样对于具周期模式的空间分布 (如规则街区) 可能不具代表性, 对此可先划分均匀网格再在格内随机选点。当采样难以覆盖整个区域时, 可在有代表性的若干局部区域聚集采样。有时需要划分子区域, 进行分层采样, 如异质性明显的区域比相对同质的区域需要更小的采样间隔。对于空间结构已知情形, 可以设计有针对性的采样方案, 如沿样带、等高线采样。

距离衰减: 体现在某一地点与其它地点的交互或影响力中, 如污染物排放、噪声传播、公园游客等; 也用于空间插值中采样点的加权。常见的衰减权重包括线性型 ($w_{ij} = a - bd_{ij}$), 幂律型 ($w_{ij} = d_{ij}^{-b}$), 指数型 ($w_{ij} = e^{-bd_{ij}}$) 等, 这假定了距离衰减是连续变化、各向同性的, 实际有时并非如此 (如诊所的服务区受交通状况、自然因素影响, 并非圆形缓冲区)。

尺度变换下众多自然、人文现象呈现自相似特性, 其带来的不规则空间变异难以用连续光滑函数表达, 可用分形维数等概念描述。

20.3 地理表达

地理表达: 对地球表层空间的一部分构建模型, 尺度覆盖从建筑物到全球。其目的是满足人们对直接感知范围之外的空间和时间的认知需求 (如地理大发现时代地图发挥的巨大作用); 此外现实世界中的计划也可以利用模型仿真模拟。借助多种形式的表达 (个体记忆、照片、文字记录、测量数据等), 人们可以集成远超于个体所能的关于世界的知识。本书关注计算机设备中基于 0 和 1 的数字模型 (digital model), 其相比于纸质地图具有易存储、易复制、表达能力强 (动态、三维、不必投影到平面)、便于分析的优点。计算机无法表达无限复杂的现实世界, 必须限制细节的层次, 忽略某些属性或其时态变化。

数据的二进制表示法: 整型 (short, long)、浮点型 (single: 7 位有效数字; double: 14 位)、ASCII 码、BLOB(binary large object, 用于图像、音频等)。

“Geographic data link place, time, and attributes.” 地理数据的最小单元包含位置、时间（可选）和属性信息。“珠峰海拔为 8848.86 米”可分解为两条原子信息：珠峰的经纬度、这一位置的海拔高度。这一最小单元即 *Geo-atom*。其中地理位置是将地理信息与其它信息区别开来的要素。

对象模型：离散的对象模型认为空间本是空的，边界明确的对象占据了空间，对象是更广泛类属的实例。对象模型对于边界不易确定的事物（如山峰、湖泊）面临困难。认为对象属性均质也是一个局限。“Nothing on the natural Earth looks remotely like a table!” GIS 对三维对象的处理能力有限，一般近似为更低维度的对象。交通网络中的 overpass 和 underpass 可通过记录一个方向可否转向另一方向实现。

场模型：连续的场模型认为地理世界可以用一系列变量描述，这些变量可以在地表每个位置被测量；包括标量场和矢量场。场的变化有是否平滑之分，地块类型可视为一种边界突变的场；人口密度也是一种场，但在面积单元过小（小于个体尺度）时无意义。

对象模型和场模型只是概念模型，仍包含无限的信息量，没有解决数字化表达问题。栅格和矢量是解决这一问题的两种方式。离散对象易于用矢量表达，而连续场的计算机建模有采样点（规则或非规则）、规则网格、不规则多边形、不规则三角网 (Triangulated Irregular Network, TIN)、等高线等方式，其中除规则采样点、网格外均属于矢量模型。与对象模型不同，它们并非真实存在的地理对象。

地理信息综合 (generalization): 对要素的综合体现在特定比例尺下的制图规范中（如决定多大的要素绘在图上）。McMaster 和 Shea 归纳了十种制图综合操作。折线的简化是最常见的制图综合形式之一，可用 Douglas-Poiker 算法实现。一些 GIS 已开始支持圆弧、椭圆弧、Bézier 曲线等，但其简化和分析方法尚无共识。此外要素的属性信息也涉及综合。

纸质地图在计算机中存储的方式包括数字线划地图 (digital line graph) 和数字栅格地图 (digital raster graphic)。空间数据集来源于纸质地图时，地图的比例尺有时被称为数据集的比例尺。互联网地图可将矢量数据即时渲染为栅格发送到移动客户端，以实现方向调整等需求。

与空间相关的核心概念（如包含、邻近性）和空间数据模型一起构成了本体 (ontology)，即获取地理知识的框架。

20.4 地理参照

地理参照 (georeference; geolocate, geocode 与之近义) 即在地理信息中指定地理位置的过程, 涉及地理位置的表达。

地理参照系统的要求: (1) 使用范围内的唯一性, 每个参照对应唯一地点; (2) 含义被该系统使用者共享; (3) 时间上的稳定性 (反例如地名、行政边界的演变); (4) 位置精度 (即不确定性, 可用面积表示, 与分辨率或测量误差有关)。前两项为基本要求。

地名和 POI: 地名词典 (gazetteer) 包含官方定义的标准名称, 兴趣点 (point-of-interest, POI) 数据库也已被集成, 用于互联网地图服务。由于邮政系统的发展, 一个县 (county) 范围内的地名一般没有重复, 但全球范围内地名重复仍很常见。街道名称一般仅在同一城市唯一。同一地物也可能存在多个名称。地名的位置不确定度往往较大; 大量地名未被官方确认, 只用于当地社群中。Wikimapia 的出现一定程度上改变了这一状况, 居民可以独立地命名当地地物。事实上在政府测绘部门出现之前的时代, 地名命名也是一种个体行为 (如制图师 Waldseemüller 对 America 的命名)。

邮政地址和编码: 对邮政业务可达的住宅、办公室提供地理参照。大量自然地物没有邮政地址和编码。若住宅不沿街道一次编号, 无法用线性插值估计位置 (如日本门牌号按建筑年代编号)。大量 GIS 应用依赖通信地址到经纬度的转换 (在互联网地图 API 中被称作地理编码, 反向转换为逆地理编码)。

IP 地址: 每个连接到互联网的设备有唯一的 IP 地址, 可用于概略定位。

线性参照系统: 通过从特定点 (网络节点) 出发, 沿特定路径 (网络中的边) 的距离描述位置, 用于公路、铁路、电网、管道网络等。两条路多次相交, 或路与自身相交, 可能给线性参照带来问题。

基于坐标系的**度量参照** (metric georeference) 理论上可以实现无限高的定位精度, 且便于距离计算。

经度 λ 的定义可适用于任何旋转体, 而纬度 ϕ 的定义依赖于椭球体 (椭球面垂线与赤道面夹角)。不同椭球体下同一经纬度的位置可相差 100 m 之多。同一经线圈上纬度的 1° 约为 111 km, $1'$ 约为 1.86 km (也即 1 海里); 赤道上经度类似, 其它纬线圈经度则向两极减小。以十进制小数表示时, 纬度小数点后第 5 位约为 1 m, 受精度限制一般不需要表达更多位数。地表两点大圆距离的计算公式为:

$$R \arccos(\sin \phi_1 \sin \phi_2 + \cos \phi_1 \cos \phi_2 \cos(\lambda_1 - \lambda_2)).$$

将地球表面投影到平面的目的包括：(1) 平面地图、图像（如航空相片）作为地理信息的输入、输出媒介；(2) 栅格本质上是平面的；(3) 同时展现地球表面的全貌。

地图投影的性质主要有等角 (conformal)、等积 (equal area)，二者不可得兼。前者保证每一点处不同方向的缩放比例相同，后者保证地图上的面积缩放比例相同。还可分为圆柱 (cylindrical)，圆锥 (conic)，方位或平面 (azimuthal, planar) 投影；这三个主要类别并未涵盖所有投影。

常见投影：

- Plate Carrée 投影：直接将经纬度对应为 x, y ；也称 unprojected projection，等距正轴圆柱投影，每一点到赤道距离的缩放比例相同。由于经纬度 1° 的差异可能很大，不适于 GIS 空间分析。
- Lambert 等角圆锥投影
- Mercator 投影：等角正轴切圆柱投影，能保持恒定航向的航线为直线。
- UTM(Universal Transverse Mercator)：等角横轴割椭圆柱投影，按 6° 分带后缩放比例在 0.9996（中央经线）至 1.0004（分带边界）之间。UTM 分带坐标系伪东偏移 500 km，南半球伪北偏移 10 000 km。分带给跨边界的城市或国家带来困难，高纬地区常改用切点为极点的方位投影。

全球导航卫星系统可用于测量经纬度和高程。确定经纬度需要地平线上至少三颗卫星；确定经纬度和高程需要四颗。GPS 的平面定位精度约 10 m（使用差分 GPS 可提升至 1 m）；高程精度约 50 m。

混搭 (mashup) 指通过位置关联（类似图层叠加）组合两种或以上互联网服务，实现它们各自不具备的新功能。如将住房列表接口与互联网地图组合，得到住房地图。

地理配准 (georegistration) 可以根据一组参考点拟合变换方程，将未知坐标系的几何数据或图像配准到已知坐标系的图像。

20.5 不确定性

大多数地理表达不完备，带来不确定性。不确定性 (uncertainty) 描述数据集内容与其数据表达的现象的差异，可以作为表达质量的笼统描述，不区分与 vagueness, fuzziness, imprecision, inaccuracy 等概念的差异。不确定性可在概念化 (conception)、地理表达

(representation)、数据分析 (analysis) 三个环节中产生并积累。

概念化中的不确定性：包括地方 (place) 和属性 (attribute) 的概念化。

地方 (place) 概念化为带边界的分析单元,但很多情况下地理分析没有自然的单元。Barry Smith 区分了两种空间边界: 自然具有的 (*bona fide*) 和人为划定的 (*fiat*); 地理分析中的单元多数是后者。划分同质区域 (homogeneous zone) 从而最大化区域间异质性,是区域地理学的基本主题。另一种方式是划分功能区 (functional zone) 使区内交互量最大、区域间交互量最小; 或根据设施的影响范围分划。

属性 (类别) 标签可能具有主观性、模糊性,模糊逻辑可缓解这一问题,但其隶属度的精确性受争议 (仍是主观的)。采用直接或间接的指数代替所描述的现象,也会因二者对应的不完全性产生不确定性。

表达中的不确定性：位置表达中,矢量线的简化有较大自由度; 出于减少数据量或隐私保护目的,也将点数据 (如个体位置) 聚合到面单元。栅格影像中覆盖多种类型土地的像元称为混合像元 (mixel), 当分类数目不变,混合像元比例随分辨率提高而减少。

分析中的不确定性：计算结果的误差可利用数据误差的度量和分布分析得到,也可采用重复模拟的方法评估。误差的空间结构 (空间自相关性质) 对 GIS 分析操作的不确定性有重要影响,使误差对许多操作的影响减小 (如计算两点间距离、坡度),也减少了数据集的“自由度”; 但当两数据集叠加时,误差可能会较大。利用模拟分析误差的影响时,应考虑误差的空间自相关。

生态谬误 (ecological fallacy) 指基于聚合数据对个体特性的不合理推断。分析单元内的异质性会增加生态谬误出现的可能性和严重性。与之相对的是原子谬误 (atomistic fallacy), 即认为个体孤立于所处的环境。

可变面积单元问题 (modifiable areal unit problem): 包括尺度效应 (scale effect) 和分区效应 (zoning effect)。双变量相关系数通常随聚合尺度增大而变得更显著 (一个实例由 Yule 和 Kendall 发现); 多变量分析的尺度效应没有一致、可预测的趋势。1984 年 Openshaw 的研究表明,相关和回归分析中的不同预设结果可通过调整分区方式实现; 1812 年 gerrymander 事件是一个现实实例。用地学计算 (geocomputation) 方法进行区域划分,有助于理解输出的敏感性,但难以得到无可争议的最优解。分析单元的划分方式难以用抽样和统计推断的方法处理。作者提倡依据清晰的假设定义分析单元,并用 (反映单元内部异质性的) 外部数据源验证划分的合理性。

不确定性的度量方法：

分类变量：混淆矩阵 (confusion matrix)，相比于正确率，Kappa 指数用随机分类结果进行修正：

$$\kappa = \frac{\sum_i c_{ii} - \sum_i c_{.i}c_{i.}/c_{..}}{c_{..} - \sum_i c_{.i}c_{i.}/c_{..}}.$$

其中 n 为类别数， $\cdot$ 代表求和。分类图中的错误不仅存在于类别标签，还存在于区块边界的位置。

连续变量：精度 (precision) 通常指测量结果有效数字的位数（报告结果时应当与实际准确度相对应，不提供更多位数），也用于描述重复测量时结果的变异程度。准确度 (accuracy) 描述测量结果 (均值) 与真实值的差异。两者没有必然联系，高精度的结果仍可能是有偏的 (biased)。误差的常用度量指标是均方根误差 (RMSE)，很多情况下误差符合正态分布。位置的误差可用多元正态分布描述。

如何应对不确定性？(1) 认识到不确定性是不可避免的，而非装作其不存在；(2) 不能将数据当做真实，利用元数据中的数据质量信息评估其可用性；(3) 利用多种数据源进行外部校正，如遥感影像和矢量地图、DEM 和高程点数据；(4) 在报告 GIS 分析结果时体现对不确定性的认识。

20.6 地理信息系统软件

GIS 的三个主要组成部分：用户界面 (user interface)，工具 (tools)，数据管理器 (data manager)。在信息系统的术语中，三者依次对应表示层 (presentation)，业务逻辑层 (business logic)，数据服务层 (data server)。

GIS 的三种架构：桌面 (desktop)，客户-服务器 (client-server)，云架构 (cloud)。GIS 的主要类型包括桌面端 GIS，互联网制图系统 (Web mapping system)，服务器 GIS，虚拟地球，开发者 GIS，移动端 GIS 等。相比于服务器 GIS，互联网制图系统仅提供制图相关功能。开发者 GIS 是用于 GIS 应用开发的组件集。

GIS 的演进：命令行时代，GIS 是处理地理数据、产生派生数据的程序（命令）的集合。20 世纪 80 年代末至 90 年代初，图形用户界面的出现简化了人机交互，高级程序设计语言和 API 的出现为软件的自定义开发提供了便利，GIS 的应用领域大大扩展。近年来互联网服务 (web service) 成为主流范式，也是云 GIS 的组成部分。

主要 GIS 软件：商业软件：Autodesk AutoCAD Map3D, Bentley Map, Esri ArcGIS, Intergraph GeoMedia. 开源软件：Quantum GIS, GRASS, MapServer.

20.7 地理数据建模

“representation”与“model”意义相近，前者侧重于概念层面，常用于学术探讨，后者偏实践。

数据模型用于在计算机中描述和表达真实世界的一部分，直接决定了可以在数据上进行何种分析操作。数据模型涉及现实世界的三个抽象层次：概念模型、逻辑模型、物理模型。概念模型面向人 (human-oriented)；逻辑模型面向实现 (implementation-oriented)，通常用图表表示；物理模型是 GIS 中的真实实现。场、对象属于概念模型；矢量、栅格属于逻辑模型。

CAD 和计算机制图系统中的数据模型：简单的点、线、面矢量符号，一般用局部坐标而非真实地理坐标，对象不能附加属性 (制图系统可加注记)，也无法表达对象间的关系，故不适于地理信息。

栅格数据模型：区别于作为对象属性的图片，须有地理参照信息（像元对应地理位置）。常用压缩方法包括游程长度编码 (run-length encoding)，块码 (block encoding，包括二叉树)，小波 (wavelet) 等。前两种是无损压缩；小波法是有损压缩，用于 JPEG2000 标准。

矢量数据模型：分为简单要素和拓扑要素。简单要素也称 spaghetti，只存储要素坐标，不存储对象关系。拓扑要素要求“逢交必断”，多边形图层需不重叠地填满平面 (planar enforcement)，按节点表、弧段表、多边形表组织，弧段表记录左右多边形。拓扑属性有助于验证数据集的完整性，加速基于拓扑关系的查询。网络模型是一种特殊的矢量模型。

不规则三角网 (Triangulated Irregular Network, TIN) 遵循拓扑数据结构，存储每个三角形的三个顶点和邻接三角形。TIN 的优点是三角形密度可以随空间位置变化；缺点是对异常值敏感（无平滑处理），高程的准确表达需要记录关键特征点（如山峰、山谷）。

对象数据模型：核心是一组对象（类）及之间的关系。地理对象集合了实体的几何数据、属性数据和方法，定义了实体的状态和行为。统一建模语言 (Unified Modeling Language, UML) 常用于描述类之间的关系；计算机辅助软件工程 (computer-aided software engineering, CASE) 工具可基于图表形式的逻辑模型生成物理模型。

20.8 数据收集

数据收集 (data collection) 分为数据采集 (data capture) 和数据迁移 (data transfer)。前者指数据直接输入系统；后者是导入已存在的数字化数据，最常见的方式是通过某种中间格式。地理数据可分为原始数据 (primary data) 和派生数据 (secondary data)，前者专门为 GIS 项目直接测量得到，如遥感影像、实地测绘（含 GNSS、LiDAR）数据；后者为其它目的采集，通常为硬拷贝文件，需要转换到合适的数字格式才能使用，如纸质地形图、相片等。若不计入人力成本，数据收集费用可以占到 GIS 项目总费用的 60%-85%。

模拟数据都需要转化为数字化数据才能加入到 GIS 中，其途径包括扫描、光学字符识别 (Optical Character Recognition)、矢量化、立体摄影测量等。**矢量化**是扫描地图的主要目的之一。手动数字化有点式、流式之分。自动矢量化仍不完善，需要前/后处理，如把虚线边界改为实线、去除盖住边界的注记等。对复杂地图交互（半自动）矢量化更常用。**摄影测量**与数字化相似，区别是还需要采集高程信息；其产品包括 DEM、正射影像、矢量要素及整合得到的三维场景。

数据收集项目需要权衡质量、速度与费用。

20.9 空间数据库

相比于文件管理，数据库管理系统 (Database Management System, DBMS) 的功能优势包括索引、结构化查询语言 (Structured/Standard Query Language, SQL)、访问控制、并发处理（事务机制）、备份等。几乎所有大型 GIS 都使用 DBMS 技术管理数据。

GIS 中常用的三类数据库包括关系数据库 (Relational DBMS)、对象数据库 (Object DBMS) 和对象关系数据库 (Object-Relational DBMS)。ORDBMS 是附加对象处理功能的 RDBMS，IBM DB2、Oracle、Microsoft SQL Server 都属于此类。

数据库针对空间数据的扩展主要包括空间数据类型、空间对象的运算函数、查询优化器、空间索引等。加入空间扩展的 ORDBMS 仍不具备完整 GIS 的分析、制图等功能，往往作为数据与 GIS 之间的中间工具。SQL 的扩展 SQL/MM 支持了空间数据类型和相关

函数。几何对象的运算包括距离、缓冲区、凸包、求交等。

Ted Codd 提出的若干范式可通过拆分表格实现，以达到减少冗余的目的，查询时需要重新连接。由于大表的连接操作很费时，GIS 中图层数据表往往不遵循此类范式。

空间数据库中的**拓扑**有两种处理方法：标准化模型 (normalized model) 和物理模型 (physical model)。前者按照弧段-节点结构存储，在实体表中记录每个要素与线、面等基本要素的关联；其几何数据无冗余，但查询、编辑操作涉及多表连接，效率较低；Oracle Spatial 采用。后者在要素的几何字段中存储完整的几何信息（节点序列），拓扑约束在另外的表中存储，拓扑关系由外部程序在需要时计算；ArcGIS 采用。

索引一方面可以避免全表扫描，加快查询效率，另一方面其建立、维护费时（特别是更新频繁的数据库），且占据空间大。空间要素索引的三种常见方法是格网、四叉树和 R 树。**格网索引**记录每个网格中的要素列表，一般三层级的格网能够满足需求。**四叉树** (quadtree) 是一类将平面递归分为四个象限的索引的总称，包括点四叉树、区域四叉树等。区域四叉树常用于索引线、面、栅格，经过四叉树编码，数据可通过 B 树索引。**R 树**利用要素的最小外包矩形 (Minimum Bounding Rectangle, MBR) 将要素分组，索引性能较好，但更新比格网、四叉树费时。

大多数数据库中的事务是短事务，通过加锁进行并发控制（消极并发策略, pessimistic locking）；空间数据库中的编辑、更新可能耗时很长，需要通过版本控制（积极并发策略, optimistic versioning）支持长事务，即为同时产生的更新分配不同的版本，分别记录每个版本的修改，待编辑完成后合并；检测到冲突时自动或交互式地进行处理。

20.10 GeoWeb

GeoWeb 描述了一种已充分实现的远景：数据、软件、硬件等 GIS 的组成部分通过网络远程组织；因特网成为一个巨大的 GIS。相比于传统工作模式，数据存储的位置、数据处理的位置不一定要与用户的位置相同；作为关注对象的位置可以与用户位置相同（用户可以在实地使用 GIS）。信息基础设施 (Cyberinfrastructure) 一词用于描述支撑科学活动的高速网络、高性能处理器、分布式传感网和数据集。

不同设备、数据、程序的互操作依赖标准和规范，其中地理信息领域的规范包括 OGC (Open Geospatial Consortium) 指制定的简单要素规范、地理标记语言 (Geography Markup Language)、互联网服务规范 (Web Map/Feature/Coverage Service)。

对象级元数据 (Object-Level Metadata, OLM) 是一个数据集内容的描述，有助于数据集

检索、可用性的评估。最广泛使用的 OLM 标准是 FGDC (US Federal Geographic Data Committee) CSDGM (Content Standards for Digital Geospatial Metadata)。这一标准旨在列出数据集所有已知、有潜在价值的性质，使元数据的生产成本较高，有时采用精简形式的元数据（如 Dublin Core 标准，不限于空间数据集）。

Geolibrary 是支持根据地理位置检索的网络数据库；Geoportal 是整合众多 Geolibrary 的搜索平台（如美国官方的 geo.data.gov）。

Web 2.0 用于描述互联网内容更多地由用户创作的现象。

基于位置的服务 (Location-based Service) 指计算设备可获知自身位置，并根据位置调整所提供信息的服务。定位方法包括 GNSS、所连接基站位置、IP 地址等。其应用包括紧急求助电话、周边查询与导航等。

两类地理信息分析功能更适合作为服务提供：依赖大数据量、昂贵且更新频繁的数据集（如地理编码、路线查询、地名服务等），依赖专业运行设备的复杂操作。

20.11 地图学

地图是多数 GIS 最重要的输出，是概括、传递 GIS 操作结果的有效手段。可以区分两类 GIS 输出：(1) 遵循制图规范的正式地图 (formal map)；(2) 仅用于显示、分析、编辑、查询的临时地图 (transitory map) 或类地图的可视化 (map-like visualization)。二者在制图目的、工具、技术上存在显著差别。二者分别在本节和下一节讨论。

“地图 (map)”一词用于描述 “digital or analog output from a GI System that shows geographic information using well-established cartographic conventions.” 海图被称为 chart，其含义与 map 一致。地图的两种基本类型是普通地图 (reference map) 和专题地图 (thematic map)。地图满足了地理信息的存储 (storage) 和交流 (communication) 两大功能。地图的局限性包括：(1) 可能在无意或故意的情况下传递误导信息；(2) 只是空间过程的单次采样，重复采样可能存在变异，故基于地图进行推断需谨慎；(3) 使用复杂的分类规则、符号等，未受训练的读图者可能难以解读。相比于纸质地图，GIS 中的数字地图更具灵活性，支持比例尺缩放（避免了制图综合的信息丢失）、动态信息、三维交互、图层显隐控制等，且不受地图分幅的限制。

地图设计的首要目标是分享信息、突出模式和过程、展示结果；做出令人满意、有趣的图片是次要的，不应牺牲对现实的忠实性。Robinson 等的 *Elements of Cartography* 总结了地图设计的七种控制因素：目的（普通/专题地图），现实，可用数据，比例尺，受

众（决策者/专业人士/视障人士），使用条件（室内/室外不同光线条件），技术限制（如显示设备分辨率、传输带宽）。

地图组成：地图主体 (map body)，嵌入或缩略图 (inset/overview map)，图名，图例，比例尺，方向指示（指北针、格网 (grid)、经纬网 (graticule)），地图元数据。

地图符号化：Bertin 和 MacEachren 总结了十种图元 (graphic primitives)，即基本点、线、面的表达维度：尺寸 (size)，朝向 (orientation)，数值 (value，即亮度)，色相 (hue)，饱和度 (saturation)，形状 (shape)，排列 (arrangement)，纹理 (texture)，焦点 (focus)，位置 (location)。其中色相（可能与形状、纹理结合）表示分类属性；位置指投影变换或为增强可理解性进行的偏移。

Chapter 21

这里是中国

中国从哪里来？

约 6500 万年前印度、亚欧板块碰撞产生了青藏高原，深刻影响了中国地貌、气候、水文格局。

- 地貌：云贵高原、黄土高原、内蒙古高原受挤压影响抬升，形成第二级阶梯（三级阶梯：从荒原到都市；人地关系）
- 气候：北纬 30 度副热带高压带本应干旱，青藏高原夏季受热更多产生上升气流(?)，抽吸季风，加剧东南季风深入大陆，导致江南的湿润。南亚季风被阻挡，形成塔克拉玛干沙漠；盛行西风被阻挡，携带西北沙尘形成黄土高原。
- 水系：“高原水塔”，大量冰川，江河发源地
- 生物：许多北极动物发源于青藏高原（因适应寒冷，能在 260 万年前大冰期生存）

可可西里：中国最伟大的荒野

北侧昆仑山，南侧唐古拉山，中央可可西里山；地势相对平缓的沉积盆地；火山遗迹、温泉群

90% 永久冻土，80-120 米厚；大量湖泊、沼泽

植物：簇生柔子草（垫状植物，先锋）

动物：鼠兔，旱獭，黑颈鹤，盘羊，藏原羚，藏野驴，野牦牛，藏羚羊（雄性打斗求偶，

主要繁殖地：卓乃湖；往返迁徙），藏狐，狼

1994 杰桑 • 索南达杰反藏羚羊盗猎牺牲

2017 入选世界遗产，核心区、缓冲区 6 万平方千米

阿里：荒野文明

西藏海拔最高的区域

山峰：纳木那尼 7694（喜马拉雅）、冈仁波齐 6656（冈底斯山脉主峰）

湖泊：扎日南木错（西藏第三大湖）、玛旁雍错

札达土林：2400 平方千米，湖盆沉积物被流水切割

文明：象雄王国（前 4 世纪-7 世纪）：土林上的都城：大鹏银城；雍仲本教发源：不分方向的万字符（雍仲符号）作为神圣符号

古格王国（9 世纪-17 世纪）：吐蕃瓦解，后裔建政权，有“阿里”之称（意为：领地）；引入印度佛教；被拉达克入侵者所灭

横断山：中国极致风光最密集的山脉

南北走向七山脉（横断七脉）平均间距 100km

山峰：梅里雪山 6740（他念他翁山-怒山）；玉龙雪山 5596（芒康山-云岭）；雀儿山 6168（沙鲁里山脉）；格聂山 6204（沙鲁里山脉）；贡嘎山 7556（大雪山）；四姑娘山（幺妹峰）6250（邛崃山脉）；雪宝顶 5588（岷山）

河流：怒江、澜沧江、金沙江、雅砻江、大渡河、岷江（横断六江）。怒江、澜沧江峡谷：高差达 3000-4000 米，向南流出国境；金沙江：丽江石鼓镇长江第一湾向东接纳后三江若尔盖湿地

黄龙、九寨沟：钙华景观（流水溶解碳酸盐，沿途沉积）

丰富的垂直自然带

九寨沟：毁灭与创造

地质基础：浅海古生物骨骼形成的碳酸盐岩沉积

冰川侵蚀产生陡峭山峰、U 型谷

崩塌、滑坡物形成瀑布、堰塞湖；钙华沉积也会形成瀑布台基、分隔湖泊

钙华的不同颜色与其表面微生物种类有关

四姑娘山：冰与岩之歌

冰川侵蚀、流水改造：U 形谷-V 形谷；冰斗湖、冰瀑

丰富的花岗岩：富含 Na、K，利于植物生长。长成乔木的沙棘；红石（藻类附着花岗岩）

花岗岩峰群：多为尖削的角峰；五色山：向斜构造；大峰、二峰、三峰：入门级山峰；幺

妹峰：攀登困难，1981 年首登

伊犁：遥远西部的一个角落

天山主脉、支脉形成向西的喇叭口，携带大西洋水汽的西风形成大量降水（迎风坡 600-800mm）

伊犁河：新疆水量最大的河流，向西注入巴尔喀什湖

植被：雪岭云杉林、野生果树；草原

龚自珍：“北可以制南，南不可制北”（伊犁可以支撑草原政权，南疆绿洲城邦势力弱小）

乾隆帝进军经营伊犁：造城、屯田、移民

罗布泊：楼兰生死五千年

位于塔里木盆地最低洼处，孔雀河、车尔臣河、塔里木河曾经汇集成湖；后下游断流，湖泊干涸，成为遍布荒漠的死亡地带

雅丹地貌分布区

前 3000 年吐火罗人进入、定居

小河墓地：船形棺木（胡杨木）；“小河公主”等干尸

楼兰：前 2 世纪-6 世纪，汉时设西域长史府，前 77 年改名鄯善，东汉中期统一塔里木盆地东南部，成为东西方文化交流通道；因自然环境恶化消失

尼雅遗址：“五星出东方利中国”织锦；佉卢文书：“我渴望追求文学、音乐以及天地间一切知识”

20 世纪后半叶对塔里木盆地的开发使罗布泊完全干涸

1901 斯文·赫定发现楼兰古城

1972 Landsat-1 拍摄“地球之耳”

1980 彭加木失踪

1996 探险家余纯顺脱水而亡

甘肃：愈多元愈美丽

省名取自甘州（张掖）、肃州（酒泉）

三大自然区交会处；多元宗教：崆峒山，拉卜楞寺，莫高窟，麦积山石窟

陇东、陇中黄土高原：沟壑顶部平地（黄土塬）易耕种

陇南山地：秦岭、岷山交会

河西走廊：干旱；祁连山东段降雨丰富，有草原、冰川，中国第二大内陆河黑河发源；“河西四郡”位于绿洲之上

甘南高原：青藏高原边缘

西安：鲜衣怒马一千年

关中平原，北依黄土高原，南临秦岭；秦岭水系带来大量泥沙，厚沉积物

成都：烟火人间三千年

成都平原：龙门山、龙泉山之间，河流泥沙沉积

前 4 世纪建城，城名未改，城址未迁移；约 3000 年前古蜀国（金沙遗址）；秦灭古蜀李冰修都江堰；蜀设锦官城（蜀锦的官府作坊）；张献忠屠城；元末以后大量移民涌入；杨森修森威路（今春熙路），成中央商务区

梵净山：红尘孤岛

主体为变质岩，不同于周围碳酸盐岩，不易被侵蚀；降水充沛

最高峰凤凰山 2570

新金顶上部有裂隙，一分为二

孑遗植物：鹅掌楸、珙桐

黔金丝猴的最后栖息地

河南：造山、造水、造中华

西北太行山：断层形成，河南一侧有陡峭悬崖（林州大峡谷）-安阳

西部秦岭余脉：熊耳山、伏牛山-洛阳

南侧：桐柏山、大别山-南阳

中部、东部：平原-开封

浙江：无敌生产力

以丘陵山地为主，“七山一水二分田”；岛屿最多的省份

得名于钱塘江（又称浙江、之江，自上游依次称新安江、富春江、钱塘江）

黄茅尖 1929（洞宫山脉）；神仙居（括苍山脉）；雁荡山：流纹火山岩

历史：河姆渡（约 7000 年前）：水稻；良渚（约 5300 年前）：玉饰、丝绸；越人（春秋）：越剑、鸟虫书；明清工商业市镇猛增（西塘、南浔、乌镇）

福建：开拓者传奇

80% 以上山地、丘陵，沿海平原；年均降水量超 2000mm，河流众多

武夷山：赣闽边界；丹霞地貌。太姥山：花岗岩峰林

闽江：省内最长河流

四大平原：福州（闽江）、莆田（木兰溪）、泉州（晋江）、漳州（九龙江）

支离破碎地形导致文化孤岛（不同方言、戏剧、神灵、民俗）

元代泉州成为重要港口，出口武夷岩茶等物产

青岛：城市美学史

1897-1914 德国占领青岛，规划建造城市。以总督府为中心；规定建筑外形不能重复；城市绿化的样板（红瓦绿树）

1931-1935 八大关别墅群；圣弥爱尔大教堂；里院的大规模发展（四周合围，中心成院）

江南：江河湖海的盛宴

文化地理概念：长江、钱塘江下游沿岸以及太湖流域

南京：东晋、南北朝，国都

扬州：隋唐，运河枢纽

杭州：南宋，国都

苏州：明清，纺织业，工商业

上海：清末以来，港口，工商业

什么是中国？

农业模式：南稻北稷（包括粟和黍），后北方被小麦玉米等取代

Chapter 22

Michael Batty 评论集

22.1 A new kind of search

2022 年 OpenAI 发布了基于语言大模型的 ChatGPT(Chat Generative Pre-trained Transformer). 作者询问 Zipf 定律这一说法的最早使用者, 得到看似合理实则不正确的答案。作者认为 AI 系统的开发有必要重新强调与人类逻辑思维方式的结合。

Part V

人文与艺术

Chapter 23

南雍古典文学八讲

莫砺锋主编

贵妃之死：五世纪中叶南朝中国的政治、爱情、文学

程章灿

南朝宋孝武帝刘骏荒淫好色，宠幸殷贵妃（依谥号也称宣贵妃，一说为其堂姐妹）。殷贵妃死后文士多献诗、诔文，以谢庄《孝武帝宣贵妃诔文》最著名，但文中用“尧母之门”典，暗指殷贵妃之子刘子鸾将即位。刘骏有意传位刘子鸾，但未废当时太子刘子业。不料刘骏两年后突然死去，刘子业即位为前废帝，谢庄因此遭报复下狱，险丧命。

谁是唐代最伟大的诗人

莫砺锋

《唐宋诗醇》唐代选李白、杜甫、韩愈、白居易四人。作者认为加上王维、李商隐是第一梯队。唐代最伟大诗人的观点除李杜外，清王士禛、宇文所安认为是王维¹。日本学界长期认为是白居易（作者：理解层次不够）。林庚因特殊时代政治因素曾称是黄巢。

李白与杜甫对比：(1) 对对方态度：相遇交游分别后，杜甫多次写诗怀念李白，而李白仅一首诗提到杜甫。(2) 物质生活：李白尽管政治上不得志，生活上不穷困；杜甫则终

¹殷璠《河岳英灵集》中王维、李白选诗数量相当（杜诗当时尚未成熟）。中唐时王维地位已经下降。

生穷困。(3) 思想：杜甫一生推崇儒家，而李白在儒家入世思想之外有反叛和追求自由的一面。(4) 生前诗坛地位：李白生前名声很高，而杜甫并未得到同时代诗人高度评价。

李杜优劣的讨论：中唐两人都受重视，元白认为杜甫更胜一筹，韩愈认为二者同样伟大。北宋起认为杜甫地位更高，如苏轼批评李白人品上不够忠君爱国（晚年从永王军）；诗歌有时率意而锤炼不足。明高棅《唐诗品汇》区分七体²，认为除五绝、七绝外的五体，杜甫是唯一的“大家”。新中国以来认为李杜同样伟大，如郭沫若提出李杜是“中国诗歌史上的双子星座”。作者认为杜甫地位提高的原因是对后世诗歌影响较大，而李白“靠天才作诗”，难以学习。从阅读角度，明王世贞认为“少陵稍难入，青莲较易倦”。

²五古、七古、五律、七律、五绝、七绝、五言排律。

Chapter 24

解谜：向 18 种经典谜题的巅峰发起挑战

The Puzzler: One Man's Quest to Solve the Most Baffling Puzzles, From Crosswords to Jigsaws to the Meaning of Life

A. J. Jacobs

纵横字谜 (crossword): 世界上已知最早的纵横字谜由 Arthur Wynne 设计, 1913 年发表在 The New York World. 《纽约时报》最初对纵横字谜持反对态度, 1942 年由编辑 Margaret P. Farrar 开始刊登纵横字谜; 近三十年的纵横字谜编辑是 Will Shortz¹. 字谜应当避免出现单词重复, 或交叉的两个词都相对生僻的情况。藏词游戏 (cryptics) 主要流行于英国, 玩法与纵横字谜类似, 但线索与答案的联系更为复杂, 一部分是同义, 另一部分可能包括同音、回文等形式。1942 年《每日电讯报》曾用藏词游戏选拔密码破译员进入布莱切利庄园。

魔方 (Rubik's cube).

回文字谜 (anagram): 将一个单词或短语字母重新排列得到另一个含义不同的单词或短语. 至少已有数百年历史, 伽利略使用过, 法王路易十三曾任命“王室回文创作师”. 回文是一种伟大的艺术 (anagrams → ars magna). 始于 1883 年的美国解谜者联盟 (National Puzzlers' League) 在会刊 The Enigma 中有大量回文创作.

2016 年 Will Shortz 创造了拼字蜜蜂 (Spelling Bee) 游戏, 规则是从 7 个六边形阵列的

¹Will Shortz 的大学毕业论文是关于美国早期的字谜历史.

字母中用至少 4 个拼出单词, 且必须用到中心字母, 字母可以重复使用.

画谜 (rebus): 使用字母、插图、创意排版等手段隐藏一个单词或短语.

拼图 (jigsaw): 1760 年前后英国制图师 John Spilsbury 将地图粘在木板上并按国家切成块, 作为地理教具, 这被认为是最早的拼图.

迷宫 (maze): 不同于迷园 (labyrinth), 迷园没有分叉道路, 从起点到终点无需做选择; 古希腊神话中囚禁牛头怪 Minotaur 的迷园其实是迷宫. 中世纪以来欧洲贵族有建造树篱迷宫的风气. Adrian Fisher 是当今最高产的迷宫设计师之一, 作品包括迪拜高楼外立面迷宫等.

迷宫的解法: (1) Wall Follower: 右手放在墙上, 每到路口右转. 不适用于有墙与外墙不相连的情形. (2) Trémaux 法: 标记每个路段的起点和终点, 避开有两个标记的路段. (3) Random Mouse: 每到路口随机决定方向.

数学与逻辑谜题 (math and logic puzzles): 可追溯到约公元前 1500 年古埃及的 Rhind 纸草书 (Rhind mathematical papyrus), 包括 87 个涉及算术、代数、几何的数学问题. 神圣罗马帝国的查理曼大帝聘请 Alcuin of York 为其谜题设计师, 后者著有 *Problems to Sharpen the Young*. 1957 年起, Martin Gardner 在 Scientific American 上撰写专栏介绍数学谜题; 为纪念他, 数学谜题盛会 G4G (Gathering for Gardner) 每两年举办一次.

暗语和密码 (ciphers and secret codes): 暗语是词语或短语层面的替换, 密码是字母层面的替换. 频率分析是破译密码的最主要手段. 历史上的密码包括 15 世纪的伏尼契手稿, 黄道十二宫杀手的密信, Beatrix Potter 的日记等. 1990 年 James Sanborn 为 CIA 设计的雕塑 Kryptos 上包含四段密码, 至今仍有一段 (K4) 未被破译; 已破译的三段使用了 Vigenère 密码和换位密码.

视觉谜题 (visual puzzles): 包括找物型 (找不同、找隐藏物体)、视错觉型等. 历史上的谜题包括 Pieter Bruegal 的画作 *Netherlandish Proverbs*, Martin Handford 的系列图书 *Where's Wally?*. Kit Williams 于 1979 年出版的图画书 *Masquerade* 包含了英格兰某处埋藏黄金兔子雕塑的线索, 一度引发寻宝热潮. 类似作品还有 Byron Preiss 的 *The Secret*, 用密文诗和画隐藏了美国、加拿大的 12 处宝藏.

纸笔谜题: 数独 (Sudoku) 最早由 Howard Garns 于 1979 年发明, 当时称为 Number Place. 1984 年鍛治真起将其改良并命名为数独. 2004 年宫本哲也发明了聪明格 (KenKen).

国际象棋谜题 (chess puzzles): Genrikh Kasparyan 的棋谜以困难著称. 西洋穴怪 (Grotesques) 指在子力明显处于劣势的情形下取胜的棋谜.

谜语 (riddles): 涉及谜语的作品包括《俄狄浦斯王》(斯芬克斯的谜语“什么东西早上四条腿，正午两条腿，晚上三条腿?”，谜底是人);《爱丽丝漫游奇境》(疯帽子的谜语“乌鸦为什么像书桌?”);《蝙蝠侠》(谜语人 Riddler 的谜语);《霍比特人》;《哈利·波特与火焰杯》等。Charade 指将谜底音节分开分别猜测的谜语。

日本机关盒 (Japanese puzzle boxes): 龟井明夫开创了现代机关盒的时代，将机关盒的复杂程度和可玩性提升到新高度。美国机关盒设计师 Kagen Sound 曾设计一个包含 22 个机关谜题的书桌。

争议谜题: Monty Hall 问题 (“三扇门”) 曾引起争议。睡美人问题 (sleeping beauty problem) 则至今仍无定论，主要观点为 $1/2$, $1/3$ 两派。

解谜大赛: MIT Puzzler Hunt 创立于 1981 年，以团队形式解决系列谜题。

Part VI

哲学与社会科学

Chapter 25

马克思恩格斯著作

Works of Karl Marx and Fredrich Engels

25.1 共产党宣言

《共产党宣言》的基本思想（唯物史观）：

1. 每一历史时代的经济生产及其必然产生的社会结构，是该时代政治和精神历史的基础。
2. 原始土地公有制解体以来的全部历史都是阶级斗争（被剥削阶级与剥削阶级，被统治阶级与统治阶级的斗争）的历史。
3. 现代大工业产生的无产阶级，只有使整个社会永远摆脱剥削、压迫和阶级斗争，才能使自己从资产阶级的剥削和压迫之下解放出来。

随着需求的增加、市场的扩大，工业生产方式由封建行会依次转变为工场手工业、现代大工业。阶级对立简单化，社会分裂为直接对立的资产阶级和无产阶级。

《宣言》的**目的**是宣告现代资产阶级所有制必然灭亡。其原因有二：(1) 资产阶级所有制下自由竞争导致生产过剩，产生周期性的商业危机，无产者失业，资产者破产；(2) 劳动的价格与其生产费用一致，从而工人失去财产、变为赤贫者，仅足以维持生活、延续后代，造成革命的因素。从供需角度看，劳动力供过于求使上述情况发生，而这是生产力发展的自然后果。

共产党的理论：代表整个无产阶级的利益、整个共产主义运动的利益。最近目的是推翻资产阶级统治，建立无产阶级政权。理论核心是消灭私有制（并非剥夺占有社会产品的权力，而是剥夺利用这种占有奴役他人的权力）。在共产主义社会，一切生产部门由整个社会经营，工业生产由整个社会按照确定的计划和所有人的需要来领导；“每个人的自由发展是一切人自由发展的条件”¹。

历史背景：《宣言》发表于 1848 年，是马克思和恩格斯应邀为共产主义者同盟撰写的党纲。后者前身是成立于 1836 年的正义者同盟，1847 年在马克思、恩格斯指导下改组为第一个以科学社会主义为指导的无产阶级政党，1852 年科隆共产党人案件后解散。其为 1864 年成立的国际工人协会（第一国际）培养了人才。

在 1847 年，“社会主义是资产阶级的运动，共产主义是工人阶级的运动。”前者寄希望于统治阶级，如欧文、傅里叶的空想社会主义；后者则不局限于政治变革，主张根本改造社会，如卡贝、魏特林。

¹恩格斯的《共产主义原理》将全面发展解释为工种轮换，摆脱分工带来的片面性。

Chapter 26

有了博士学位还不够：学术生涯指南

A PhD Is not Enough! A Guide to Survival in Science

Peter J. Feibelman

作者认为，（自然科学）学术界的生存技能是可以传授的，而非只能通过积累经验获得。

做研究：不应只关注研究中的技术性问题及其解决方案，还要清楚研究的背景和意义，在科学体系中的位置。时至今日，这一点要求已被固化在期刊论文的格式里。建议问题导向而非技术导向，关注科学问题的解决。将较大的研究目标分解为一系列小文章，及时发表（论文量子“publon”）。平行开展两个或多个项目。

选择导师和团队：相比年轻导师，资深导师“不会与你争抢什么东西”，学生的成功就是他的成功；年轻导师可能会对学生或博士后有所戒备，不愿分享科研思路、研究进展。理想的科研团队应当有清晰的目标，内部相互交流；不仅是导师，每个成员也了解研究的整体方向。

做博士后：做出一些成果（谨慎选择长期投入而不能及时出成果的项目）；让同事认可自己的能力（多交流）。

做报告：自信的气场；提纲需要准备，但不必在开始时介绍；除非在讨论技术进展的场合，不必着重公式等技术细节（可以列出公式，但只讲方法的思想和应用，如王劲峰分层异质性报告）。

职业选择：高校教授拥有科研上的自由，广受尊重，寒暑假和学术休假，顾问、编写教材等额外收入；任务繁多（授课，参与学院管理，申请基金，审稿、编辑等学术服务），以

至没有时间参与具体科研工作。助理教授则承受上述多数不利而只有少数好处（低薪、任务繁多且职业没有保障）。政府和企业研究机构职责相对单一，但需受管理。

求职面试：了解听众的需求和对应聘者的期待。表现出积极主动、愿与人交流。有清晰的科研方向、未来两三年的计划；并阐明计划与要加入团队的契合之处。可以向主管领导发邮件确认约定的工作条件。如果必要可以毁约较早的 offer，接下之后更好的。

申请经费：职业早期不建议申请重大、需要多年积累的项目；或者可以分点时间做，快成功时再申请。